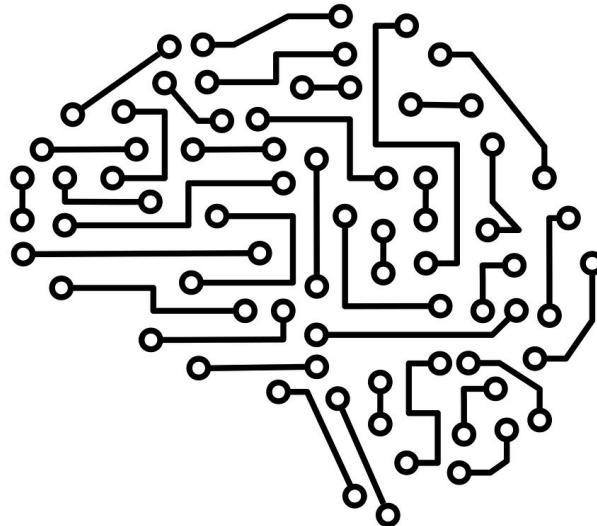


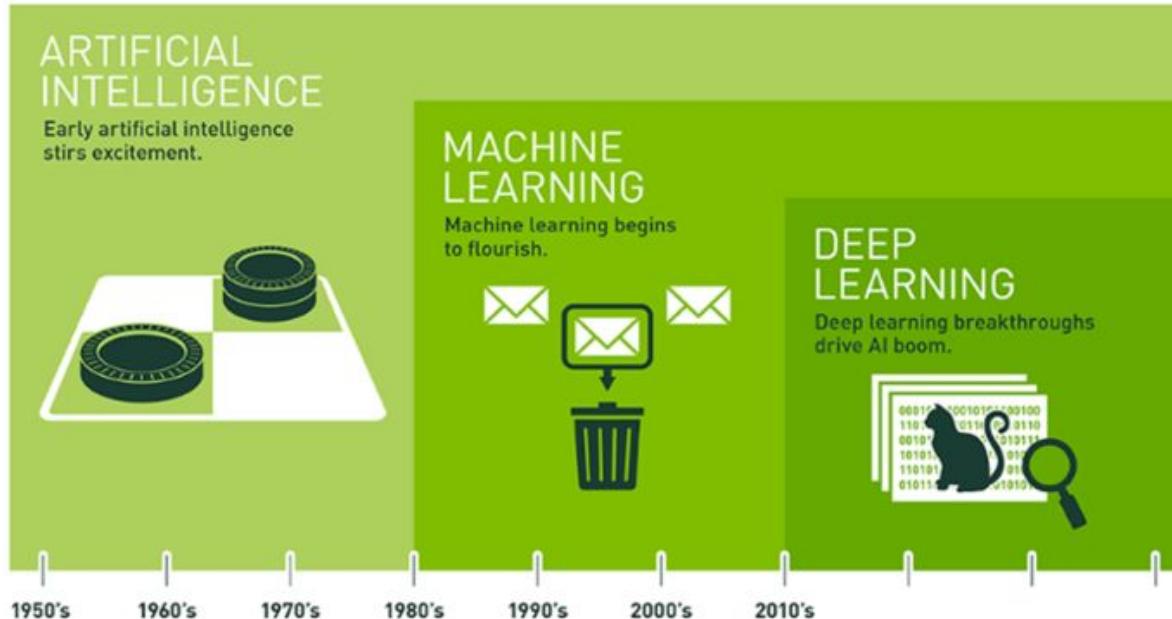
# Deep Learning



# Contents

- Deep Learning?
- ML? DL? AI?
- Deep Learning 적용 사례
- How to start learning Deep Learning?
- Neural Network?
- Keywords

# Machine Learning? Deep Learning? A.I.?



Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

[https://blogs.nvidia.co.kr/2016/08/03/difference\\_ai\\_learning\\_machinelearning/](https://blogs.nvidia.co.kr/2016/08/03/difference_ai_learning_machinelearning/)

# Machine Learning? Deep Learning? A.I.?

- 인공 지능 (Artificial Intelligence)  
기계로 부터 만들어진 지능
- 기계 학습 (Machine Learning)  
통계적 기법을 이용해 데이터로부터 학습
- 딥러닝 (Deep Learning)  
인공신경망을 기반으로 함

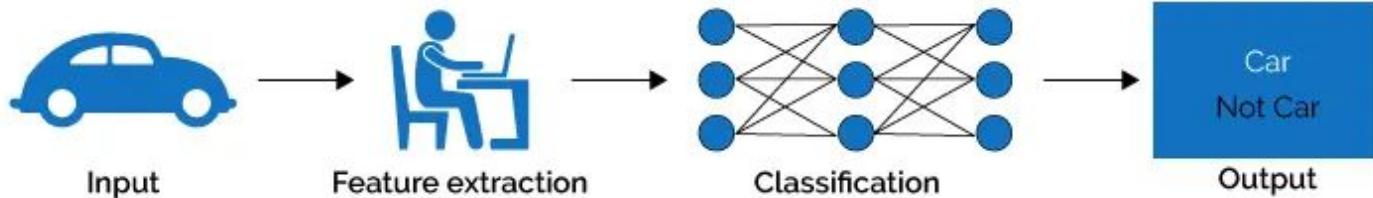
<https://www.hohyeonmoon.com/blog/ai-ml-dl-relation/>

<https://blog.naver.com/PostView.nhn?blogId=dsjang650628&logNo=221864626337>

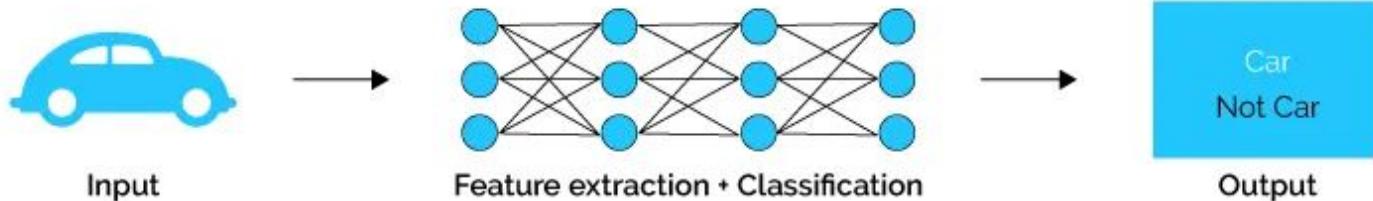
<https://towardsdatascience.com/understanding-the-difference-between-ai-ml-and-dl-cceb63252a6c>

# Why Deep Learning?

## Machine Learning



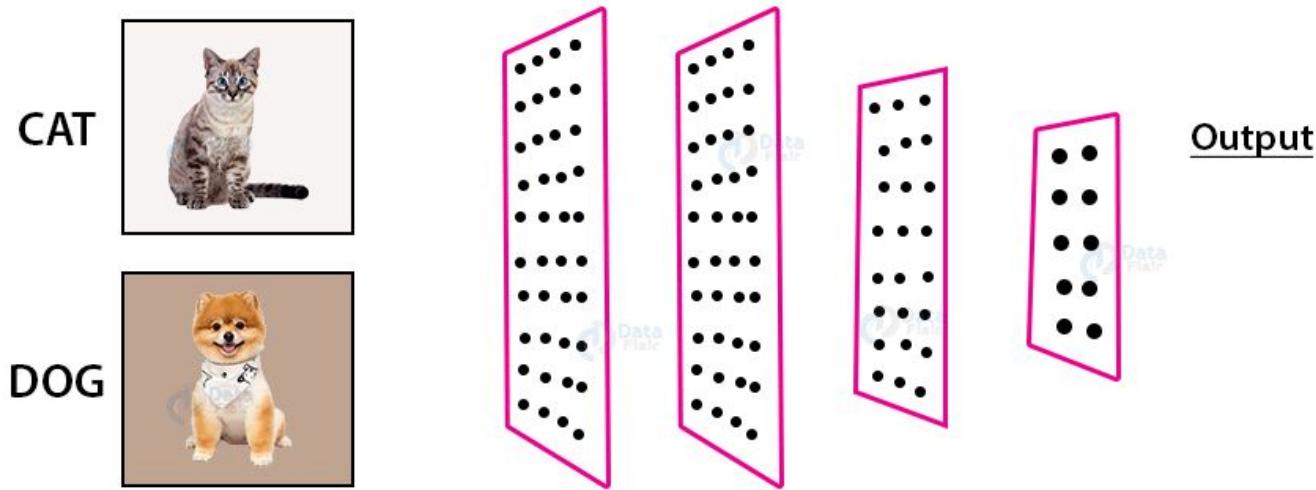
## Deep Learning



# Deep Learning 적용 사례

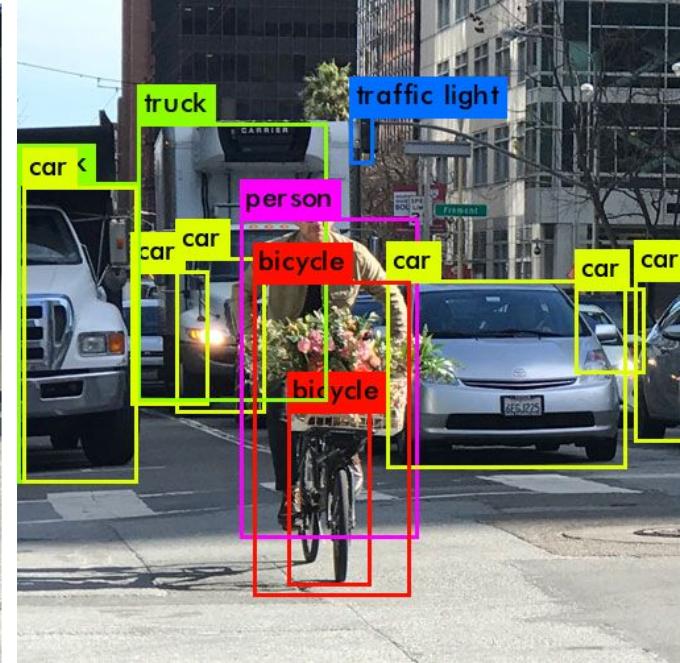
- Classification
- Object Detection & Segmentation
- Generation (Generative Adversarial Network)
- Reinforcement Learning
- 다른 적용 사례들

# Deep Learning - Classification

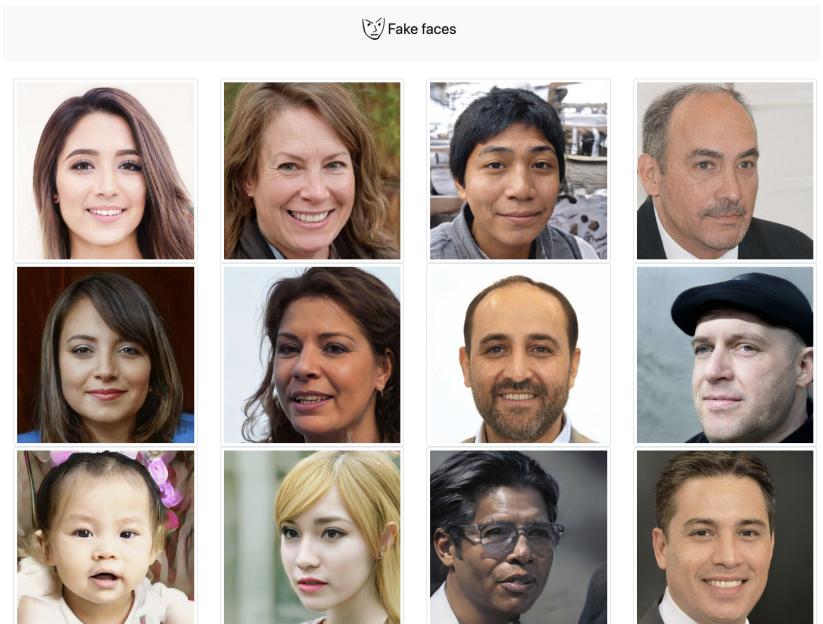


<https://data-flair.training/blogs/cats-dogs-classification-deep-learning-project-beginners/>

# Deep Learning - Detection & Segmentation



# Deep Learning - Generation (GAN)



<https://fakeface.co/>

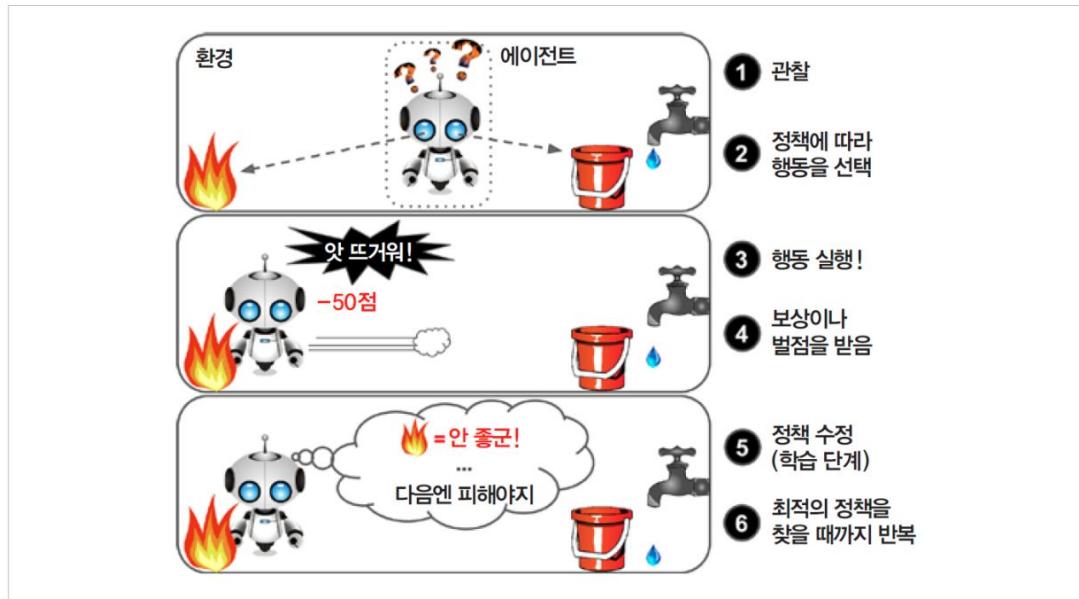


<https://thispersondoesnotexist.com/>

이게 다 가짜라니..

# Deep Learning - Reinforcement Learning

그림 1-12 강화 학습



출처: tensorflow.blog



# Deep Learning 적용 사례

<http://www.yaronhadad.com/deep-learning-most-amazing-applications/>

딥러닝이 적용된 연구 사례, 논문, 프로젝트 등을 소개한 블로그 포스트를 요약 소개함

## 딥러닝 적용 사례 카테고리

- 컴퓨터 비전과 패턴 인식
- 컴퓨터 게임, 자율 주행, 로봇
- 작곡, 음성합성, 입모양 인식
- 딥러닝이 만들어내는 예술 작품
- 컴퓨터 환각, 예측 및 기타 사례 들

# 사례 - 컴퓨터 비전과 패턴 인식

## 정치인 재연

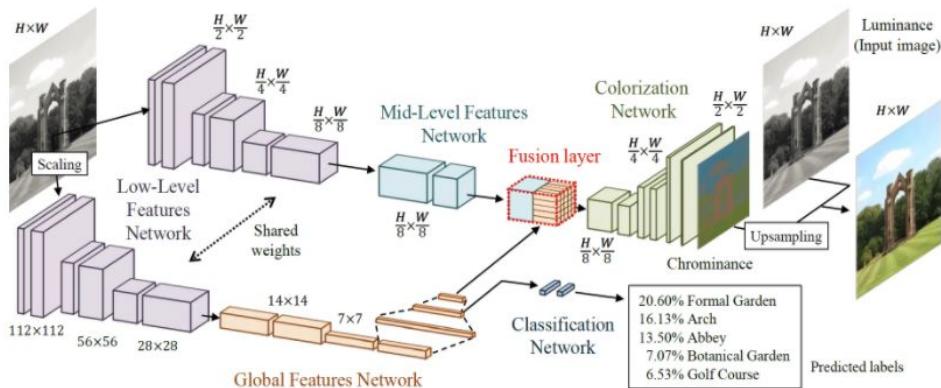
워싱턴 대학의 한 연구 그룹이 오디오 사운드를 이용하여 입술 모양을 재현하는 프로젝트를 수행함



# 사례 - 컴퓨터 비전과 패턴 인식

흑백 사진 색상 복원 (사진, 영상)

Feature network와 colorization network를  
동시에 학습하여 흑백 사진 복원 기술을  
구현함



논문 링크

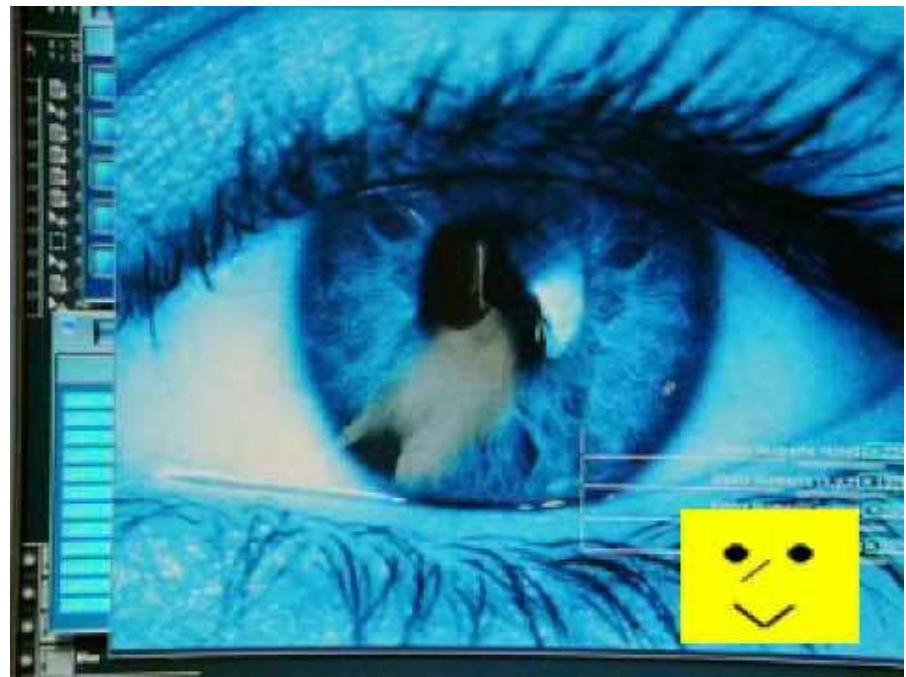
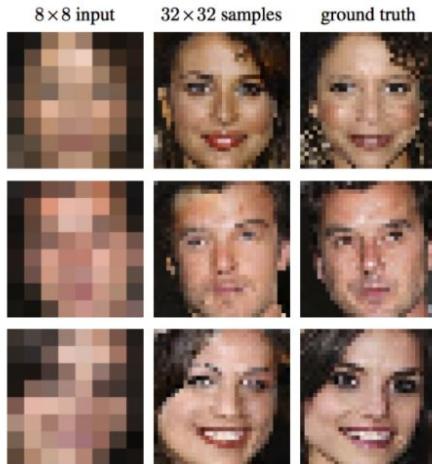
결과  
예시들



# 사례 - 컴퓨터 비전과 패턴 인식

픽셀 복원, 해상도 복원

저해상도 이미지에서 고해상도 이미지를  
복원함

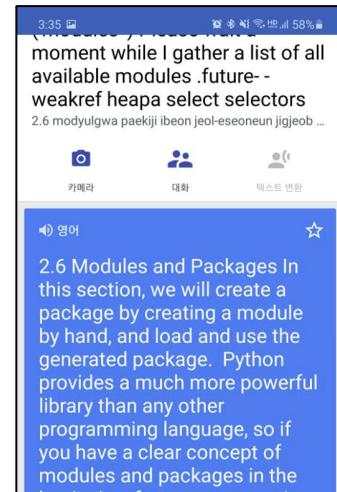
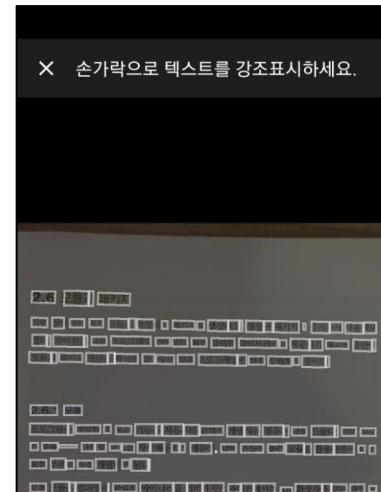
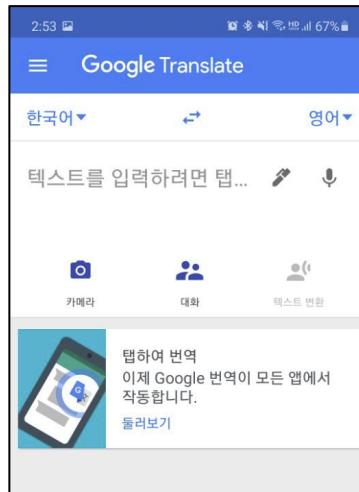


# 사례 - 컴퓨터 비전과 패턴 인식

## 글자 번역 (Google Translator)

[블로그  
링크](#)

이미지에서 글자를 인식하여 번역함



# 사례 - 컴퓨터 비전과 패턴 인식

## 새로운 이미지 생성

이미지의 특성을 학습하여 새로운 이미지를  
생성하거나 주어진 이미지를 재창조함



[이미지 재생성 페이지 링크](#)

# 사례 - 자율 주행 자동차

자동차에 부착된 센서에서 획득 할 수 있는 정보를 이용하여 자율 주행 기능을 수행함

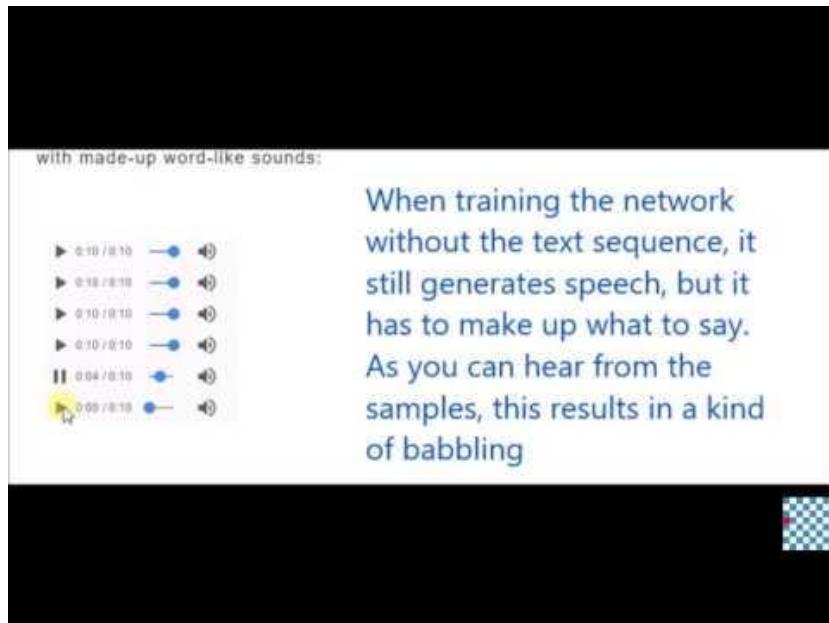
0 단계 비자동화	1 단계 운전자 보조	2 단계 부분 자동화	3 단계 조건부 자동화	4 단계 고도 자동화	5 단계 완전 자동화
<ul style="list-style-type: none"><li>운전자는 상황을 파악하고 운전함</li><li>시스템이 운전자의 가/감속 또는 조향을 보조함</li><li>스마트 크루즈 컨트롤, 차로 유지 보조 등</li></ul>	<ul style="list-style-type: none"><li>운전자는 상황을 파악하고 운전함</li><li>시스템이 운전자의 가/감속 또는 조향을 보조함</li></ul>	<ul style="list-style-type: none"><li>운전자는 상황을 파악하고 운전함</li><li>운전자가 시스템의 요청 시 운전함</li></ul>	<ul style="list-style-type: none"><li>운전자가 시스템에 개입하지 않음</li><li>시스템이 상황을 파악하고 운전함</li><li>교통 혼잡 시 저속주행, 고속도로 주행, 자동 차로 변경 등</li></ul>	<ul style="list-style-type: none"><li>운전자가 시스템에 개입하지 않음</li><li>시스템이 정해진 도로와 조건 하에 운전함</li></ul>	<ul style="list-style-type: none"><li>시스템이 모든 도로와 조건에서 운전함</li></ul>



# 사례 - 소리 데이터

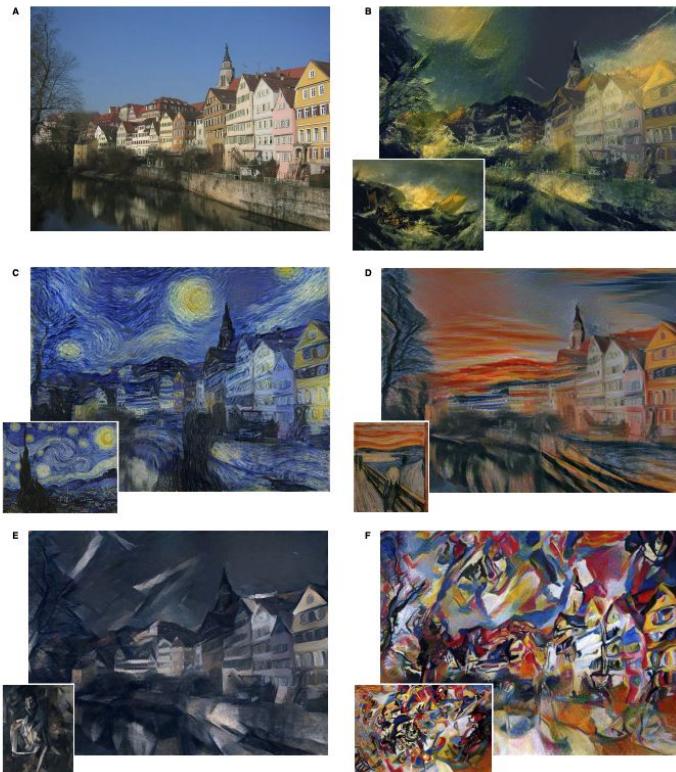
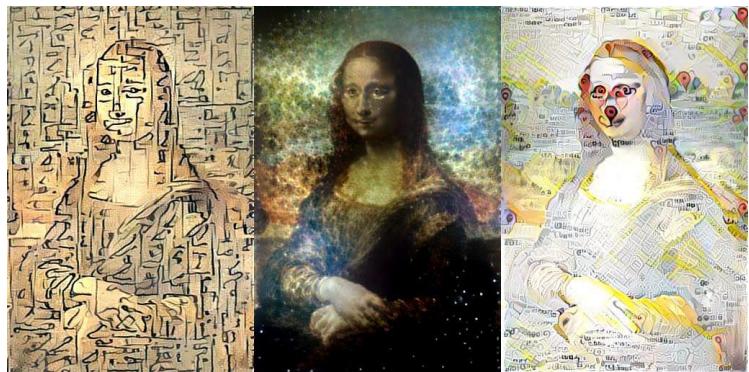
- 음성 합성 기술
- 작곡하는 인공지능

<https://openai.com/blog/musenet/>



# 사례 - 예술 작품

- 화풍을 따라하는 인공지능



[관련 논문 페이지 링크](#)

# 딥러닝 사업화 사례



vFlat - 내 손 안에 책 스캐너, 브이플랫

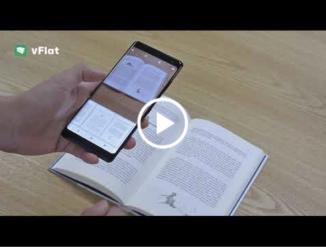
VoyagerX 생산성 ★★★★ 6,554

① 일부 기기와 호환되는 앱입니다.

이 항목을 가족과 공유할 수 있습니다. [기록](#) [콘텐츠](#) [라이브러리](#)

[자세히 알아보기](#)

[설치됨](#)



디지털 한번으로  
빠르고 쉬운 스캔

2019 Google Play 올해의 숨은 보석 앱으로 선정!

vFlat은 문서, 책, 메모 등 핸드폰으로 촬영한 이미지를 고화질 PDF 또는 JPG 이미지로 만들어주는 스캐닝 앱입니다. vFlat은 문서의 테두리를 자동으로 인식하여 자르고 보정합니다. 또한 촬영한 이미지를 텍스트로 변환하여 원하는 키워드를 검색하거나 복사할 수 있습니다.

내가 쓰고, 인공지능이 채워줍니다.

한글 손글씨 폰트에 들어가는 글자는 총 11,172자,  
이를 일일이 적는 것은 무척 힘든 일입니다.

이제, 당신은 300자만 쓰세요.  
나머지는 온글잎의 인공지능이 꽉 채워드리겠습니다.

온글잎  
OWNGLYPH



# Deep Learning History

- [딥러닝 역사 - 타임라인](#)
- [딥러닝 타임라인 - 위키피디아](#)
- [한국테크노파크진흥회 요약자료](#)

# How to start learning Deep Learning?

1. 개발환경 세팅 (pycharm, anaconda, colab, 등)
2. Framework 선택 (tensorflow, pytorch, 등)
3. 문제 정의 (classification, regression, 등)
4. 풀이 방법 설계
5. 데이터 분석, 전처리 (data-EDA, preprocessing)
6. Coding
7. 결과 분석 (hyper parameter tuning 등)
8. 성능 향상을 위한 추가적인 작업들

# How to start learning Deep Learning?

Dataset

- MNIST
- Fashion-MNIST
- CelebA
- LSUN
- Kaggle
- Dacon
- +Custom data..

Tools & Frameworks



Models

- Classification
- Regression
- Generative
- Reinforcement
- NLP

# 딥러닝 프레임워크

 TensorFlow    vs     PyTorch

# How to start learning Deep Learning?

1. 개발환경 세팅 (pycharm, anaconda, colab, 등) → **Google Colab** [Colab Tutorial](#)
2. Framework 선택 (tensorflow, pytorch, 등) → **Tensorflow (Keras)** [TF공식 투토리얼](#)
3. 문제 정의 (classification, regression, 등) → 분석하려는 데이터에 따라 결정
4. 풀이 방법 설계
5. 데이터 분석, 전처리 (data-EDA, preprocessing)
6. Coding → **Coding (python)**
7. 결과 분석 (hyper parameter tuning 등)
8. 성능 향상을 위한 추가적인 작업들 → 데이터셋 정제, 네트워크 고도화 등

필요에 따라 다른 방향으로 분석하는 것도 당연히 가능하다!

# Deep Learning, Neural Network

Google search results for "deep learning":

Search terms: python, artificial intelligence, convolutional neural, computer vision, recurrent neural, tensorflow

Results:

- Machine Learning vs Deep Learning (semengineering.com)
- What is the Difference Between Machine Learning and Deep Learning (blog.bismart.com)
- Deep Learning: How Will It Change Health (orbograph.com)
- Simple Neural Network vs Deep Learning Neural Network (pinterest.com)
- Machine Learning vs Deep Learning (lawtomatic.com)
- A.I. technical - Machine Learning vs. Deep Learning (towardsdatascience.com)
- What is Deep Learning? (ko.wikipedia.org)
- Machine Learning vs Deep Learning (cri... (critiques.com)
- Machine learning is everywhere: Is there a role ... (seattleteachnologyhub.com)
- Deep Learning이란 무엇인가? Back... (open-mmlab.github.io)
- Information about neural networks (medium.com)

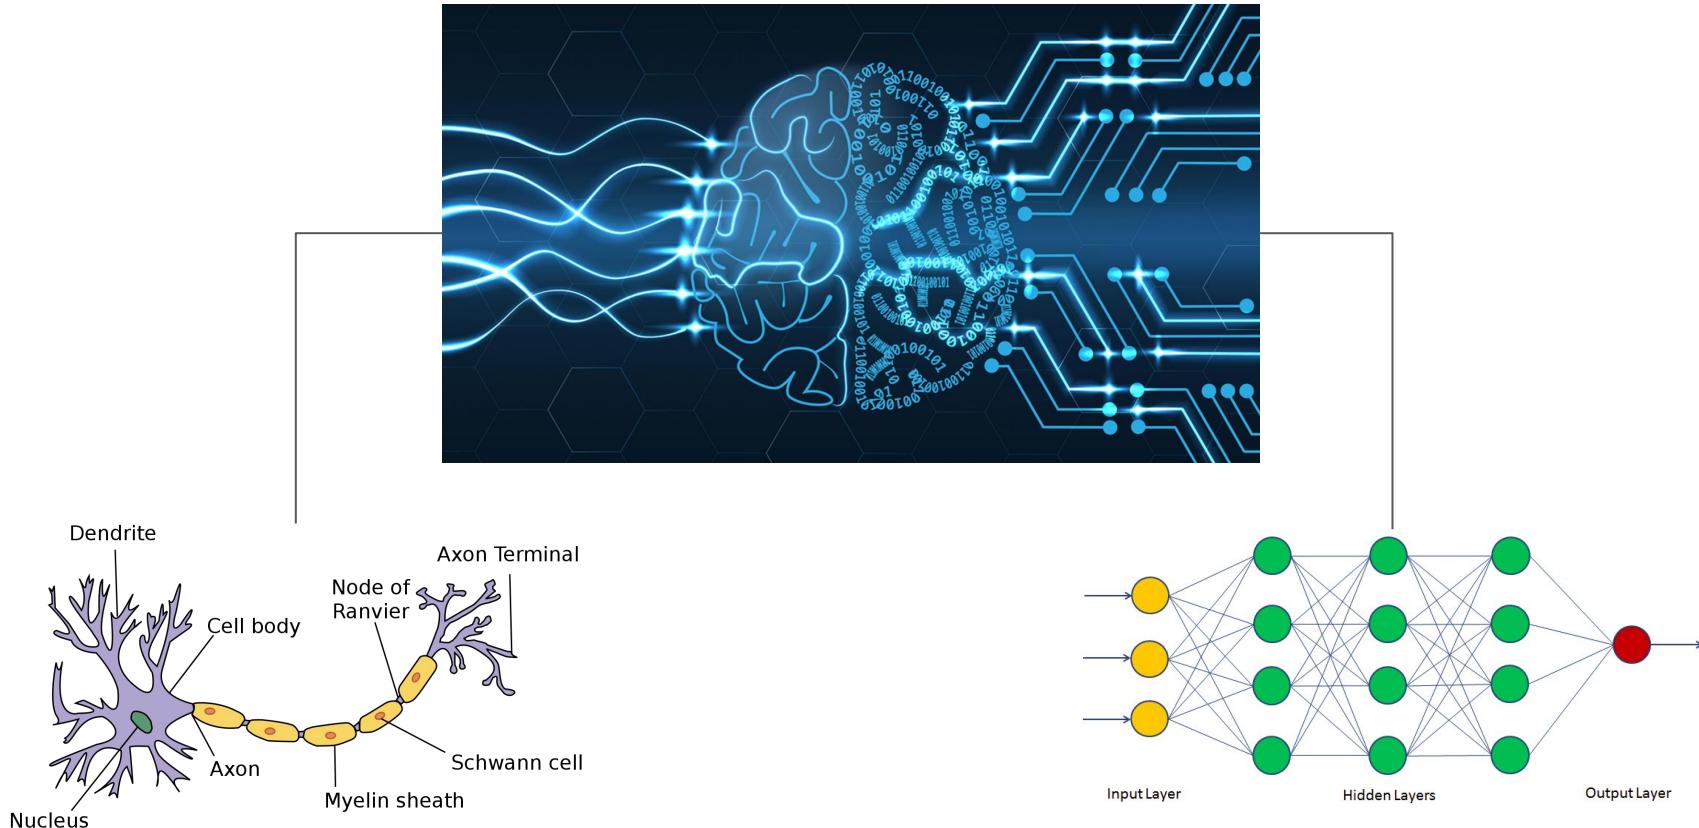
Google search results for "neural network":

Search terms: 인공신경망, convolutional, recurrent neural, convolutional neural, deep neural, deep learning

Results:

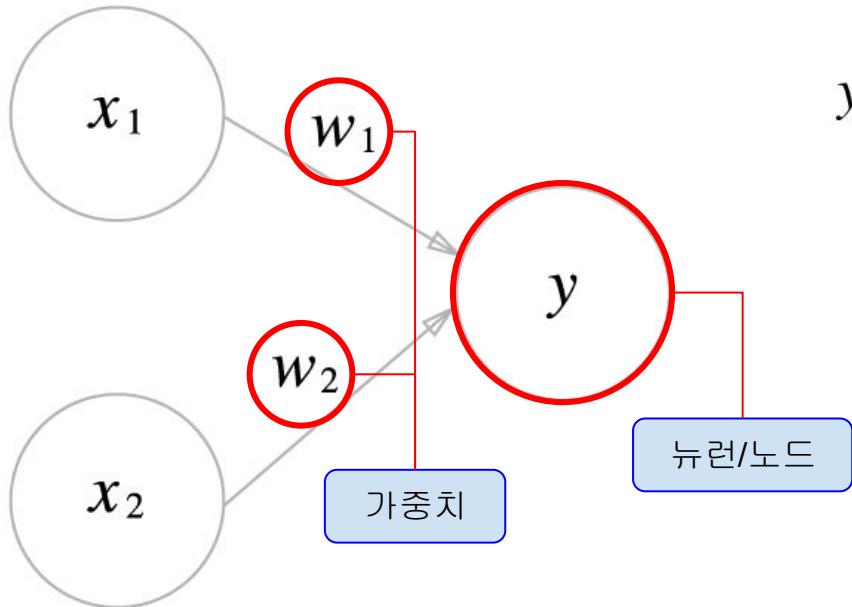
- A Simple Neural Network (investopedia.com)
- A simple neural network (en.wikipedia.org)
- Neural Network Definition (ko.wikipedia.org)
- Machine learning fundamentals (II): Neural networks (towardsdatascience.com)
- Predicting the accuracy of a neural network (phys.org)
- 인공 신경망 - 위키백과, 우리 모... (ko.wikipedia.org)
- Artificial Neural Network (groupfuturista.com)
- LAYERS IN ARTIFICIAL NEURAL NETWORK (medium.com)
- Artificial Neural Network Intuition - YouTube (YouTube)
- Recurrent Neural Network (medium.com)

# Deep Learning, Neural Network



# Perceptron (퍼셉트론)

입력이 2개인 퍼셉트론



수식으로 나타내면..

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

임계값

입력신호가 **뉴런(노드)**에 보내질 때 고유한 **가중치**가 곱해짐.  
뉴런에서 보내온 신호의 총 합이 **임계값**을 넘을 때만 1을 출력(**활성화**)함

# 단순한 논리 회로

- AND
- NAND (Not AND)
- OR

# 단순한 논리 회로

AND GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	0
0	1	0
1	1	1

NAND GATE

$x_1$	$x_2$	$y$
0	0	1
1	0	1
0	1	1
1	1	0

OR GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	1
0	1	1
1	1	1

퍼셉트론이 위의 **논리표**대로 작동하게 하려면 어떻게 해야 할까?

- $x_1, x_2$  입력에 대한 가중치  $w_1, w_2$  와 임계값  $\theta$ 를 결정
- $w_1, w_2, \theta$  는 여러가지 조합이 존재할 수 있음

# 단순한 논리 회로

AND GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	0
0	1	0
1	1	1

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

$$(w_1, w_2, \theta) = (0.5, 0.5, 0.7)$$

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

↓

$$y = \begin{cases} 0 & (0.5x_1 + 0.5x_2 \leq 0.7) \\ 1 & (0.5x_1 + 0.5x_2 > 0.7) \end{cases}$$

# 단순한 논리 회로

AND GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	0
0	1	0
1	1	1

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

$$(w_1, w_2, \theta) = (0.5, 0.5, 0.7)$$

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

↓

$$y = \begin{cases} 0 & (0.5x_1 + 0.5x_2 \leq 0.7) \\ 1 & (0.5x_1 + 0.5x_2 > 0.7) \end{cases}$$

$x_1$	$x_2$	$y$	$\theta = 0.7$
0	0	$0.5 \times 0 + 0.5 \times 0 = 0$	0
1	0	$0.5 \times 1 + 0.5 \times 0 = 0.5$	0
0	1	$0.5 \times 0 + 0.5 \times 1 = 0.5$	0
1	1	$0.5 \times 1 + 0.5 \times 1 = 1$	1

# 단순한 논리 회로

AND GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	0
0	1	0
1	1	1

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

$$(w_1, w_2, \theta) = (0.5, 0.5, 0.7)$$

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases}$$

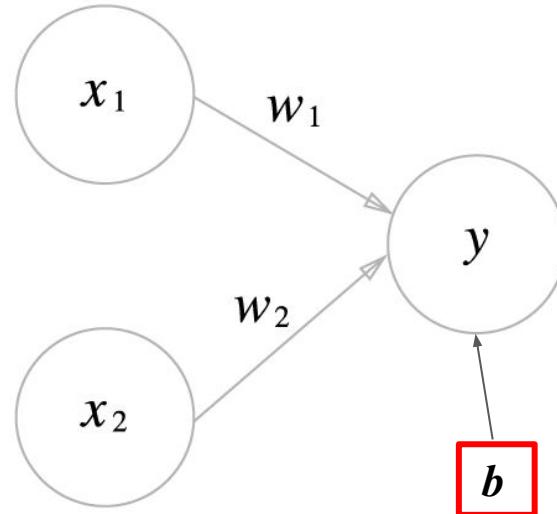
↓

$$y = \begin{cases} 0 & (0.5x_1 + 0.5x_2 \leq 0.7) \\ 1 & (0.5x_1 + 0.5x_2 > 0.7) \end{cases}$$

$x_1$	$x_2$	$y$	$\theta = 0.7$
0	0	$0.5 \times 0 + 0.5 \times 0 = 0$	0
1	0	$0.5 \times 1 + 0.5 \times 0 = 0.5$	0
0	1	$0.5 \times 0 + 0.5 \times 1 = 0.5$	0
1	1	$0.5 \times 1 + 0.5 \times 1 = 1$	1

# 가중치와 편향

$$y = \begin{cases} 0 & (w_1x_1 + w_2x_2 \leq \theta) \\ 1 & (w_1x_1 + w_2x_2 > \theta) \end{cases} \quad \rightarrow \quad y = \begin{cases} 0 & (b + w_1x_1 + w_2x_2 \leq 0) \\ 1 & (b + w_1x_1 + w_2x_2 > 0) \end{cases}$$



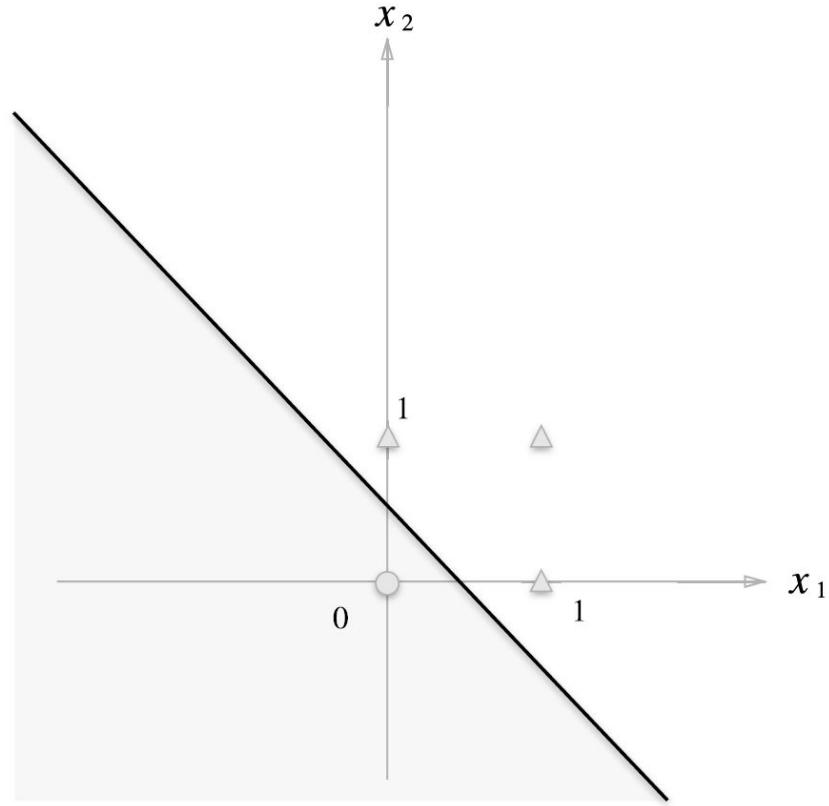
# 퍼셉트론의 시각화

$$y = \begin{cases} 0 & (-0.5 + x_1 + x_2 \leq 0) \\ 1 & (-0.5 + x_1 + x_2 > 0) \end{cases}$$

OR 게이트

$x_1$	$x_2$	$y$
0	0	0
1	0	1
0	1	1
1	1	1

회색 영역은 0을 출력하는 영역,  
전체 영역은 OR 게이트의 성질을 만족함



# 퍼셉트론 구현하기

앞에서 학습한 간단한 논리 회로를 python 코드로 학습

- AND
- NAND
- OR

[Colab에서 확인하기](#)

# 퍼셉트론 구현하기

앞에서 학습한 간단한 논리 회로를 python 코드로 학습

```
1 def AND(x1, x2):
2     x = np.array([x1, x2])
3     w = np.array([0.5, 0.5])
4     b = -0.7
5     tmp = np.sum(w*x) + b
6     if tmp <= 0:
7         return 0
8     else:
9         return 1
```

```
1 def NAND(x1, x2):
2     x = np.array([x1, x2])
3     w = np.array([-0.5, -0.5])
4     b = 0.7
5     tmp = np.sum(w*x) + b
6     if tmp <= 0:
7         return 0
8     else:
9         return 1
```

```
1 def OR(x1, x2):
2     x = np.array([x1, x2])
3     w = np.array([0.5, 0.5])
4     b = -0.2
5     tmp = np.sum(w*x) + b
6     if tmp <= 0:
7         return 0
8     else:
9         return 1
```

구조는 모두 같고 가중치나 편향이 다른 것을 확인할 수 있음

# 퍼셉트론의 한계

## XOR GATE

$x_1$	$x_2$	$y$
0	0	0
1	0	1
0	1	1
1	1	0

$$(w1, w2, \theta) = ( ?, ?, ?, ? )$$

가중치와 임계값(혹은 편향)이 어떤 값을 가져야  
XOR 게이트의 진리표를 충족시킬 수 있을까?

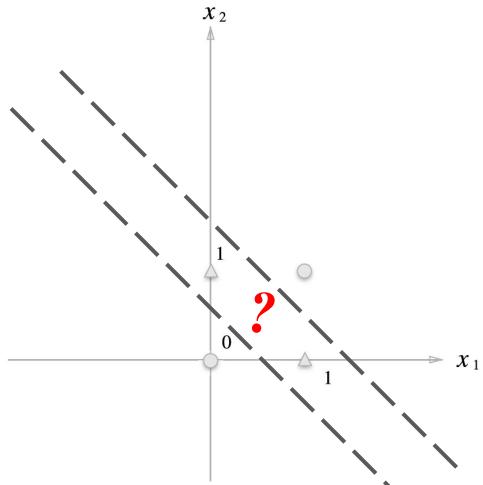
(퍼셉트론으로 XOR 게이트를 구현하려면 어떻게 해야 할까?)

# 퍼셉트론의 한계

XOR GATE

퍼셉트론으로 XOR 게이트를 구현하려면 어떻게 해야 할까?

$x_1$	$x_2$	$y$
0	0	0
1	0	1
0	1	1
1	1	0

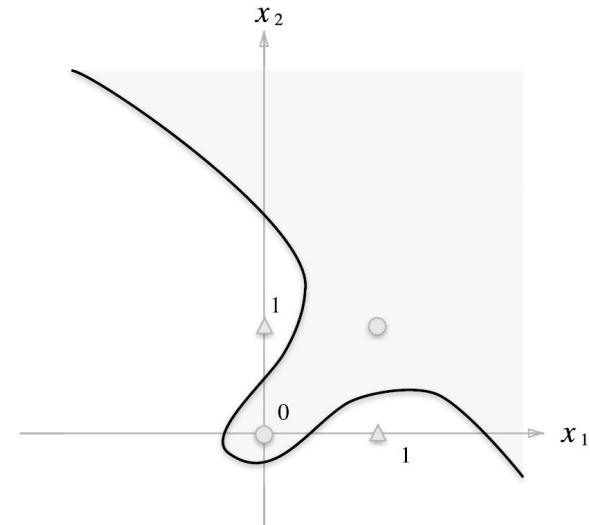
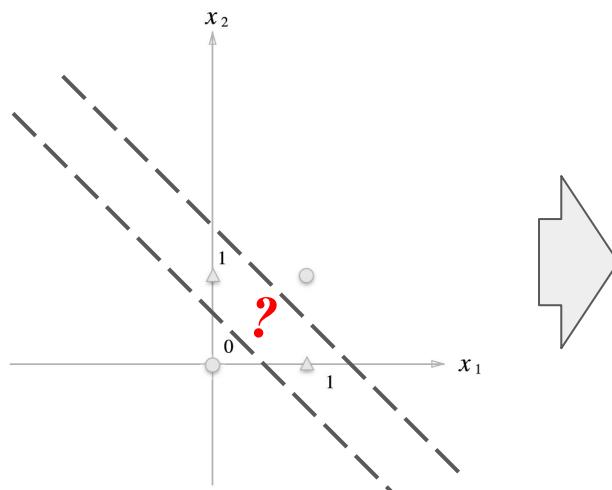


# 퍼셉트론의 한계

## XOR GATE

퍼셉트론으로 XOR 게이트를 구현하려면 어떻게 해야 할까?

$x_1$	$x_2$	$y$
0	0	0
1	0	1
0	1	1
1	1	0



퍼셉트론은 직선 하나로 나눈 영역만 표현할 수 있다는 한계가 있음

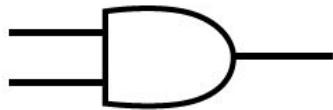
→ **비선형** 영역의 필요성

# 다중 퍼셉트론

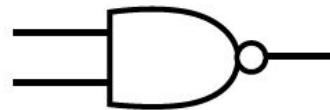
- 기존 게이트 조합하기
- XOR 게이트 구현하기

# 다중 퍼셉트론

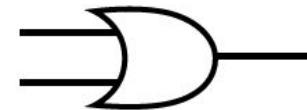
게이트 기호



AND



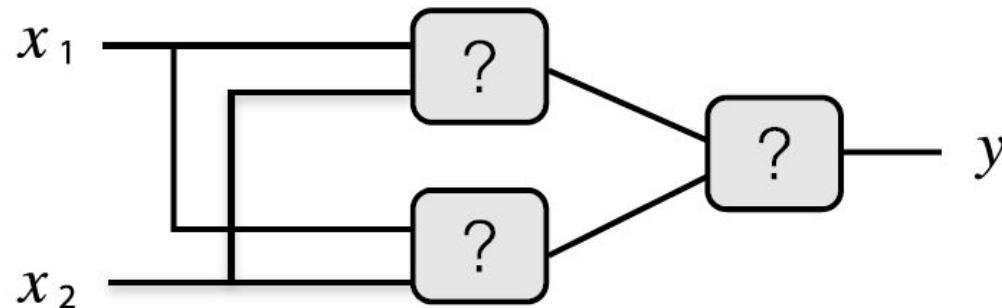
NAND



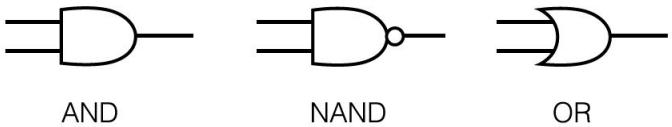
OR

퍼셉트론 여러개를 조합하여 XOR 게이트를 구현할 수 있음

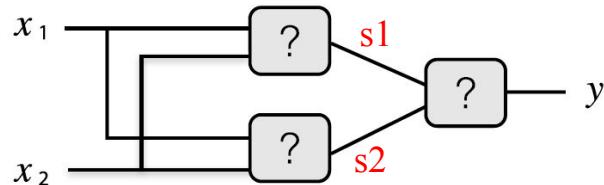
(게이트의 output들이 다른 게이트의 input으로 사용될 수 있음)



# 다중 퍼셉트론

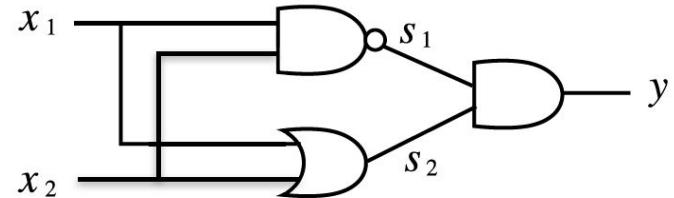


퍼셉트론 여러개를 조합하여 XOR 게이트를 구현할 수 있음



$x_1$	$x_2$	$s_1$	$s_2$	$y$
0	0	0	0	0
1	0	1	0	1
0	1	0	1	1
1	1	1	1	0

기이트의 output

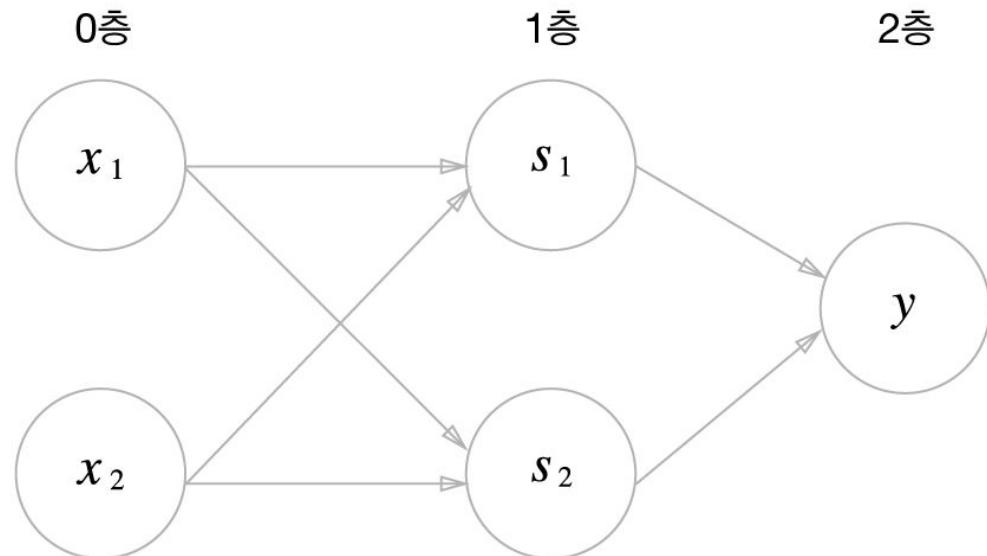


$x_1$	$x_2$	$s_1$	$s_2$	$y$
0	0	1	0	0
1	0	1	1	1
0	1	1	1	1
1	1	0	1	0

[Colab에서 확인하기](#)

# 다중 퍼셉트론

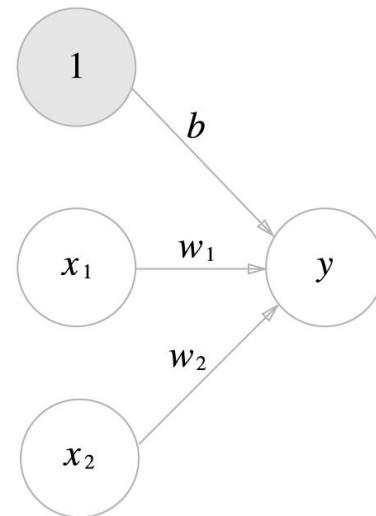
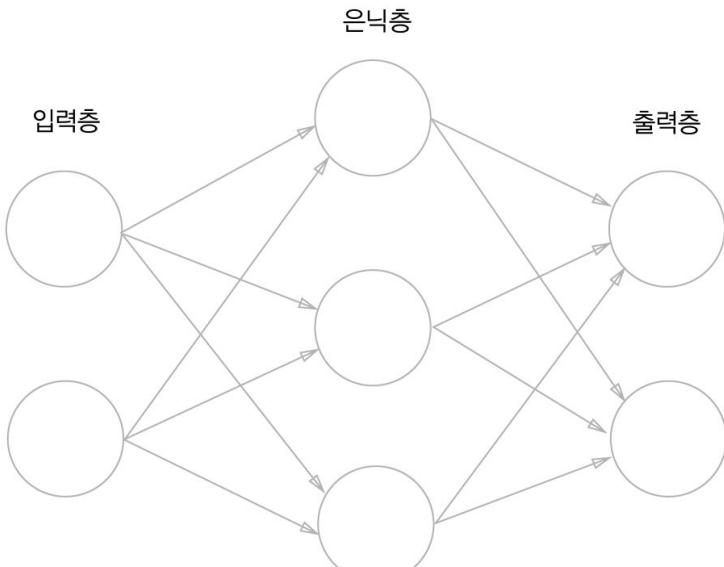
XOR 게이트를 퍼셉트론으로 표현하면 다음과 같음



# 퍼셉트론 요약

- 퍼셉트론은 입출력을 갖춘 알고리즘이다. 입력을 주면 정해진 규칙에 따른 값을 출력한다.
- 퍼셉트론에서는 ‘**가중치**’와 ‘**편향**’을 매개변수로 설정한다.
- 퍼셉트론으로 AND, OR 게이트 등의 **논리 회로를 표현할 수 있다.**
- **XOR 게이트**는 단층 퍼셉트론으로는 표현할 수 없다.
- 2층 퍼셉트론을 이용하면 **XOR 게이트를 표현할 수 있다.**
- 단층 퍼셉트론은 직선형 영역만, 다층 퍼셉트론은 비선형 영역도 표현할 수 있다.

# 퍼셉트론에서 신경망으로

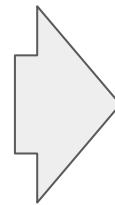


# 활성화 함수 (Activation Function)

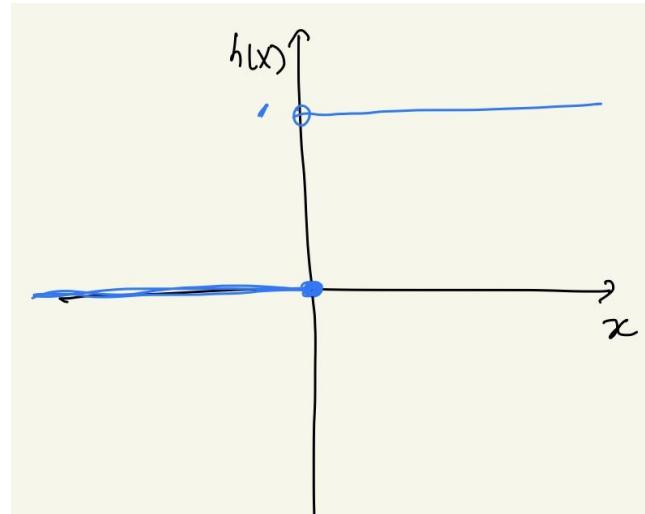
$$y = \begin{cases} 0 & (b + w_1x_1 + w_2x_2 \leq 0) \\ 1 & (b + w_1x_1 + w_2x_2 > 0) \end{cases}$$

# 활성화 함수 (Activation Function)

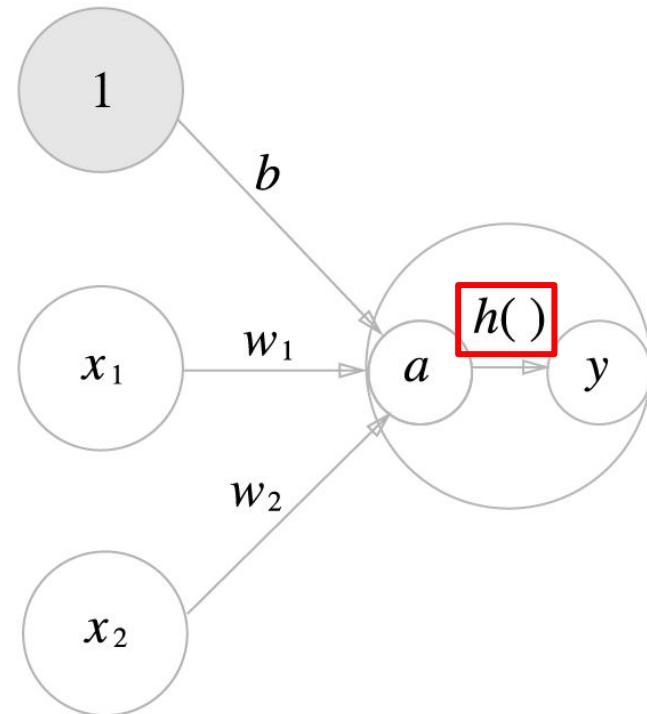
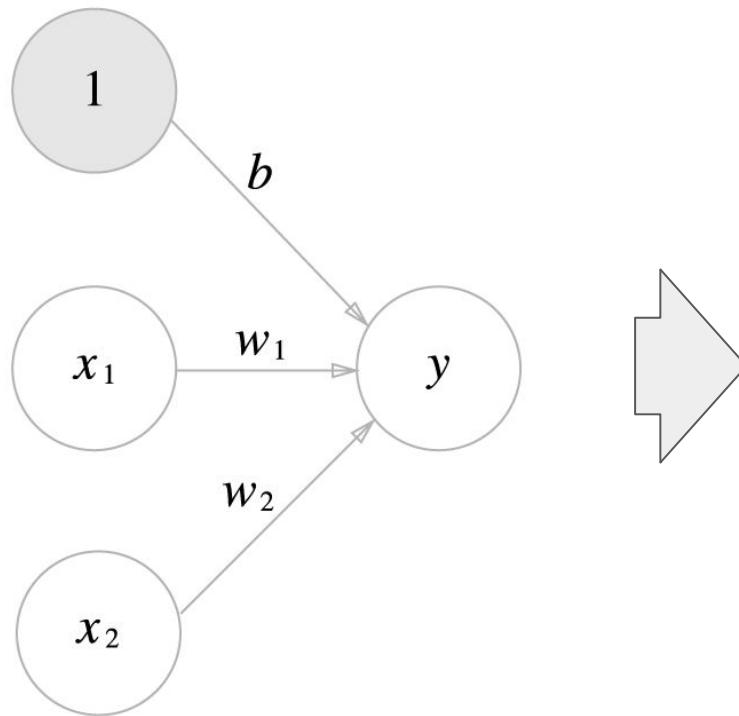
$$y = \begin{cases} 0 & (b + w_1x_1 + w_2x_2) \leq 0 \\ 1 & (b + w_1x_1 + w_2x_2) > 0 \end{cases}$$



$$y = h(b + w_1x_1 + w_2x_2)$$
$$h(x) = \begin{cases} 0 & (x \leq 0) \\ 1 & (x > 0) \end{cases}$$



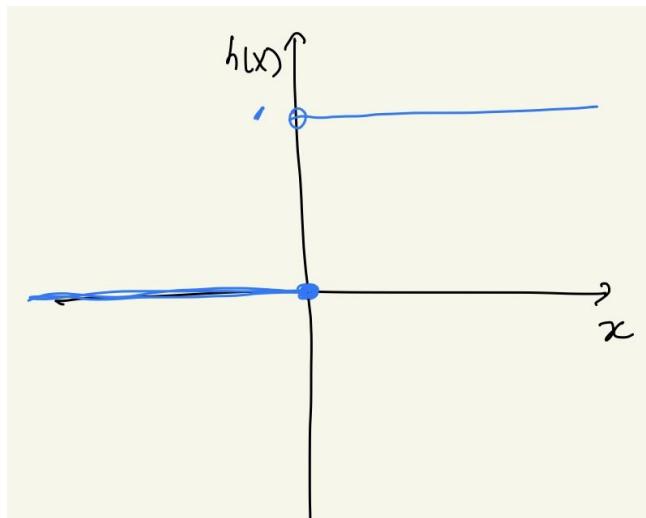
# 활성화 함수 (Activation Function)



# 활성화 함수 (Activation Function)

$$h(x) = \begin{cases} 0 & (x \leq 0) \\ 1 & (x > 0) \end{cases}$$

```
def step_function(x):
    if x > 0:
        return 1
    else:
        return 0
```



임계값을 경계로 출력이 바뀌는  
함수를 계단 함수 (step function)  
이라고 함

```
1 def step_function(x):
2     y = x > 0
3     return y.astype(np.int)
```

```
1 import numpy as np
```

```
1 x = np.array([-1.0, 1.0, 2.0])
```

```
1 x
```

```
array([-1., 1., 2.])
```

```
1 y = x > 0
```

```
1 y
```

```
array([False, True, True])
```

```
1 y = y.astype(np.int)
```

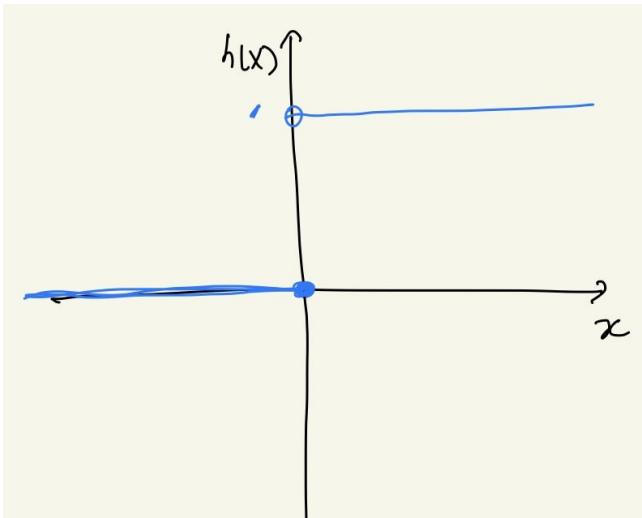
```
1 y
```

```
array([0, 1, 1])
```

# 활성화 함수 (Activation Function)

$$h(x) = \begin{cases} 0 & (x \leq 0) \\ 1 & (x > 0) \end{cases}$$

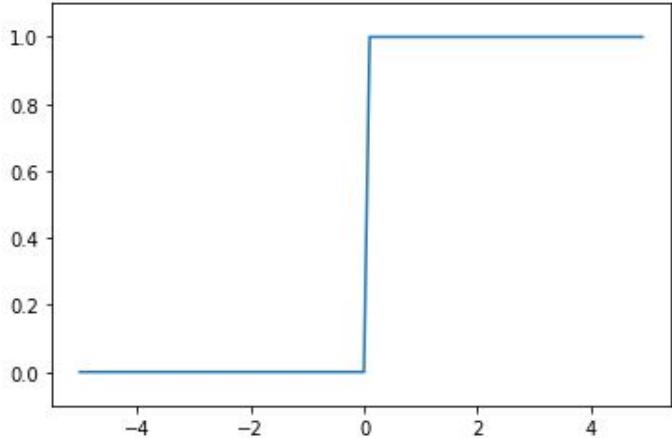
```
def step_function(x):
    if x > 0:
        return 1
    else:
        return 0
```



임계값을 경계로 출력이 바뀌는  
함수를 계단 함수 (step function)  
이라고 함

```
1 import numpy as np
2 import matplotlib.pyplot as plt

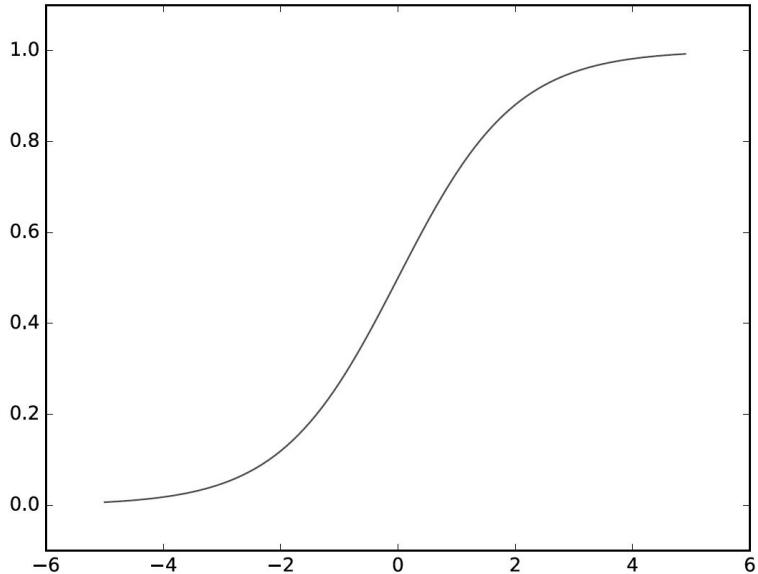
1 x = np.arange(-5.0, 5.0, 0.1)
2 y = step_function(x)
3 plt.plot(x,y)
4 plt.ylim(-0.1, 1.1)
5 plt.show()
```



# 활성화 함수 (Activation Function)

시그모이드 함수  
(Sigmoid function)

$$h(x) = \frac{1}{1 + \exp(-x)}$$

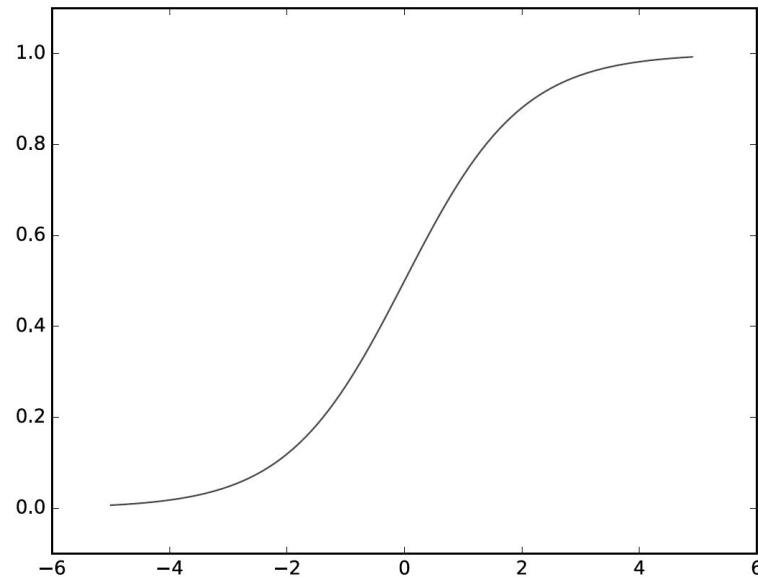


# 활성화 함수 (Activation Function)

시그모이드 함수  
(Sigmoid function)

$$h(x) = \frac{1}{1 + \exp(-x)}$$

```
def sigmoid(x):  
    return 1 / (1 + np.exp(-x))
```

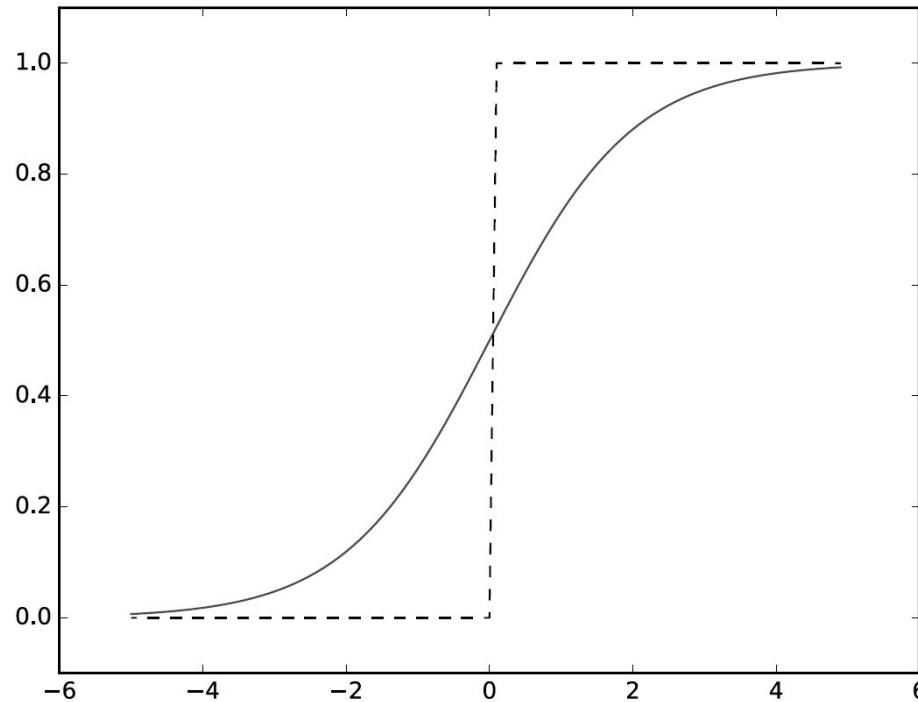


```
1 x = np.array([-1.0, 1.0, 2.0])  
2 y = sigmoid(x)  
3 print(y)
```

```
[0.26894142 0.73105858 0.88079708]
```

# 활성화 함수 (Activation Function)

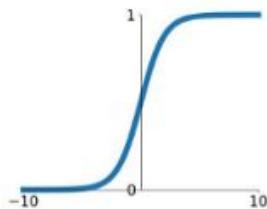
시그모이드 함수 (Sigmoid function) & 계단 함수 (Step function)



# 활성화 함수 (Activation Function)

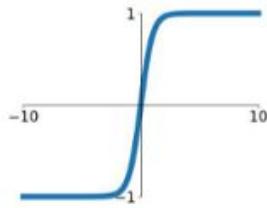
## Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



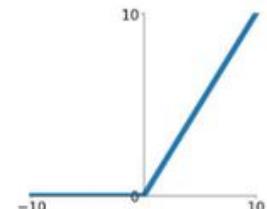
## tanh

$$\tanh(x)$$



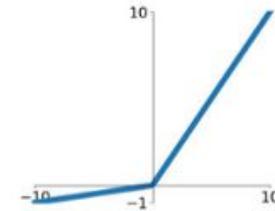
## ReLU

$$\max(0, x)$$



## Leaky ReLU

$$\max(0.1x, x)$$



## Maxout

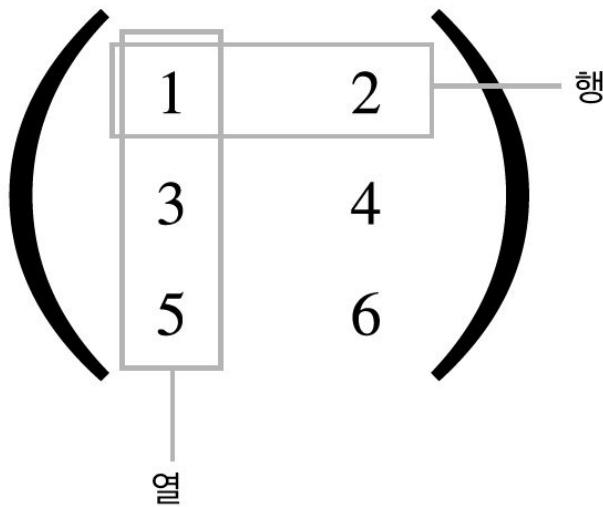
$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

## ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



# 다차원 배열의 계산



2차원 배열의 행과 열

```
1 import numpy as np  
2 A = np.array([1,2,3,4])  
3 print(A)
```

```
[1 2 3 4]
```

```
1 B = np.array([[1,2], [3,4], [5,6]])
```

```
1 print(B)
```

```
[[1 2]  
 [3 4]  
 [5 6]]
```

# 다차원 배열의 계산

행렬의 내적 계산 방법

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$$

$1 \times 5 + 2 \times 7$

$3 \times 5 + 4 \times 7$

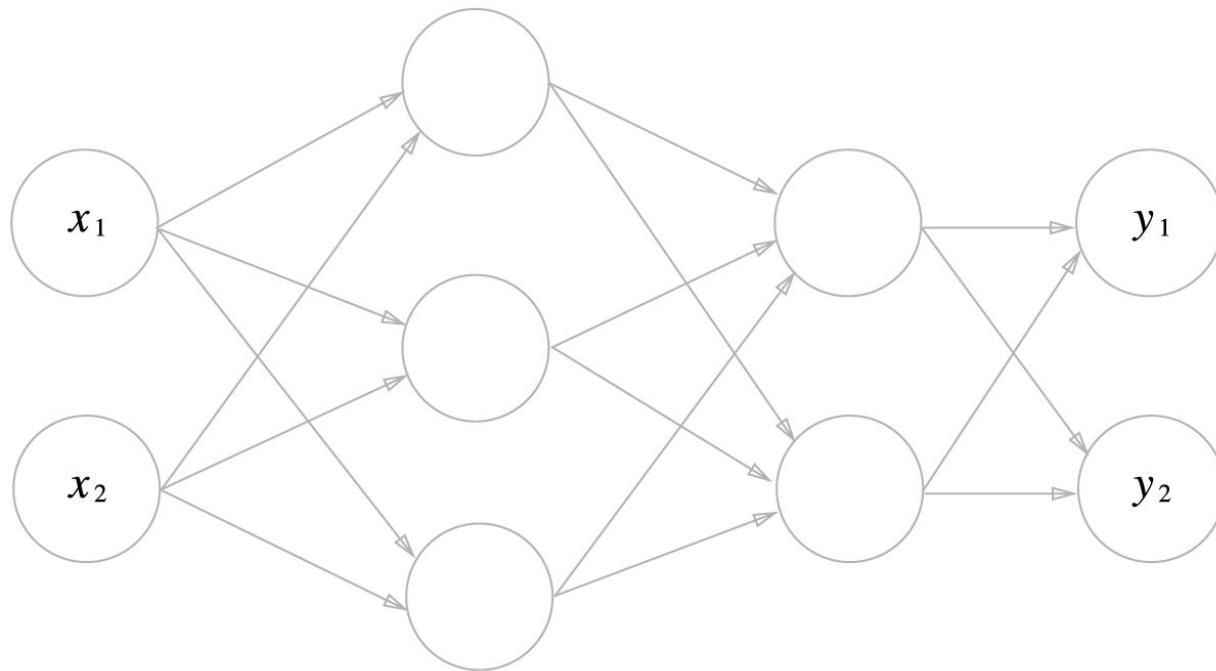
A                      B

```
1 A = np.array([[1,2], [3,4]])  
2 B = np.array([[5,6], [7,8]])
```

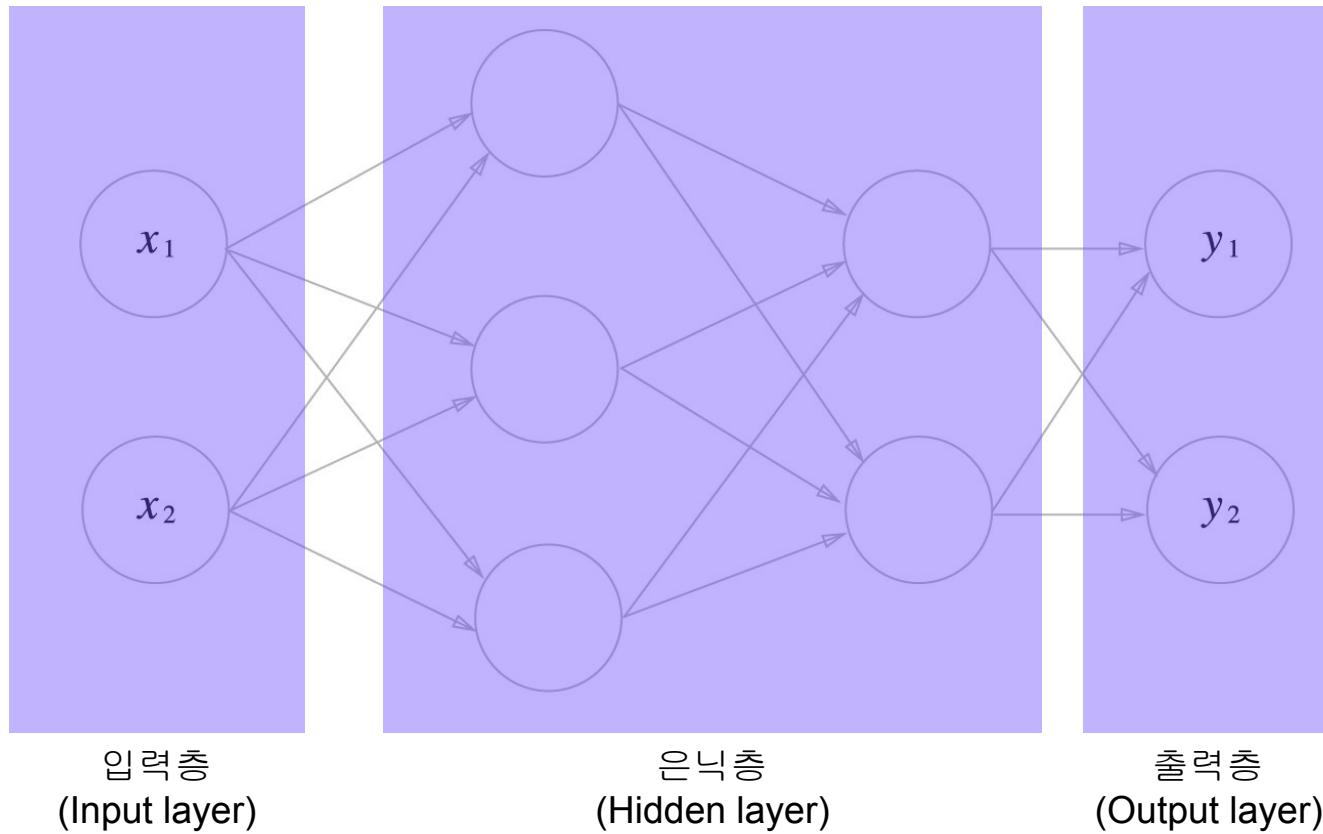
```
1 np.dot(A, B)
```

```
array([[19, 22],  
       [43, 50]])
```

# 신경망 구현하기



# 신경망 구현하기

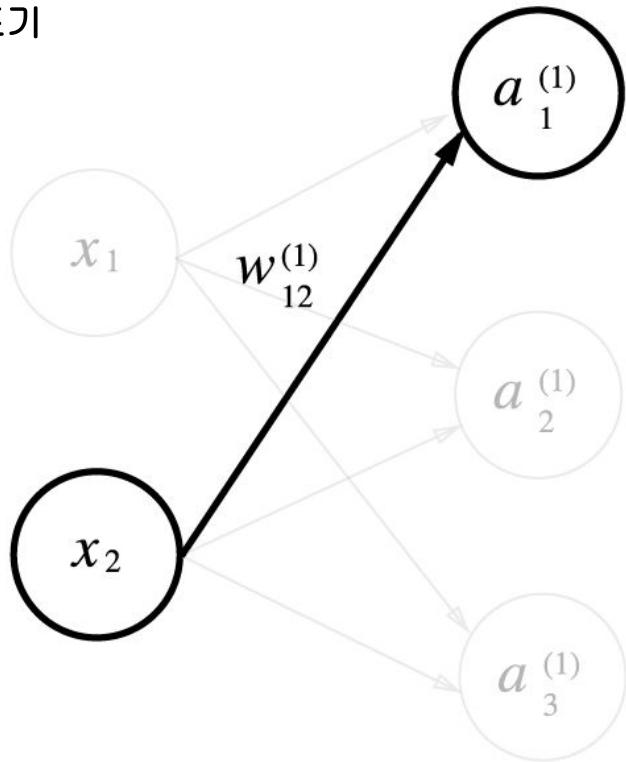


# 지금까지 학습한 내용

- 퍼셉트론
- 활성화 함수
- 다차원 배열의 계산

# 신경망 구현하기

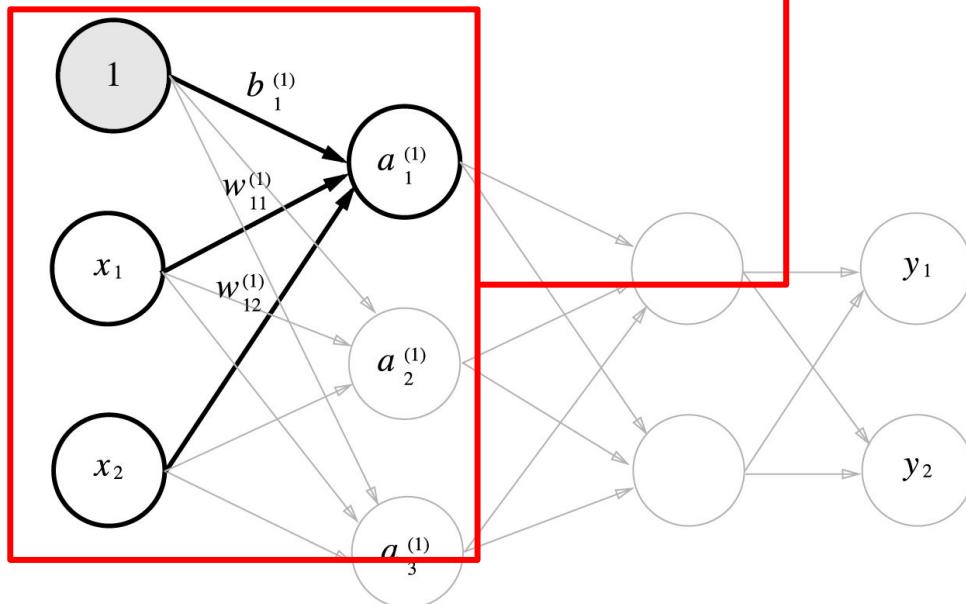
중요한 표기



$w$  1 층의 가중치  
 $\begin{matrix} & (1) \\ 1 & 2 \end{matrix}$   
앞 층의 2번째 뉴런  
다음 층의 1번째 뉴런

# 신경망 구현하기

신호 전달 구현하기



$$a_1^{(1)} = w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)}$$

$$\mathbf{A}^{(1)} = \mathbf{X}\mathbf{W}^{(1)} + \mathbf{B}^{(1)}$$

$$\mathbf{A}^{(1)} = (a_1^{(1)}, a_2^{(1)}, a_3^{(1)})$$

$$\mathbf{X} = (x_1, x_2)$$

$$\mathbf{B}^{(1)} = (b_1^{(1)}, b_2^{(1)}, b_3^{(1)})$$

$$\mathbf{W}^{(1)} = \begin{pmatrix} w_{11}^{(1)} & w_{21}^{(1)} & w_{31}^{(1)} \\ w_{12}^{(1)} & w_{22}^{(1)} & w_{32}^{(1)} \end{pmatrix}$$

# 신경망 구현하기

## 신호 전달 구현하기

$$a_1^{(1)} = w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)}$$

$$\mathbf{A}^{(1)} = \mathbf{X}\mathbf{W}^{(1)} + \mathbf{B}^{(1)}$$

$$\mathbf{A}^{(1)} = (a_1^{(1)}, a_2^{(1)}, a_3^{(1)})$$

$$\mathbf{X} = (x_1, x_2)$$

$$\mathbf{B}^{(1)} = (b_1^{(1)}, b_2^{(1)}, b_3^{(1)})$$

$$\mathbf{W}^{(1)} = \begin{pmatrix} w_{11}^{(1)} & w_{21}^{(1)} & w_{31}^{(1)} \\ w_{12}^{(1)} & w_{22}^{(1)} & w_{32}^{(1)} \end{pmatrix}$$

```
1 import numpy as np
2
3 X = np.array([1.0, 0.5])
4 W1 = np.array([[0.1, 0.3, 0.5],
5                 [0.2, 0.4, 0.6]])
6 B1 = np.array([0.1, 0.2, 0.3])
7
8 print(W1.shape)
9 print(X.shape)
10 print(B1.shape)
11
12 A1 = np.dot(X, W1) + B1
```

(2, 3)

(2, )

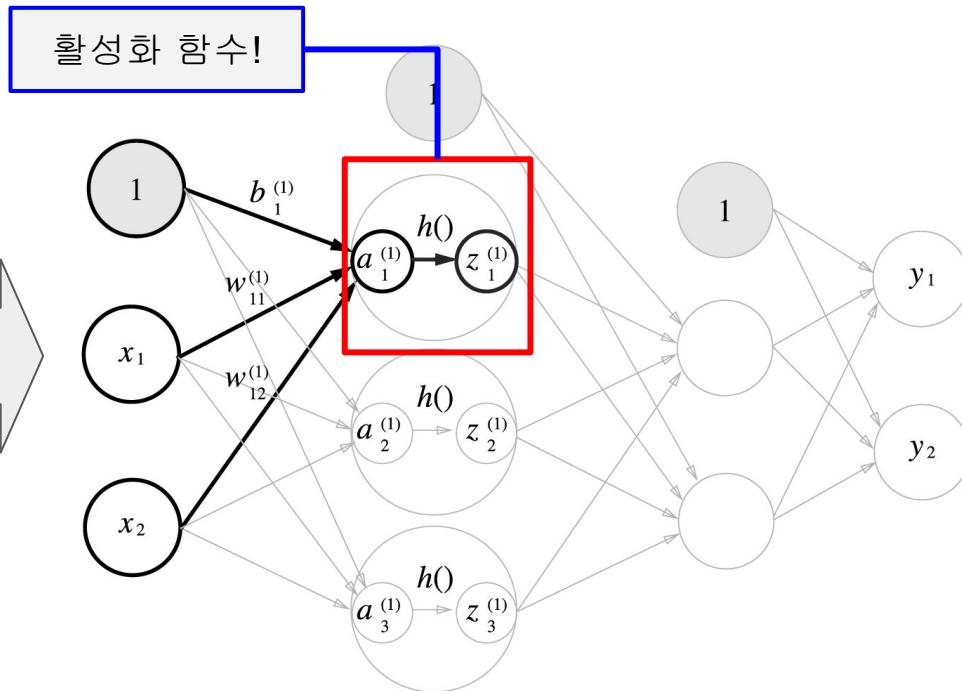
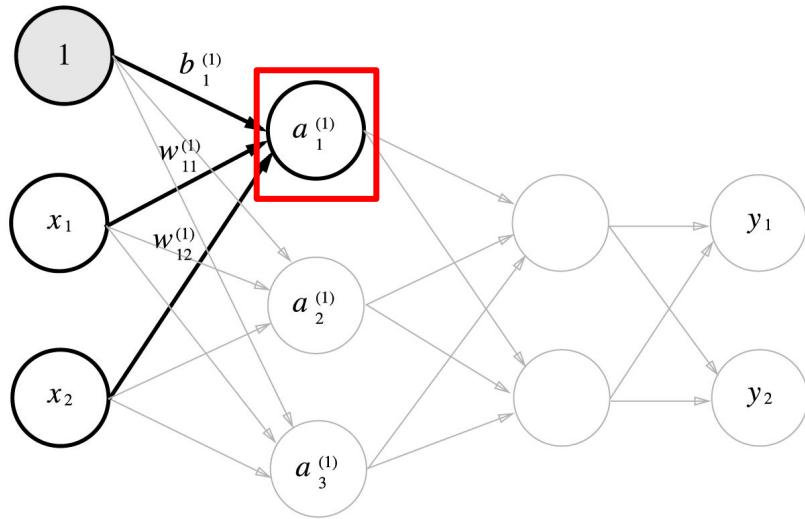
(3, )

```
1 print(A1)
```

[0.3 0.7 1.1]

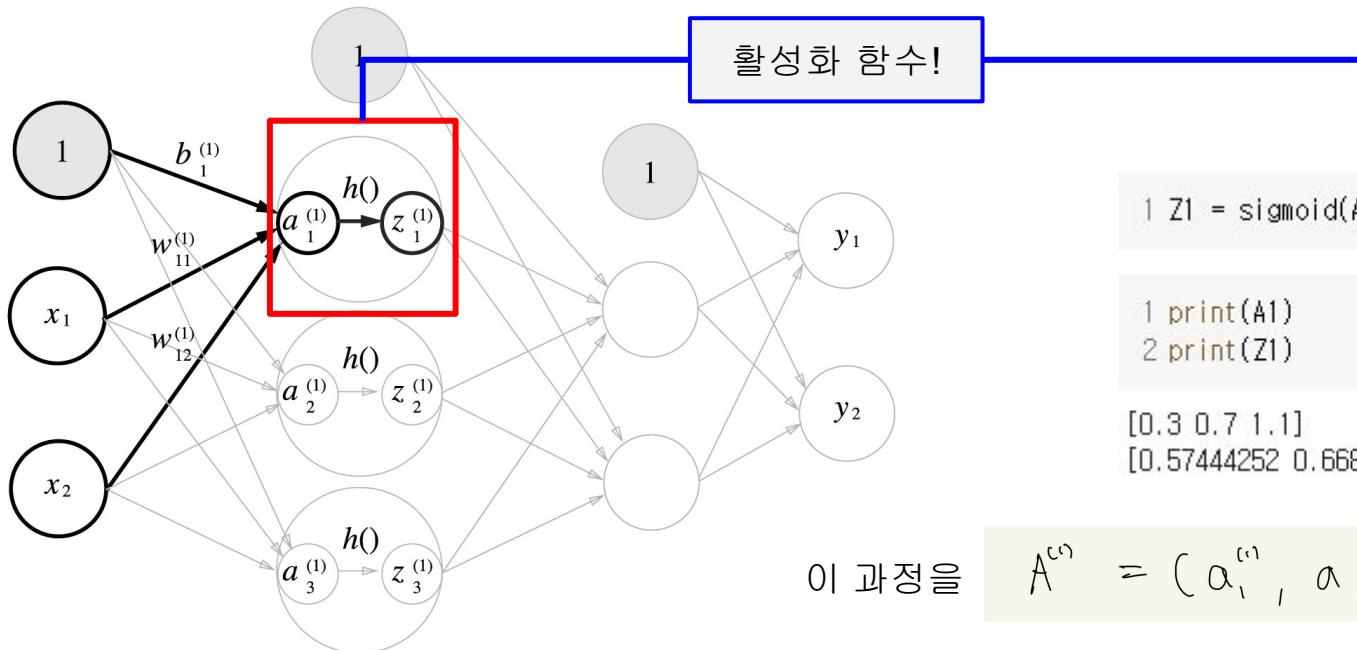
# 신경망 구현하기

## 신호 전달 구현하기



# 신경망 구현하기

## 신호 전달 구현하기



1  $Z1 = \text{sigmoid}(A1)$

1 print(A1)  
2 print(Z1)

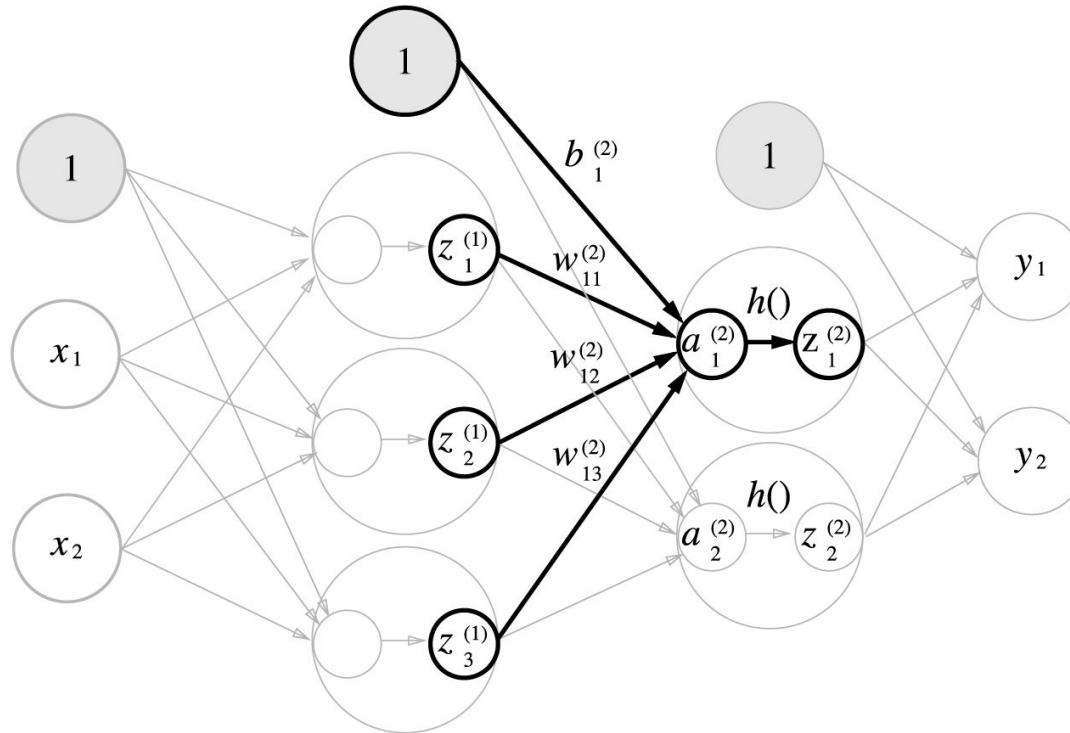
[0.3 0.7 1.1]  
[0.57444252 0.66818777 0.75026011]

이 과정을  $A^{(1)} = (a_1^{(1)}, a_2^{(1)}, a_3^{(1)})$  에 대해 모두 수행

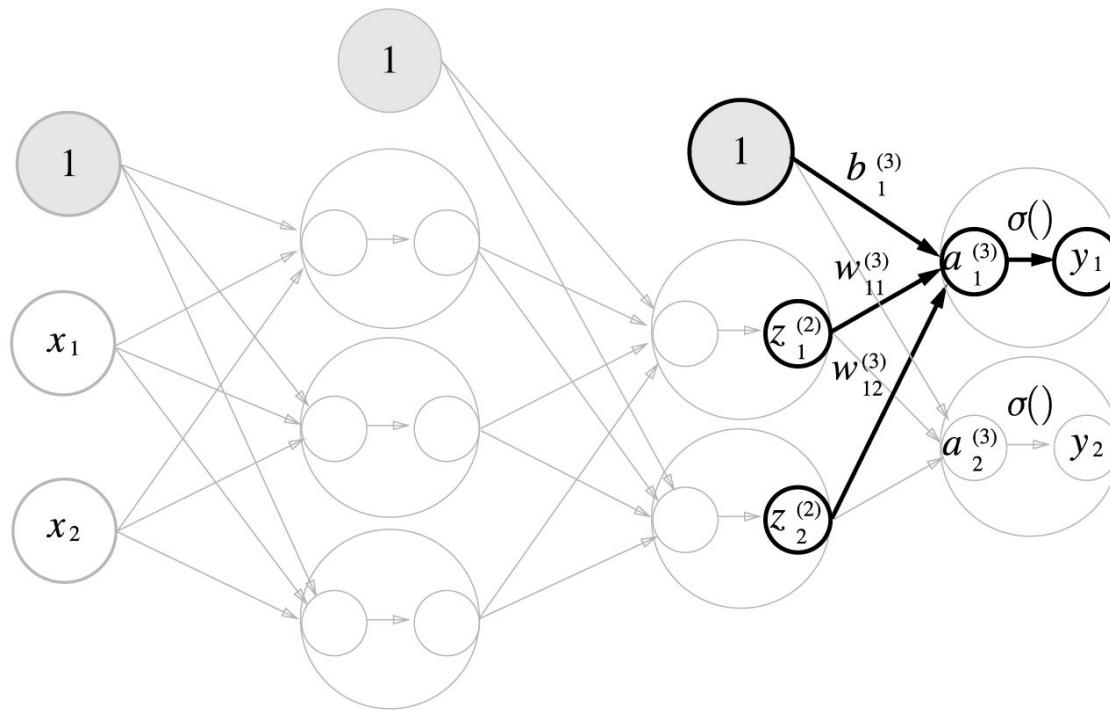
$A1$ 은 두번째 은닉층의 입력으로 전달됨

# 신경망 구현하기

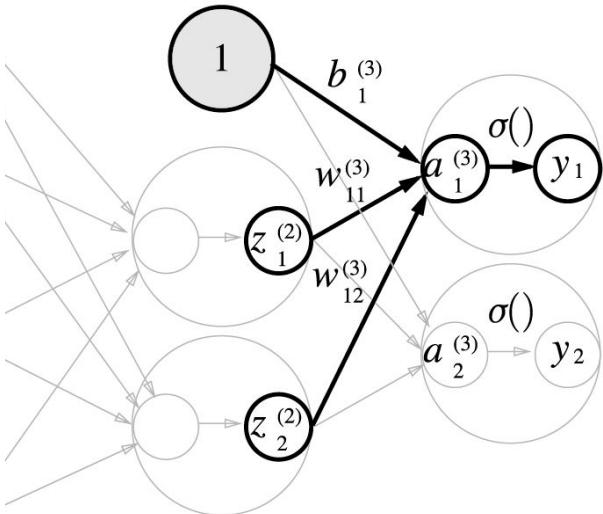
## 신호 전달 구현하기



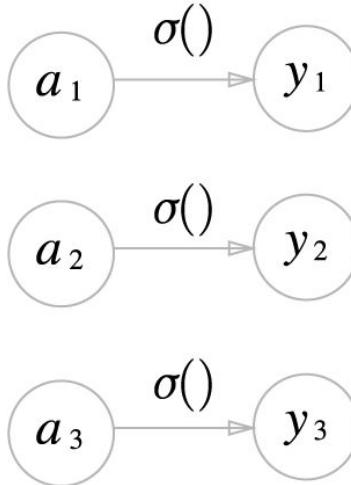
# 신경망 구현하기



# 출력층 설계하기



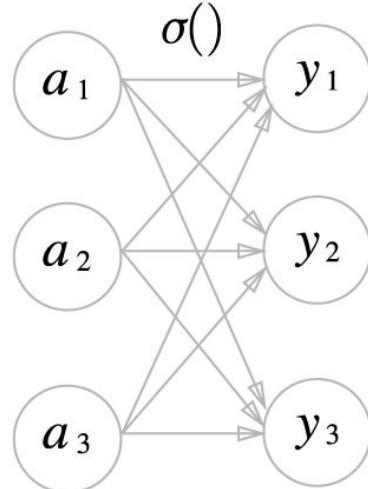
항등 함수



일반적으로  
회귀 문제에 사용

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

소프트맥스 함수

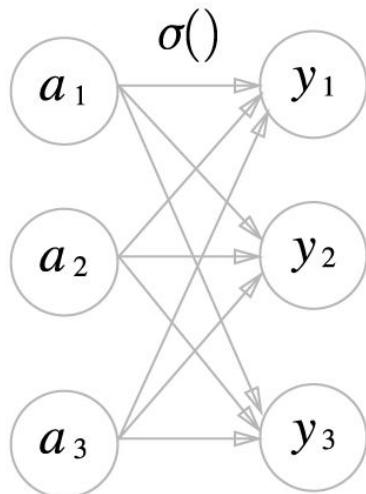


일반적으로  
분류 문제에 사용

# 출력층 설계하기

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

소프트맥스 함수



```
1 a = np.array([0.3, 2.9, 4.0])
2
3 exp_a = np.exp(a)
4 print(exp_a)

[ 1.34985881 18.17414537 54.59815003]

1 sum_exp_a = np.sum(exp_a)
2 print(sum_exp_a)

74.1221542101633

1 y = exp_a / sum_exp_a
2 print(y)

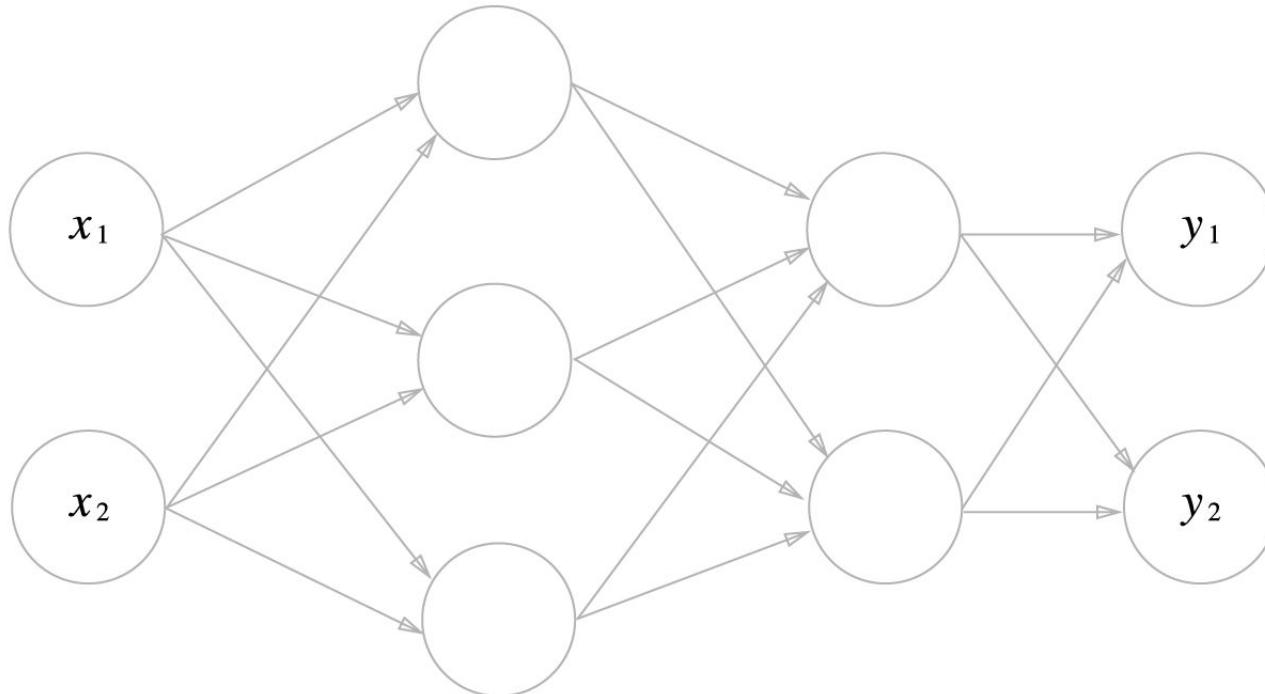
[0.01821127 0.24519181 0.73659691]
```

```
def softmax(a):
    exp_a = np.exp(a)
    sum_exp_a = np.sum(exp_a)
    y = exp_a / sum_exp_a

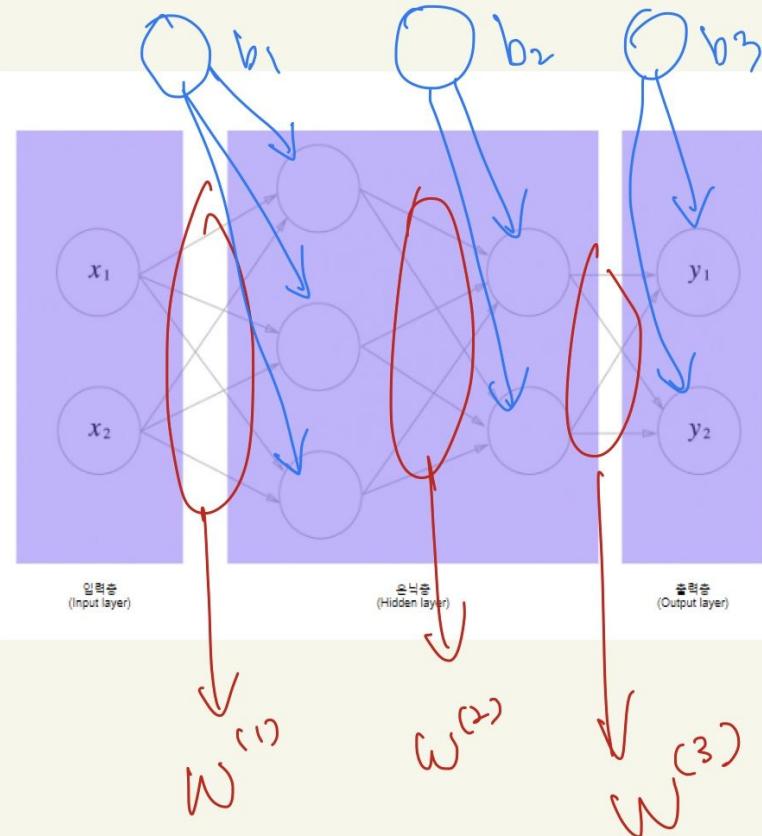
    return y
```

- 마지막 단계의 출력값을 정규화 시킴
- Softmax output의 합은 항상 1임
- Output Node의 개수는 예측하려는 Class 수

# 구현 내용 정리



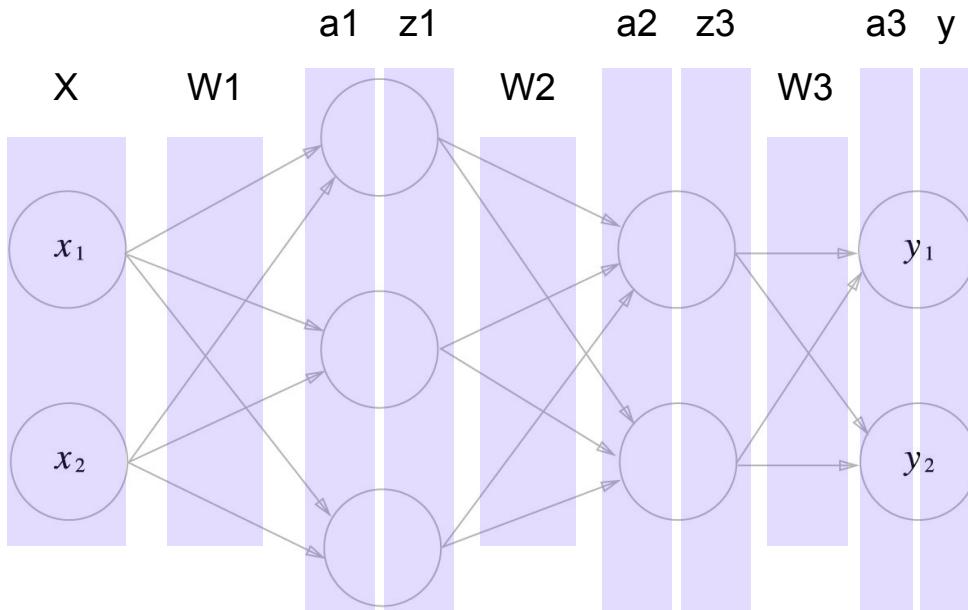
# 구현 내용 정리



```
def init_network():
    network = {}
    network['W1'] = np.array([[0.1, 0.3, 0.5], [0.2, 0.4, 0.6]])
    network['b1'] = np.array([0.1, 0.2, 0.3])
    network['W2'] = np.array([[0.1, 0.4], [0.2, 0.5], [0.3, 0.6]])
    network['b2'] = np.array([0.1, 0.2])
    network['W3'] = np.array([[0.1, 0.3], [0.2, 0.4]])
    network['b3'] = np.array([0.1, 0.2])

    return network
```

# 구현 내용 정리



```
def forward(network, x):
    W1, W2, W3 = network['W1'], network['W2'], network['W3']
    b1, b2, b3 = network['b1'], network['b2'], network['b3']

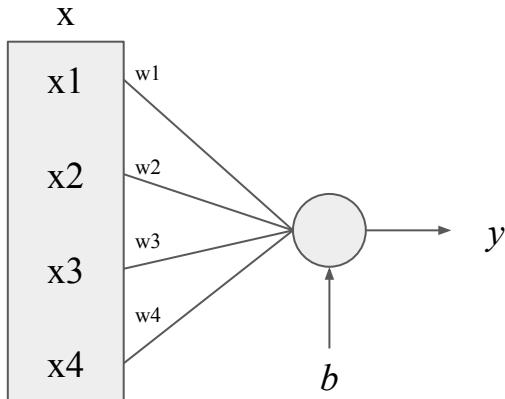
    a1 = np.dot(x, W1) + b1
    z1 = sigmoid(a1)
    a2 = np.dot(z1, W2) + b2
    z2 = sigmoid(a2)
    a3 = np.dot(z2, W3) + b3
    y = identity_function(a3)

    return y
```

# 지금까지 학습한 내용

- 신경망 신호 전달 방식 구현
- 출력층 설계

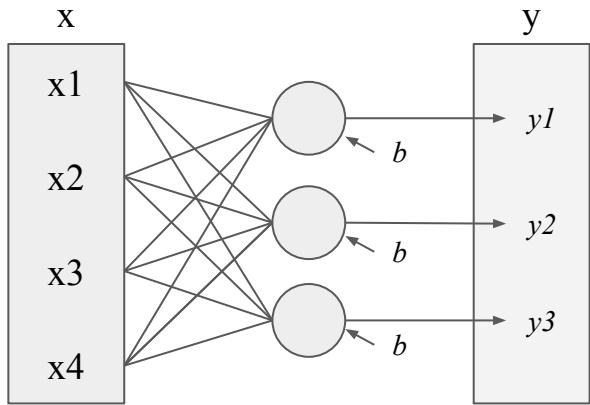
# Perceptron - single layer



가중치 벡터  
입력 벡터  
가중치 편향  
스칼라 출력

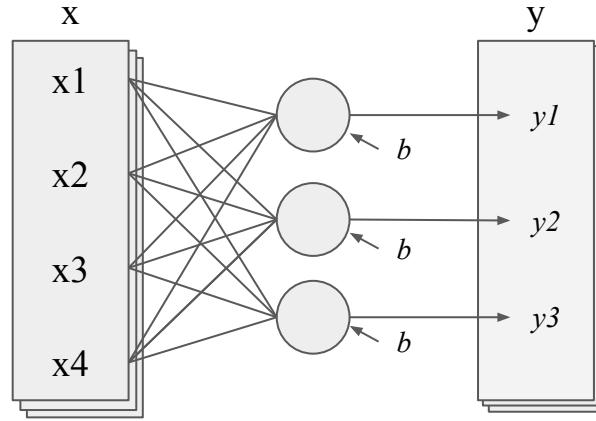
$$\begin{aligned} \mathbf{w} &= (w_1, w_2, w_3, w_4) \\ \mathbf{x} &= (x_1, x_2, x_3, x_4) \\ b & \\ y &= \mathbf{xw} + b \end{aligned}$$

# Perceptron - multi layer



가중치 벡터  
입력 벡터  
가중치 편향  
출력 벡터

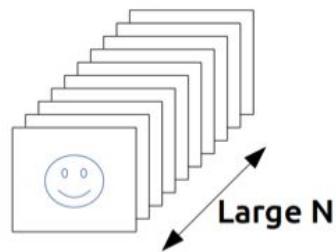
$$\begin{aligned}W &= (w_{11}, w_{12}, \dots, w_{43}, w_{44}) \\x &= (x_1, x_2, x_3, x_4) \\b &= (b_1, b_2, b_3) \\y &= xW + b\end{aligned}$$



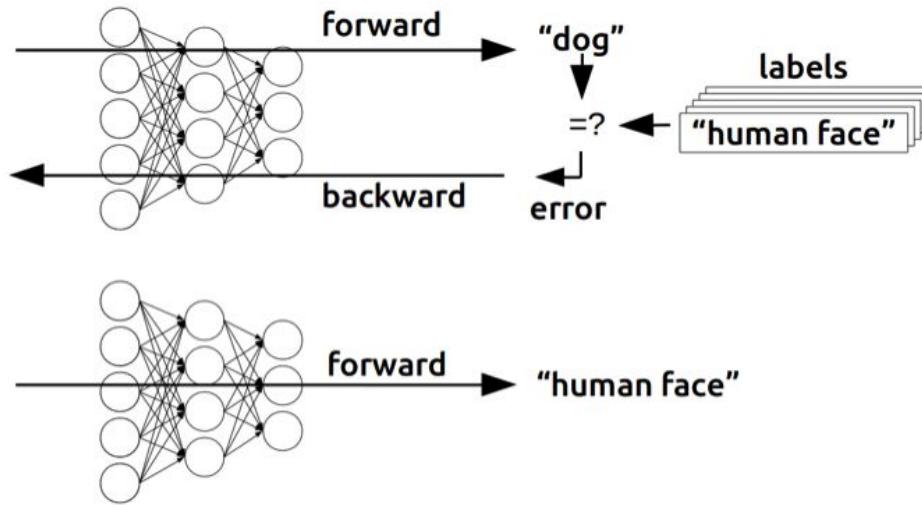
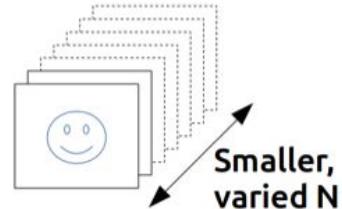
미니배치 데이터 처리

# 인공신경망을 학습시키는 방법

Training

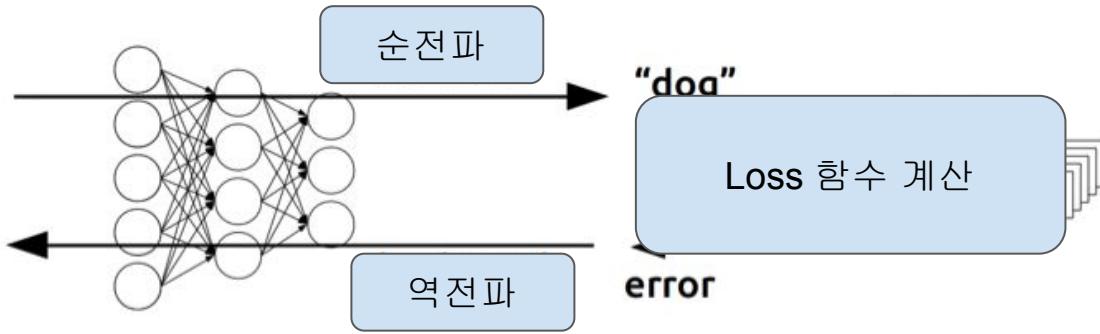
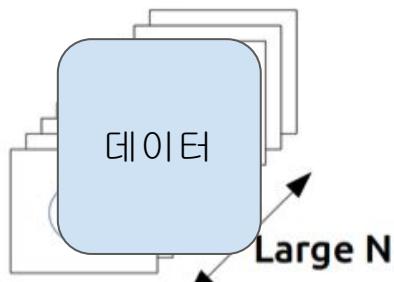


Inference

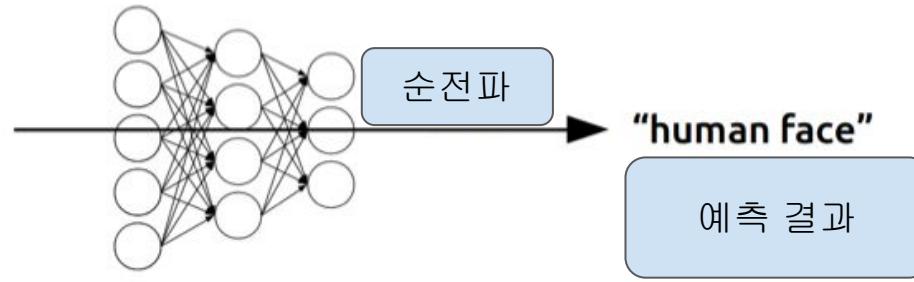
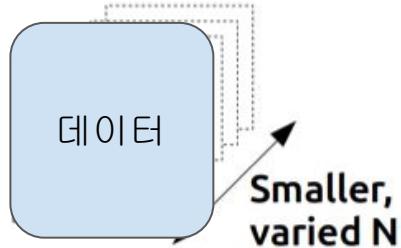


# 인공신경망을 학습시키는 방법

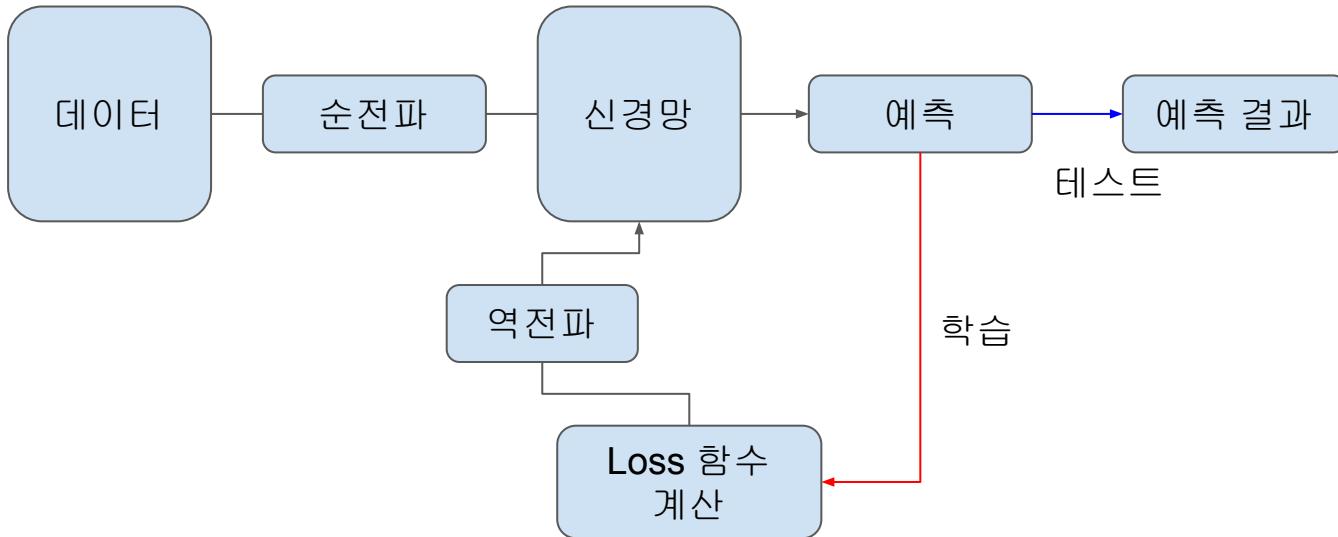
## Training



## Inference



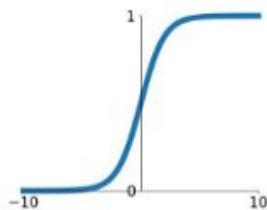
# Training Neural Network



# Activation function

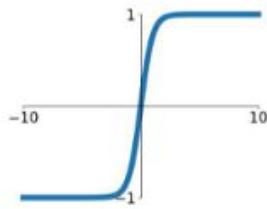
## Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



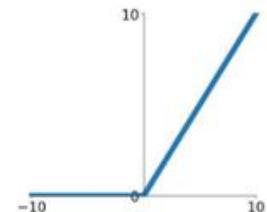
## tanh

$$\tanh(x)$$



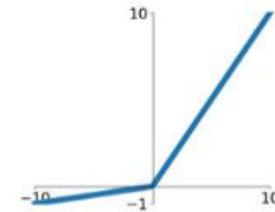
## ReLU

$$\max(0, x)$$



## Leaky ReLU

$$\max(0.1x, x)$$

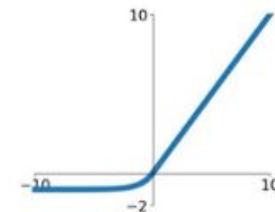


## Maxout

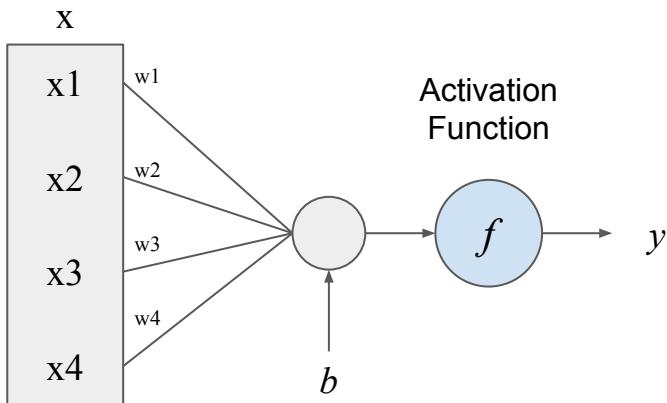
$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

## ELU

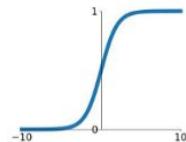
$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



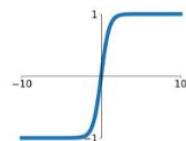
# Activation function



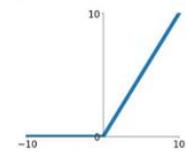
**Sigmoid**  
 $\sigma(x) = \frac{1}{1+e^{-x}}$



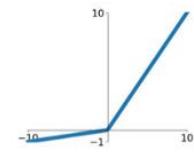
**tanh**  
 $\tanh(x)$



**ReLU**  
 $\max(0, x)$

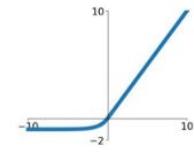


**Leaky ReLU**  
 $\max(0.1x, x)$



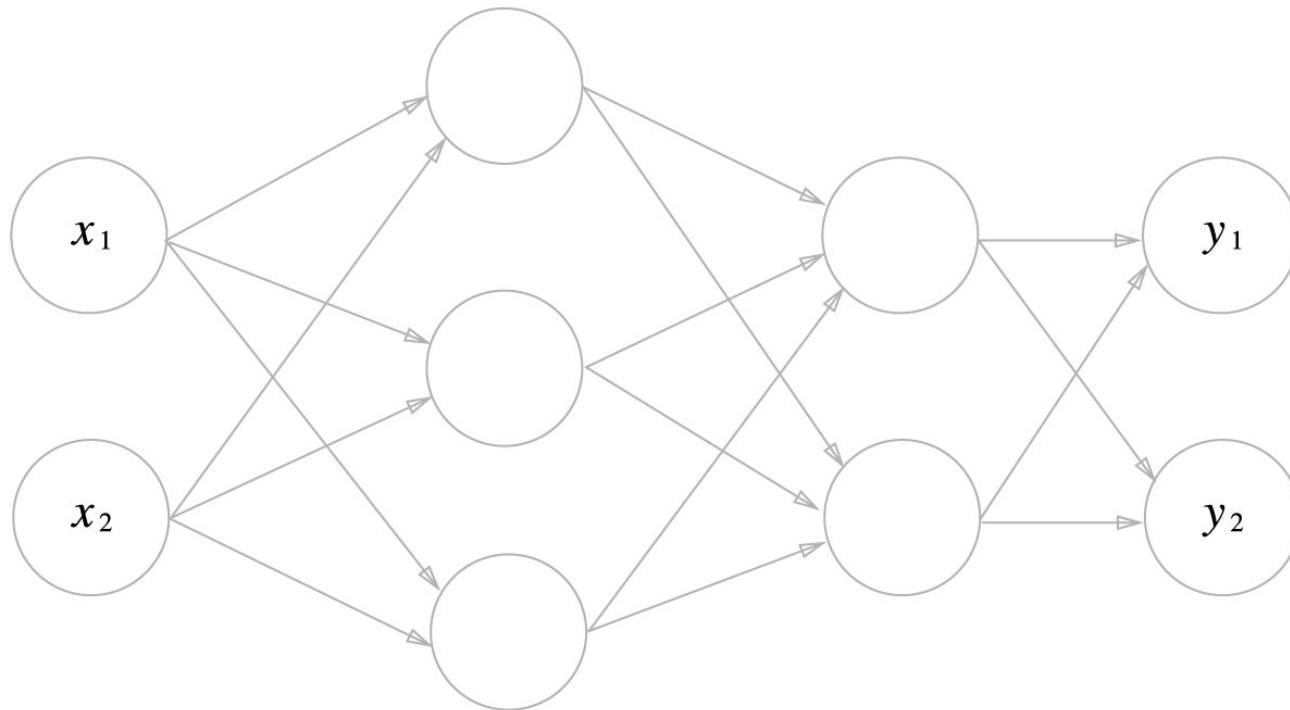
**Maxout**  
 $\max(w_1^T x + b_1, w_2^T x + b_2)$

**ELU**  
$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

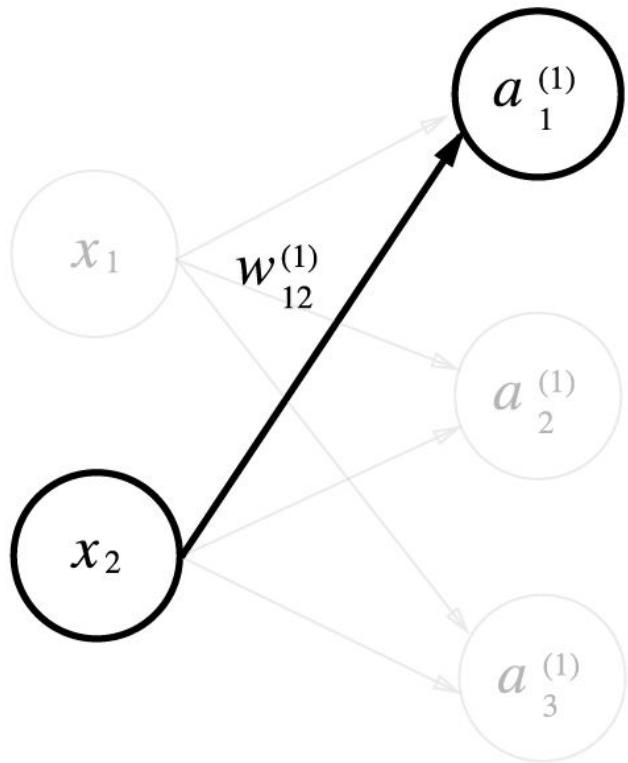


node에 계산된 값을 바로 다음 layer (output)으로 전달하지 않고,  
비선형 함수 (activation function)을 통과 시킨 후 전달함  
이 과정을 통해 layer를 깊게 쌓을 때 이점이 생김

# Neural Network - 순전파 (Feed forward)



# Neural Network

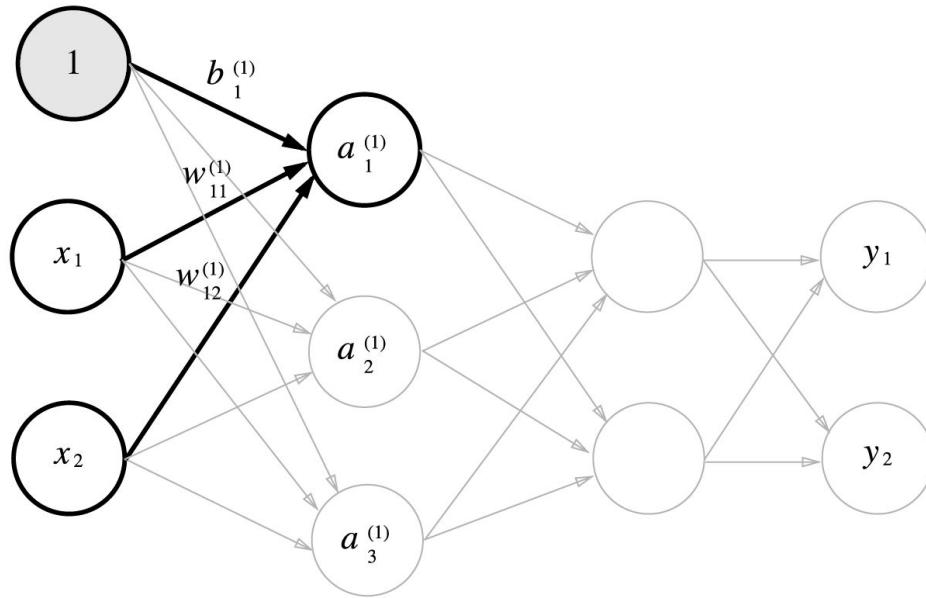


$w^{(1)}$

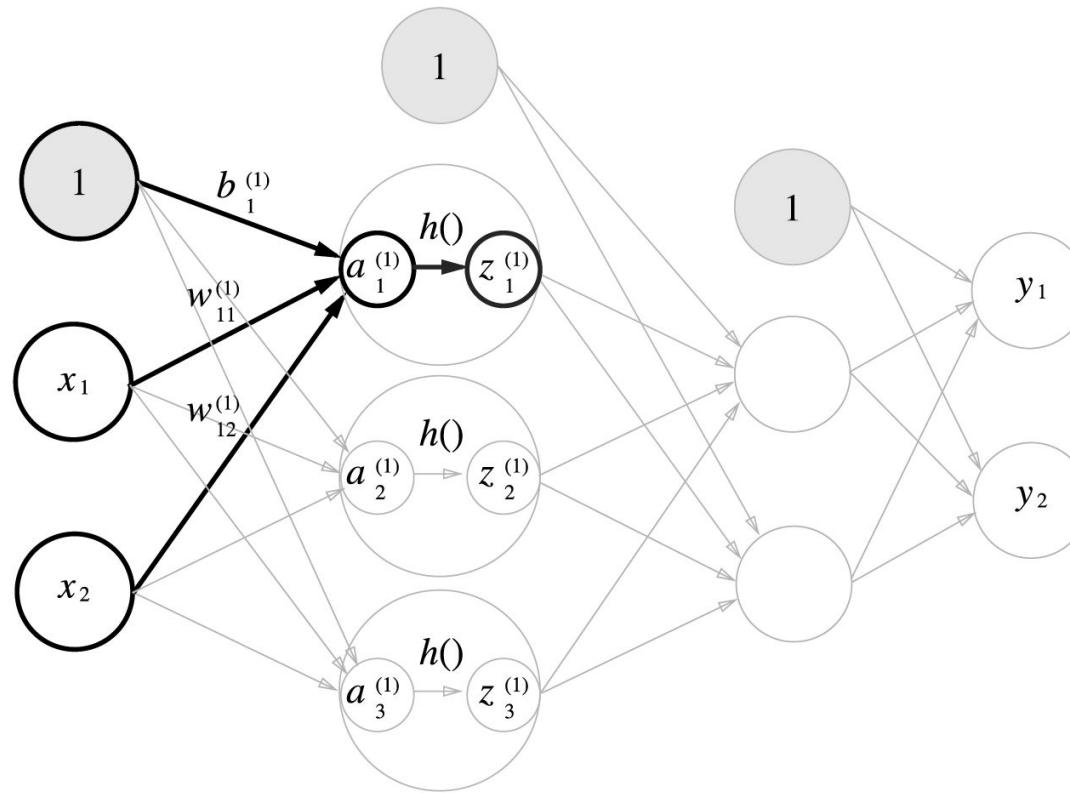
1 2

1층의 가중치  
앞 층의 2번째 뉴런  
다음 층의 1번째 뉴런

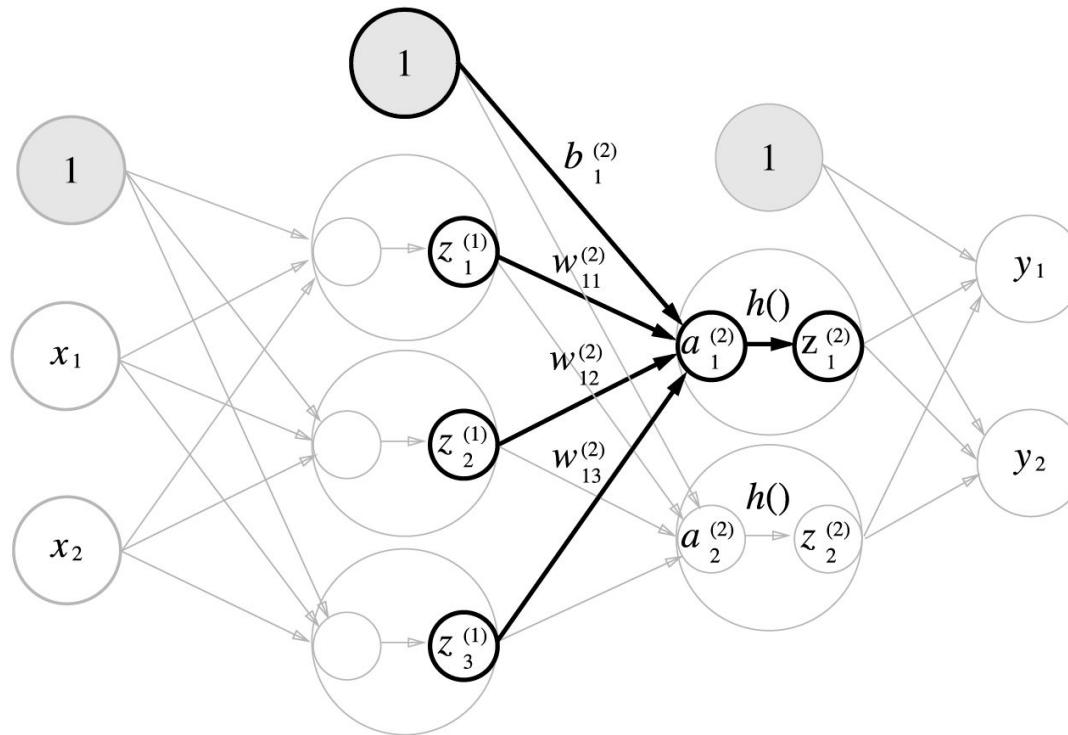
# Neural Network



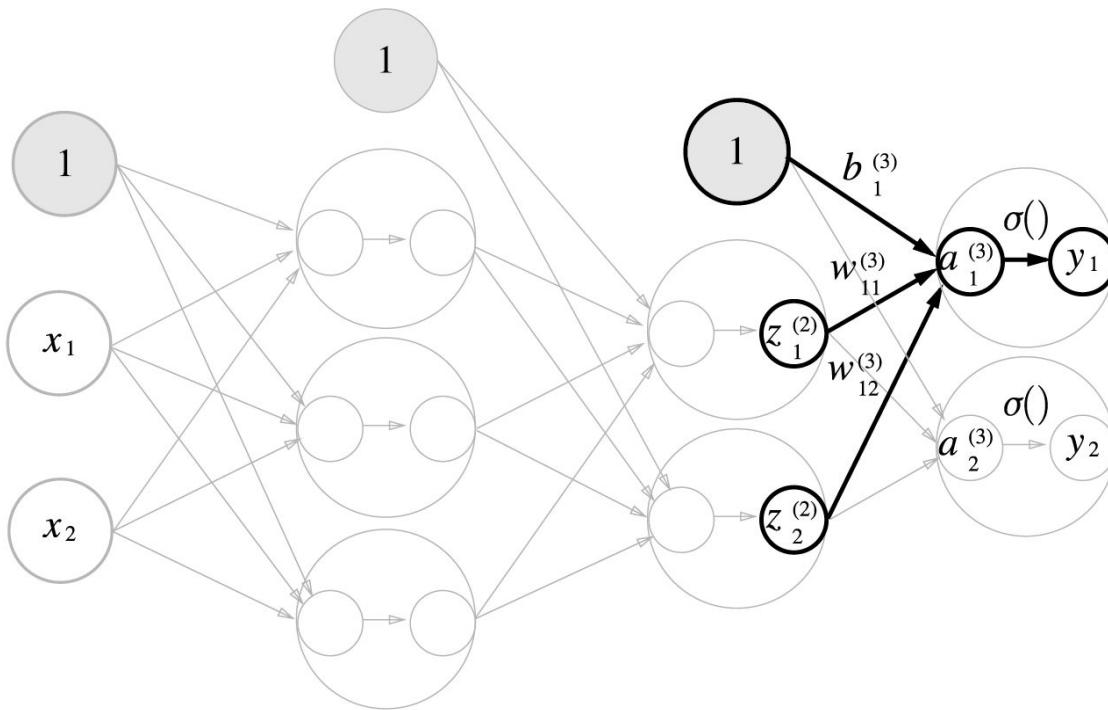
# Neural Network



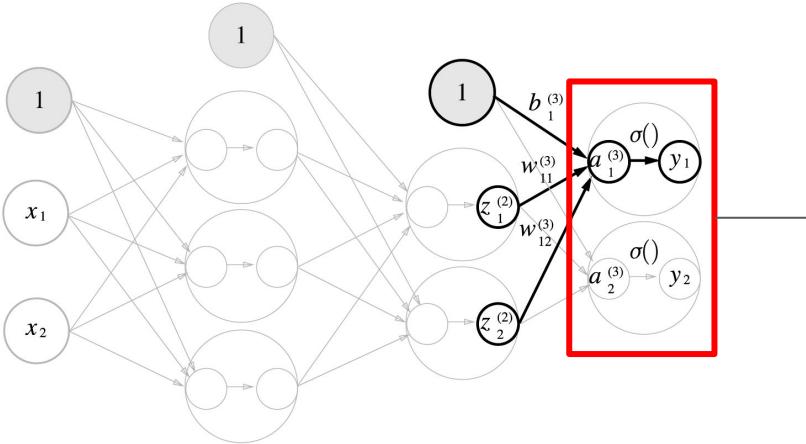
# Neural Network



# Neural Network

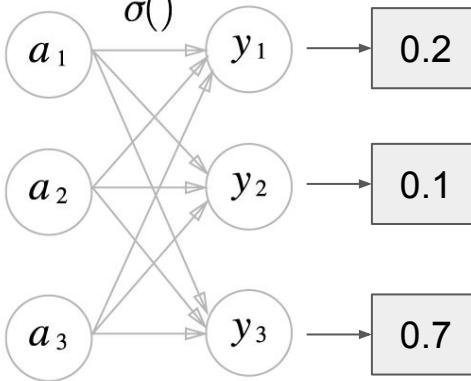


# Neural Network - Softmax function



Softmax 함수

$$p_j = \frac{\exp(x_j)}{\sum_k \exp(x_k)}$$



- 마지막 단계의 출력값을 정규화 시킴
- Softmax output의 합은 항상 1임
- Output Node의 개수는 예측하려는 Class 수

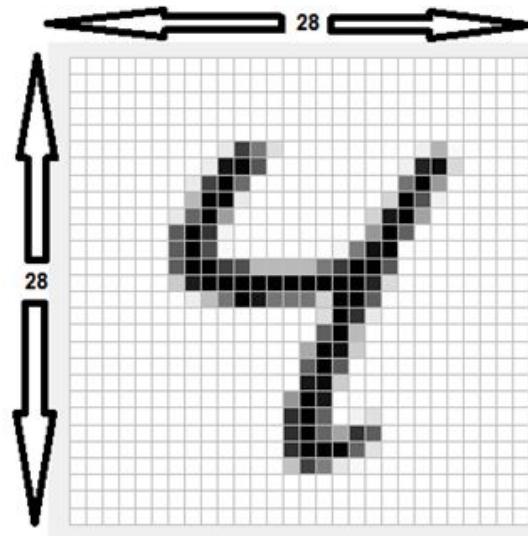
# 앞으로 학습 할 내용

- 가중치는 어떻게 결정되는가?
- 신경망에 실제 데이터를 학습하는 방식
- 신명망으로 분석할 수 있는 데이터들

# 데이터 추론 과정 (신경망 계산 과정 예시)

## 손글씨 숫자 데이터 (MNIST dataset)

00000000000000000000  
11111111111111111111  
22222222222222222222  
33333333333333333333  
44444444444444444444  
55555555555555555555  
66666666666666666666  
77777777777777777777  
88888888888888888888  
99999999999999999999

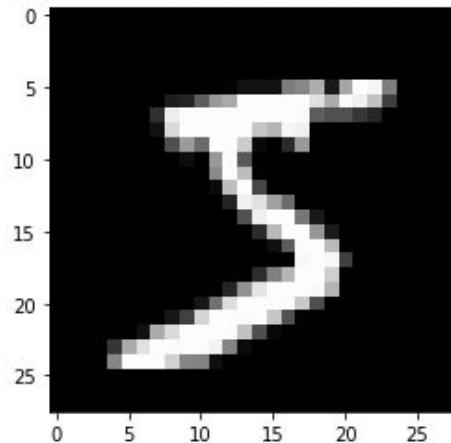


## 데이터 추론 과정

```
[ ] 1 import tensorflow as tf  
2 mnist = tf.keras.datasets.mnist  
3 (x_train, y_train), (x_test, y_test) = mnist.load_data()
```

```
1 plt.imshow(x_train[0], cmap='gray')
```

```
<matplotlib.image.AxesImage at 0x7f4313a36358>
```



데이터  
확인하기

```
1 for i in range(len(x_train[0])):
2     for j in range(len(x_train[0][i])):
3         if x_train[0][i][j] > 0:
4             print(1, end=' ')
5         else:
6             print(0, end=' ')
7     print('')
```

# 데이터 추론 과정

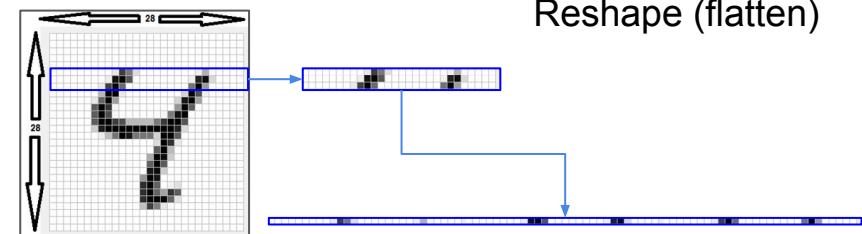
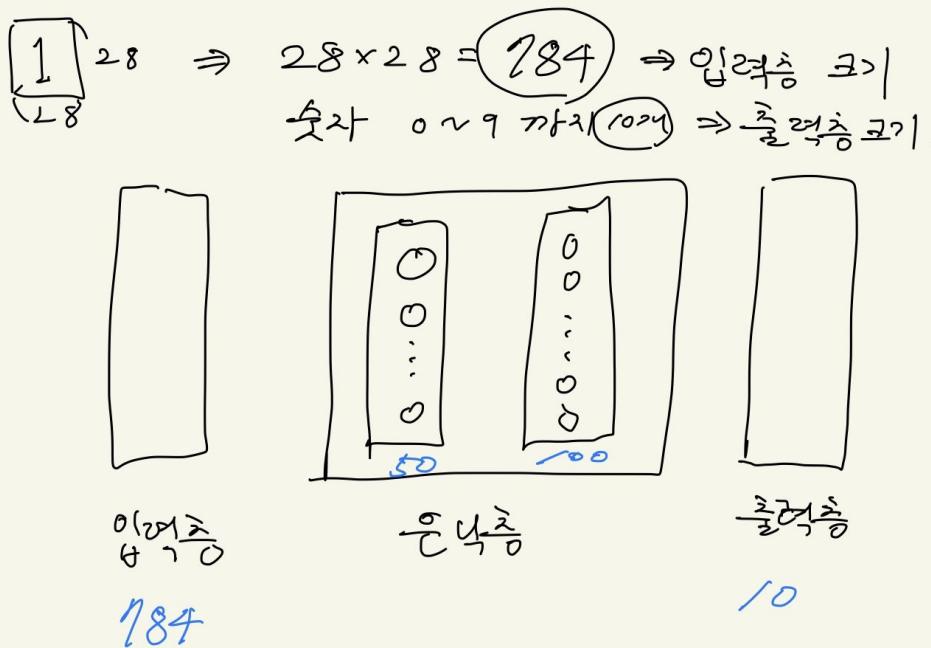
## 원-핫 인코딩 One-hot Encoding

0 [1, 0, 0, 0, 0, 0, 0, 0, 0, 0]  
1 [0, 1, 0, 0, 0, 0, 0, 0, 0, 0]  
2 [0, 0, 1, 0, 0, 0, 0, 0, 0, 0]  
3 [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]  
4 [0, 0, 0, 0, 1, 0, 0, 0, 0, 0]  
5 [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]  
6 [0, 0, 0, 0, 0, 0, 1, 0, 0, 0]  
7 [0, 0, 0, 0, 0, 0, 0, 1, 0, 0]  
8 [0, 0, 0, 0, 0, 0, 0, 0, 1, 0]  
9 [0, 0, 0, 0, 0, 0, 0, 0, 0, 1]

5 [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]

전체 class 수

# 데이터 추론 과정



```

1 import tensorflow as tf
2 mnist = tf.keras.datasets.mnist
3 (x_train, y_train), (x_test, y_test) = mnist.load_data()
4
5 # 픽셀 값을 0~1 사이로 정규화합니다.
6 x_train, x_test = x_train / 255.0, x_test / 255.0
7
8 x_test_flatten = x_test.reshape([x_test.shape[0], -1])

```

# 데이터 추론 과정

```
def init_network():
    with open("sample_weight.pkl", 'rb') as f:
        network = pickle.load(f)
    return network

def predict(network, x):
    W1, W2, W3 = network['W1'], network['W2'], network['W3']
    b1, b2, b3 = network['b1'], network['b2'], network['b3']

    a1 = np.dot(x, W1) + b1
    z1 = sigmoid(a1)
    a2 = np.dot(z1, W2) + b2
    z2 = sigmoid(a2)
    a3 = np.dot(z2, W3) + b3
    y = softmax(a3)

    return y
```

앞서 학습한 predict 코드와  
같은 코드

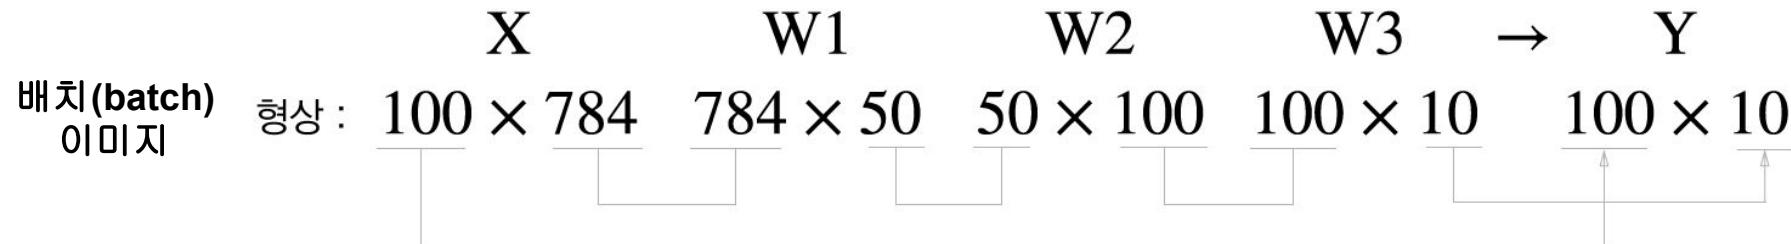
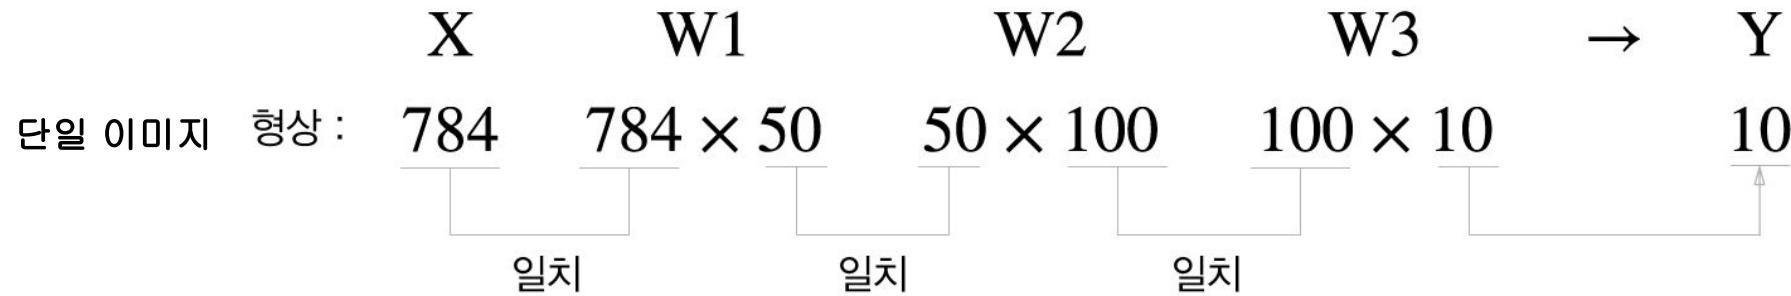
- MNIST 분류에 최적화 돼 있는 가중치

1 network

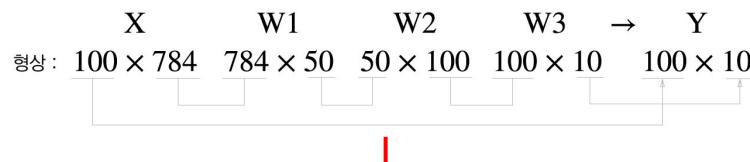
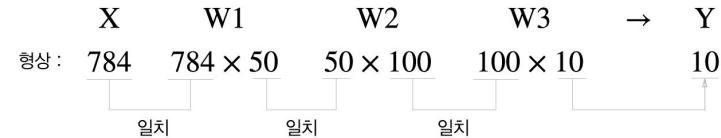
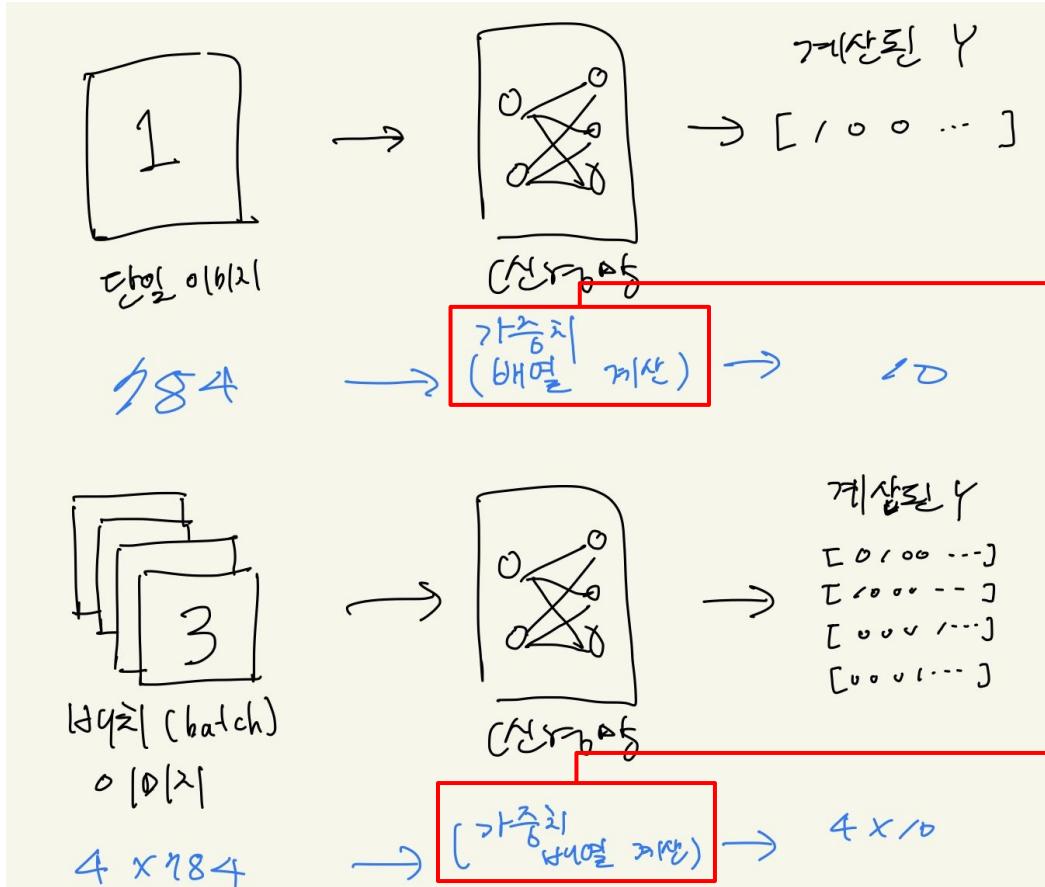
```
'W1': array([[-0.00741249, -0.00790439, -0.01307499, ..., 0.01978721,
   -0.04331266, -0.01350104],
   [-0.01029745, -0.01616653, -0.01228376, ..., 0.01920228,
   0.02809811, 0.01450908],
   [-0.01309184, -0.00244747, -0.0177224, ..., 0.00944778,
   0.01387301, 0.03393568],
   ...,
   [ 0.02242565, -0.0296145, -0.06326169, ..., -0.01012643,
   0.01120969, 0.01027199],
   [-0.00761533, 0.02028973, -0.01498873, ..., 0.02735376,
   -0.01229855, 0.02407041],
   [ 0.00027915, -0.06848375, 0.00911191, ..., -0.03183098,
   0.00743086, -0.04021148]], dtype=float32),
'W2': array([[-0.10694039, 0.01591247, -0.44349867, ..., 0.03561032,
   0.14045963, 0.03964241],
   [ 0.29911557, -0.03322235, -0.08902215, ..., -0.04722451,
   -0.0972147, 0.2950258],
   [ 0.06576645, 0.6330455, 0.02325344, ..., 0.05046809,
   0.26831996, -0.13252524],
   ...,
   [-0.1839421, -0.10925075, 0.25180233, ..., 0.06017017,
   0.11689074, 0.28868544],
   [ 0.10001627, 0.0899286, -0.03874066, ..., 0.15217757,
   -0.05744234, -0.00713823],
   [-0.02220659, -0.05105179, 0.00777963, ..., -0.531206,
   -0.4042084, 0.0090801]], dtype=float32),
```

## 데이터 추론 과정

신경망 각 층의 형상(shape) 추이



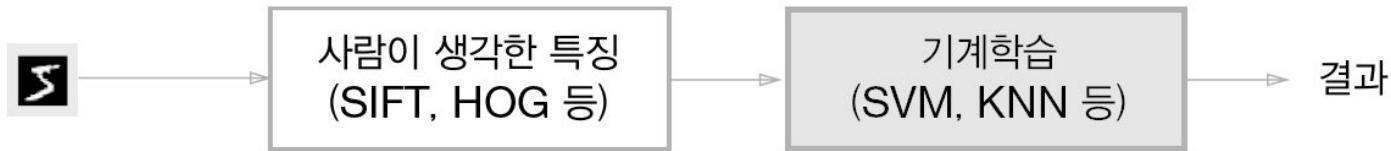
# 데이터 추론 과정



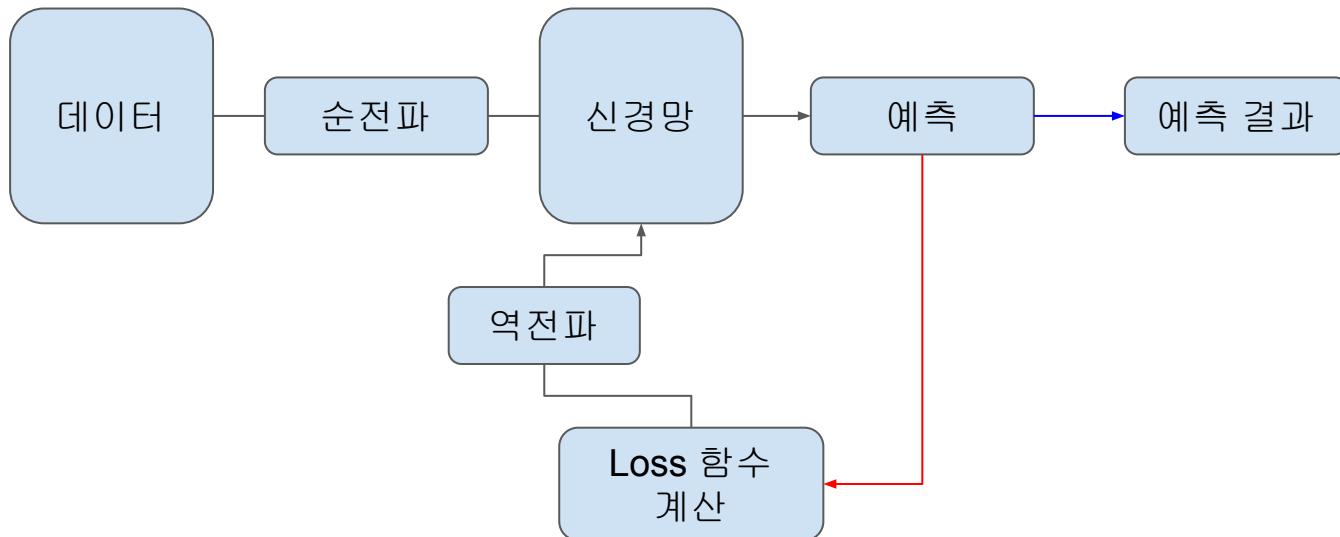
# 데이터 추론 과정

- 신경망에서는 활성화 함수로 시그모이드 함수와 ReLU 함수 같은 매끄럽게 변화하는 함수를 이용한다.
- 넘파이의 **다차원 배열**을 잘 사용하면 신경망을 효율적으로 구현할 수 있다.
- 기계학습 문제는 크게 **회귀와 분류**로 나눌 수 있다.
- 출력층의 활성화 함수로는 **회귀**에서는 주로 **항등 함수**를, **분류**에서는 주로 **소프트맥스** 함수를 이용한다.
- **분류**에서는 **출력층의 뉴런 수**를 **분류하려는 클래스 수**와 같게 설정한다.
- 입력 데이터를 묶은 것을 **배치**라 하며, 추론 처리를 이 **배치 단위로 진행**하면 결과를 훨씬 빠르게 얻을 수 있다.

# 신경망 학습



# 신경망 학습



# 손실함수 Loss functions

손실함수란?

신경망 성능이 얼마나 나쁜지 나타내는 지표

일반적으로 신경망이 예측한 결과와 정답을 비교하여 얼마나 차이가 있는지 수치화 함  
차이를 계산하는 방식은 여러가지가 있음

대표적인 손실 함수

평균 제곱 오차  
(Mean Squared Error, MSE)

$$E = \frac{1}{2} \sum_k (y_k - t_k)^2$$

교차 엔트로피 오차  
(Cross Entropy Error, CEE)

$$E = -\sum_k t_k \log y_k$$

# 손실함수 Loss functions

평균 제곱 오차 (Mean Squared Error, MSE)

$$E = \frac{1}{2} \sum_k (y_k - t_k)^2$$

```
def mean_squared_error(y, t):  
    return 0.5 * np.sum((y-t)**2)
```

Label	예측	정답	차이^2
0	0.1	0	0.01
1	0.05	0	0.0025
2	0.6	1	0.16
3	0	0	0
4	0.05	0	0.0025
5	0.1	0	0.01
6	0	0	0
7	0.1	0	0.01
9	0	0	0
합계		0.195	0.0975

$$E = \frac{1}{2} \sum_k (y_k - t_k)^2$$

Label	예측	정답	차이^2
0	0.1	0	0.01
1	0.05	0	0.0025
2	0.6	0	0.36
3	0	0	0
4	0.05	0	0.0025
5	0.1	0	0.01
6	0	0	0
7	0.1	1	0.81
9	0	0	0
합계		1.195	0.5975

$$E = \frac{1}{2} \sum_k (y_k - t_k)^2$$

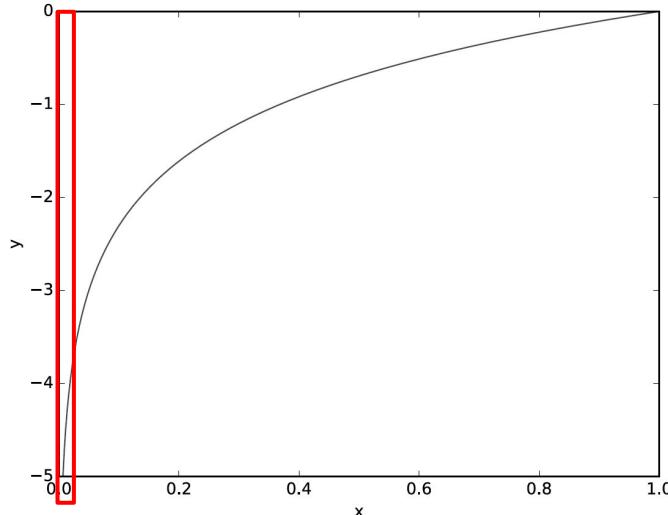
정답을 잘 맞추지 못할수록 손실 함수 계산 값은 커짐

# 손실함수 Loss functions

교차 엔트로피 오차 (Cross Entropy Error, CEE)

$$E = -\sum_k t_k \log y_k$$

```
def cross_entropy_error(y, t):
    delta = 1e-7
    return -np.sum(t * np.log(y+delta))
```



Label	예측	예측+1e-7	정답	$t_k * \log y_k$
0	0.1	0.1000001	0	0.00
1	0.05	0.0500001	0	0.00
2	0.6	0.6000001	1	-0.51
3	0	0.0000001	0	0.00
4	0.05	0.0500001	0	0.00
5	0.1	0.1000001	0	0.00
6	0	0.0000001	0	0.00
7	0.1	0.1000001	0	0.00
9	0	0.0000001	0	0.00
합계				0.51

자연로그에서 x가 0을 가질땐 음의 무한대로 수렴하므로  
아주작은 값을 예측값에 더해줘서 계산 가능한 형태로 만들어  
주어야 함

$$E = -\sum_k t_k \log y_k$$

# 미니배치 학습에서 손실함수

교차 엔트로피 오차 (Cross Entropy Error, CEE)

$$E = -\sum_k t_k \log y_k \quad \rightarrow \quad E = -\frac{1}{N} \sum_n \sum_k t_{nk} \log y_{nk}$$

n개의 배치에 대한 평균 손실 함수를 구하는 것

```
# 배치용 교차 엔트로피 오차
def cross_entropy_error(y, t):
    if y.ndim == 1:
        t = t.reshape(1, t.size)
        y = y.reshape(1, y.size)

    batch_size = y.shape[0]
    return -np.sum(t * np.log(y)) / batch_size
```

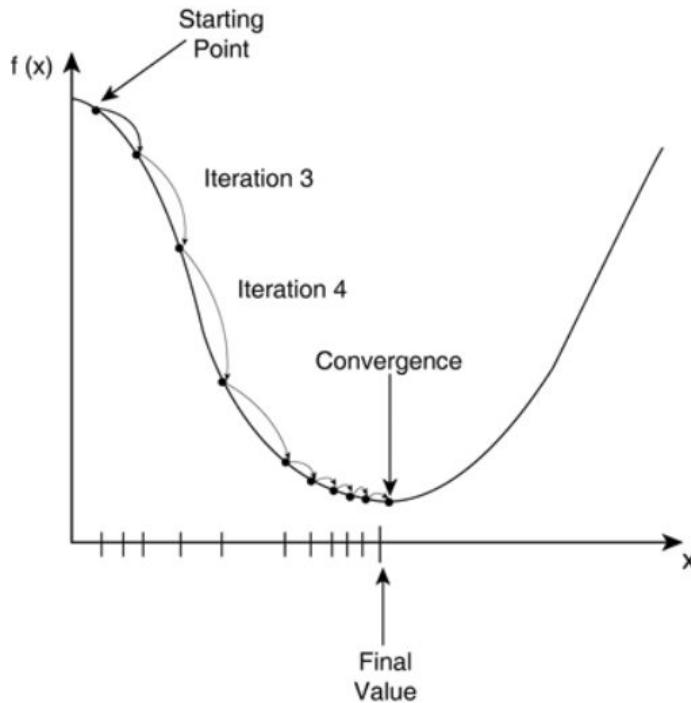
# 손실 함수 (Loss function)

- MSE (Mean Squared Error) - L2 Loss
- MAE (Mean Absolute Error) - L1 Loss
- CEE (Cross Entropy Error)
- ...

symbol	name	equation
$\mathcal{L}_1$	$L_1$ loss	$\ \mathbf{y} - \mathbf{o}\ _1$
$\mathcal{L}_2$	$L_2$ loss	$\ \mathbf{y} - \mathbf{o}\ _2^2$
$\mathcal{L}_1 \circ \sigma$	expectation loss	$\ \mathbf{y} - \sigma(\mathbf{o})\ _1$
$\mathcal{L}_2 \circ \sigma$	regularised expectation loss <sup>1</sup>	$\ \mathbf{y} - \sigma(\mathbf{o})\ _2^2$
$\mathcal{L}_{\infty} \circ \sigma$	Chebyshev loss	$\max_j  \sigma(\mathbf{o})^{(j)} - \mathbf{y}^{(j)} $
hinge	hinge [13] (margin) loss	$\sum_j \max(0, \frac{1}{2} - \hat{\mathbf{y}}^{(j)} \mathbf{o}^{(j)})$
hinge <sup>2</sup>	squared hinge (margin) loss	$\sum_j \max(0, \frac{1}{2} - \hat{\mathbf{y}}^{(j)} \mathbf{o}^{(j)})^2$
hinge <sup>3</sup>	cubed hinge (margin) loss	$\sum_j \max(0, \frac{1}{2} - \hat{\mathbf{y}}^{(j)} \mathbf{o}^{(j)})^3$
log	log (cross entropy) loss	$-\sum_j \mathbf{y}^{(j)} \log \sigma(\mathbf{o})^{(j)}$
log <sup>2</sup>	squared log loss	$-\sum_j [\mathbf{y}^{(j)} \log \sigma(\mathbf{o})^{(j)}]^2$
tan	Tanimoto loss	$-\sum_j \sigma(\mathbf{o})^{(j)} \mathbf{y}^{(j)} / \ \sigma(\mathbf{o})\ _2^2 + \ \mathbf{y}\ _2^2 - \sum_j \sigma(\mathbf{o})^{(j)} \mathbf{y}^{(j)}$
D <sub>CS</sub>	Cauchy-Schwarz Divergence [3]	$-\log \frac{\sum_j \sigma(\mathbf{o})^{(j)} \mathbf{y}^{(j)}}{\ \sigma(\mathbf{o})\ _2 \ \mathbf{y}\ _2}$

# 경사 하강법

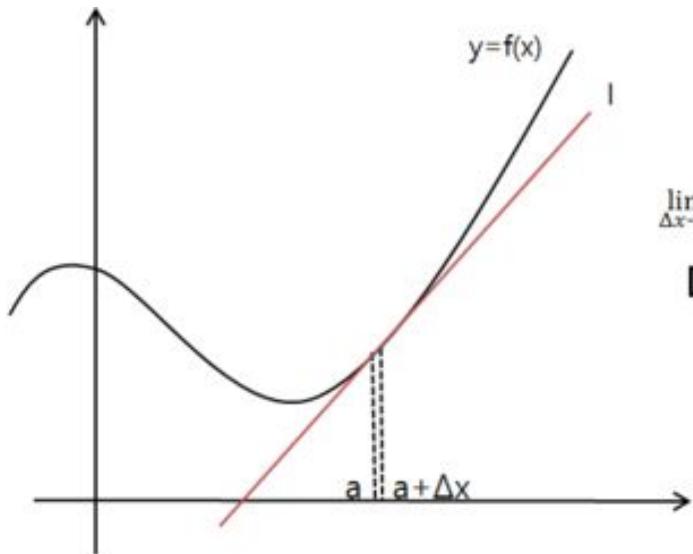
- 초기값 설정
- Cost function 계산
- 파라미터 값 업데이트
- 과정 반복



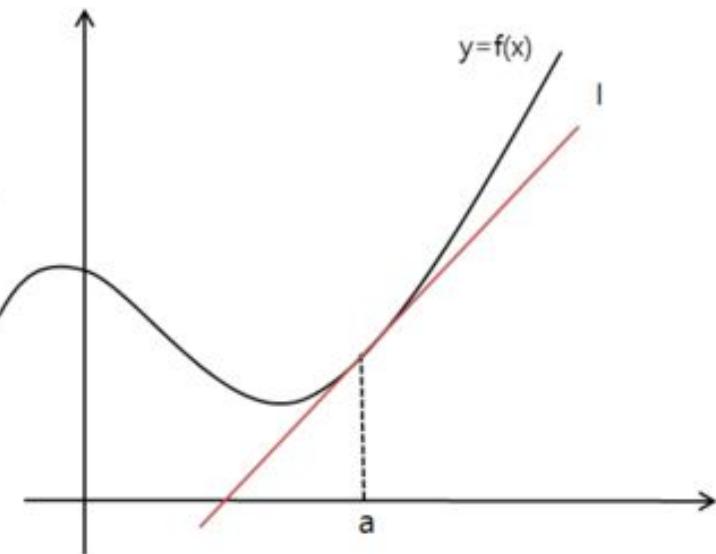
# 경사 하강법을 학습하기 전에...

미분, 편미분, 기울기 등 개념 복습

$$\frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x + h) - f(x)}{h}$$

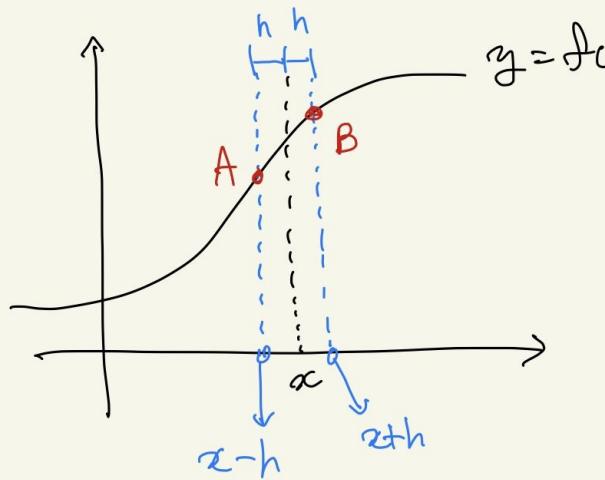


$$\lim_{\Delta x \rightarrow 0} \frac{f(a + \Delta x) - f(a)}{\Delta x}$$



# 경사 하강법을 학습하기 전에...

“수치 미분”



$$y = f(x)$$

A, B에 대한 기울기는?

$$\frac{\text{양증가분}}{\text{x증가분}}$$

$$\Rightarrow \frac{f(x+h) - f(x-h)}{(x+h) - (x-h)}$$

$$= \frac{f(x+h) - f(x-h)}{2h}$$

▶ “h”가 매우 작은 값으로 설정하면

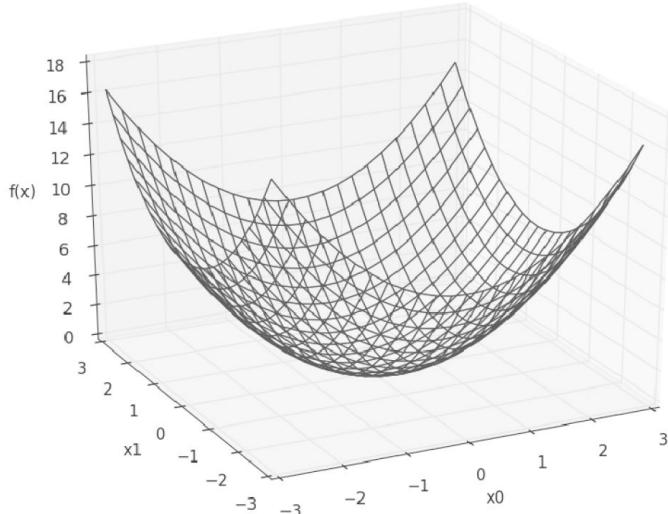
x에서의 실제 기울기와 유사한 값을 얻을 수 있다!

```
def numerical_diff(f, x):  
    h = 1e-4 # 0.0001  
    return (f(x+h) - f(x-h)) / (2*h)
```

# 경사 하강법을 학습하기 전에...

## 편미분

$$f(x_0, x_1) = x_0^2 + x_1^2$$



$$f(x_0, x_1) = x_0^2 + x_1^2$$

" $x_0$ 에 대해 편미분" :  $\frac{\partial f}{\partial x_0}$

" $x_1$ 에 대해 편미분" :  $\frac{\partial f}{\partial x_1}$

수치 미분을 편미분에 적용한다면?

미분하려는 변수를 제외한 다른 값들은 고정한 뒤  
수치 미분을 적용함

# 경사 하강법

$$x_0 = x_0 - \eta \frac{\partial f}{\partial x_0}$$

$$x_1 = x_1 - \eta \frac{\partial f}{\partial x_1}$$

학습률 (Learning rate)

```
def gradient_descent(f, init_x, lr=0.01, step_num=100):
    x = init_x

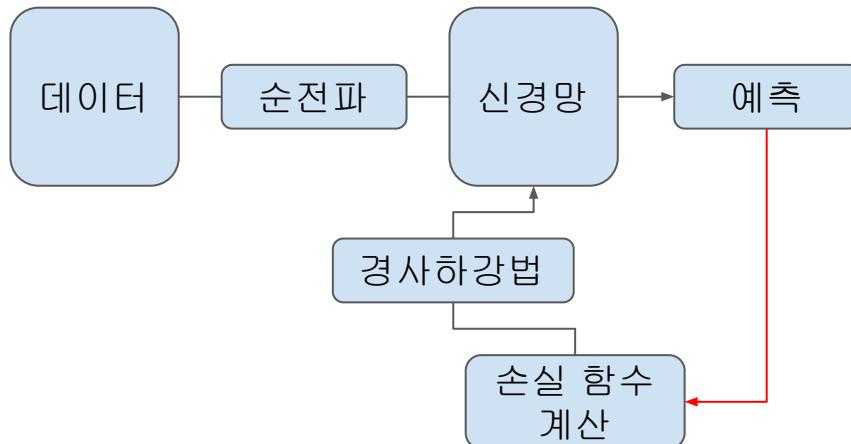
    for i in range(step_num):
        grad = numerical_gradient(f, x)
        x -= lr * grad

    return x
```

- 경사 하강법은 최적(최소)값을 보장하지는 않지만, 함수의 값을 줄일 수 있는 방법임
- 현 위치에서 기울어진 방향으로 일정거리 이동
- 이동한 곳에서 다시 경사 하강법 반복
- 학습률이 너무 크거나 작으면 효과가 없음

# 현재까지 학습한 내용

- 퍼셉트론
- 활성화 함수
- 다차원 배열의 계산
- 신경망 구현하기, 출력층 설계하기
- 데이터 추론
- 손실함수
- 미니배치
- 경사 하강법 (수치 미분)



# 현재까지 학습한 내용 구현하기

- 퍼셉트론
- 활성화 함수
- 다차원 배열의 계산
- 신경망 구현하기, 출력층 설계하기
- 데이터 추론
- 손실함수
- 미니배치
- 경사 하강법 (수치 미분)

# 현재까지 학습한 내용 구현하기

1. 데이터 로딩
2. 하이퍼파라미터 설정하기
3. 신경망 & 출력층 설계 및 구현
4. 미니배치 구성 & 학습
5. 기울기 (gradient) 계산
6. 가중치 업데이트
7. 학습 경과 기록하기 (loss function)

# 현재까지 학습한 내용 구현하기

## 1. 데이터 로딩 - MNIST 데이터

```
import tensorflow as tf
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()

# 픽셀 값을 0~1 사이로 정규화합니다.
x_train, x_test = x_train / 255.0, x_test / 255.0
```

TensorFlow > API > TensorFlow Core v2.3.0 > Python

`tf.keras.datasets.mnist.load_data` [공식 문서 링크](#)

### Returns

Tuple of Numpy arrays: (x\_train, y\_train), (x\_test, y\_test).

x\_train, x\_test: uint8 arrays of grayscale image data with shapes (num\_samples, 28, 28).

y\_train, y\_test: uint8 arrays of digit labels (integers in range 0-9) with shapes (num\_samples,).

# 현재까지 학습한 내용 구현하기

## 1. 데이터 로딩 - MNIST 데이터

```
import tensorflow as tf
mnist = tf.keras.datasets.mnist
(x_train, y_train), (x_test, y_test) = mnist.load_data()

# 픽셀 값을 0~1 사이로 정규화합니다.
x_train, x_test = x_train / 255.0, x_test / 255.0
```

```
x_test_flatten = x_test.reshape([x_test.shape[0], -1])
```

신경망 입력층으로 전달하기 위해 데이터  
형상을 28x28에서 784로 맞춤

```
1 print(x_test.shape)
2 print(x_test_flatten.shape)

(10000, 28, 28)
(10000, 784)
```

[공식 문서 링크](#)

TensorFlow > API > TensorFlow Core v2.3.0 > Python

`tf.keras.datasets.mnist.load_data`

Returns

Tuple of Numpy arrays: (x\_train, y\_train), (x\_test, y\_test).

x\_train, x\_test: uint8 arrays of grayscale image data with shapes (num\_samples, 28, 28).

y\_train, y\_test: uint8 arrays of digit labels (integers in range 0-9) with shapes (num\_samples,).

# 현재까지 학습한 내용 구현하기

## 2. 하이퍼파라미터 설정하기

하이퍼파라미터란? 모델링할 때 사용자가 직접 설정해주는 값을 뜻함

딥러닝 모델링 시에 설정하는 하이퍼파라미터로는 대표적으로 아래와 같은 값들이 있음

- 학습률 (Learning rate)
- 미니배치 크기
- 학습 반복 횟수

이 외에도 모델에 따라 여러가지 하이퍼파라미터가 있을 수 있음

# 현재까지 학습한 내용 구현하기

## 2. 하이퍼파라미터 설정하기

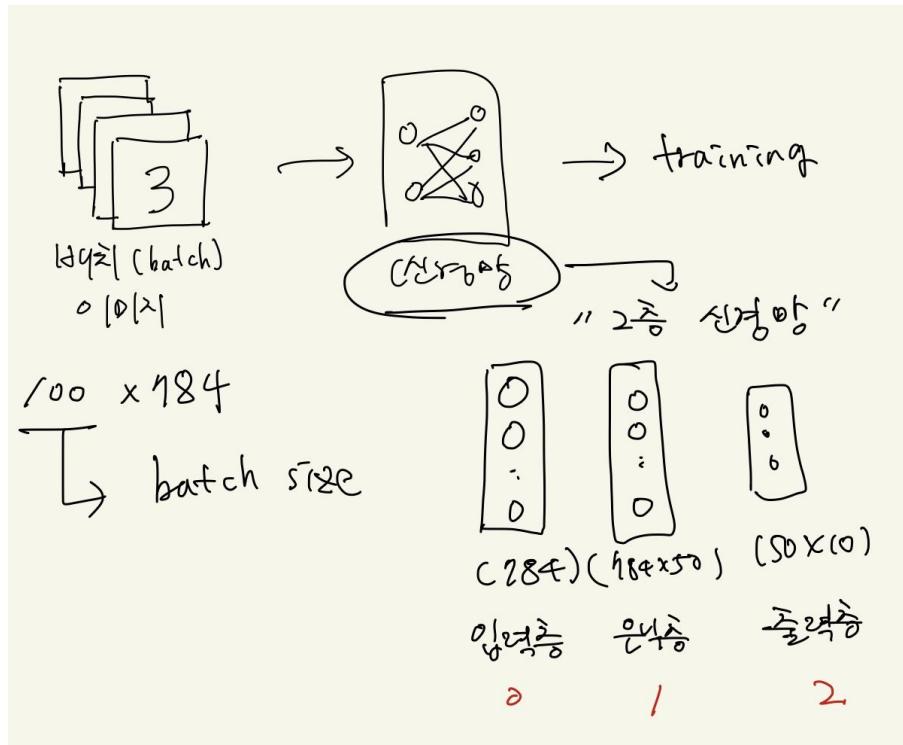
본 예시에서 사용하는 하이퍼파라미터

```
# 하이퍼파라미터 설정
iters_num = 10000 # 반복 횟수
train_size = x_train_flatten.shape[0]
batch_size = 100 # 미니배치 크기
learning_rate = 0.1
```

# 현재까지 학습한 내용 구현하기

[Colab에서 확인하기](#)

## 3. 신경망 & 출력층 설계 및 구현



```
def predict(self, x):
    W1, W2 = self.params['W1'], self.params['W2']
    b1, b2 = self.params['b1'], self.params['b2']

    a1 = np.dot(x, W1) + b1
    z1 = sigmoid(a1)
    a2 = np.dot(z1, W2) + b2
    y = softmax(a2)

    return y
```

(code 일부)

# 현재까지 학습한 내용 구현하기

## 4. 미니배치 구성 & 학습

### # 미니배치 획득

```
batch_mask = np.random.choice(train_size, batch_size)
x_batch = x_train_flatten[batch_mask]
t_batch = t_train[batch_mask]
```

```
1 batch_mask = np.random.choice(train_size, batch_size)
```

```
1 batch_mask
```

```
array([52561, 50710, 53084, 18135, 51108, 16164, 52756, 1943, 50638,
       955, 32013, 28355, 21440, 14731, 313, 13573, 15709, 12626,
       26219, 17018, 37639, 8130, 37994, 12281, 58532, 19161, 28458,
       38488, 50212, 26498, 14359, 8035, 56998, 55129, 12071, 10960,
       48525, 4079, 141, 47901, 41360, 59310, 38015, 6440, 26912,
       58357, 55789, 25486, 9456, 24933, 31985, 35151, 54278, 58009,
       10787, 16678, 49943, 35562, 23786, 46182, 37909, 38026, 32125,
       55127, 24962, 50218, 17726, 16019, 37506, 26506, 34762, 58135,
       9124, 33258, 55016, 23428, 9496, 57777, 2554, 5584, 30748,
       3769, 11875, 33923, 47622, 54920, 30565, 23118, 31595, 53873,
       18641, 41440, 18178, 23042, 4248, 33978, 31902, 11985, 39362,
       51771])
```

# 현재까지 학습한 내용 구현하기

## 5. 기울기 (gradient) 계산

```
def numerical_gradient(f, x):
    h = 1e-4
    grad = np.zeros_like(x) # x와 형상이 같은 배열을 생성

    for idx in range(x.shape[0]):
        tmp_val = x[idx]

        # f(x+h) 계산
        x[idx] = tmp_val + h
        fxh1 = f(x)

        # f(x-h) 계산
        x[idx] = tmp_val - h
        fxh2 = f(x)

        grad[idx] = (fxh1 - fxh2) / (2*h)
        x[idx] = tmp_val

    return grad
```

TwoLayerNet class의 함수

```
# x : 입력 데이터, t : 정답 레이블
def numerical_gradient(self, x, t):

    loss_W = lambda W: self.loss(x, t)

    grads = {}
    grads['W1'] = numerical_gradient(loss_W, self.params['W1'])
    grads['b1'] = numerical_gradient(loss_W, self.params['b1'])
    grads['W2'] = numerical_gradient(loss_W, self.params['W2'])
    grads['b2'] = numerical_gradient(loss_W, self.params['b2'])

    return grads
```

# 현재까지 학습한 내용 구현하기

## 6. 가중치 업데이트

```
# 매개 변수 갱신  
for key in ('W1', 'b1', 'W2', 'b2'):  
    network.params[key] -= learning_rate * grad[key]
```

앞 단계에서 계산한 gradient

## 7. 학습 경과 기록하기

```
# 학습 경과 기록  
loss = network.loss(x_batch, t_batch)  
train_loss_list.append(loss)  
print(loss)
```

# 오차역전파법 (backpropagation)

오차역전파법이란?

오차를 역으로 전파하는 방법 (backward propagation of errors)를 줄여서 ‘backpropagation’이라고 함

앞서 학습한 **수치 미분**은 단순하고 구현하기도 쉽지만 계산 시간이 오래 걸린다는 단점이 있음

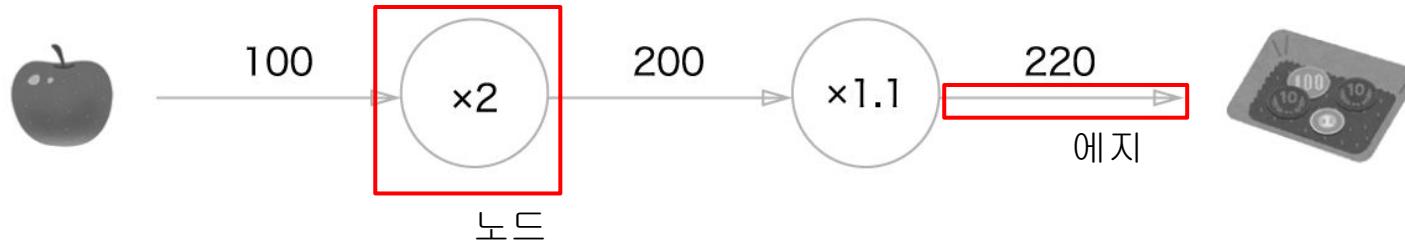
오차역전파법을 이용하면 가중치 매개변수의 기울기를 **효율적으로 계산**할 수 있음

# Computational graph (계산 그래프)

계산그래프란?

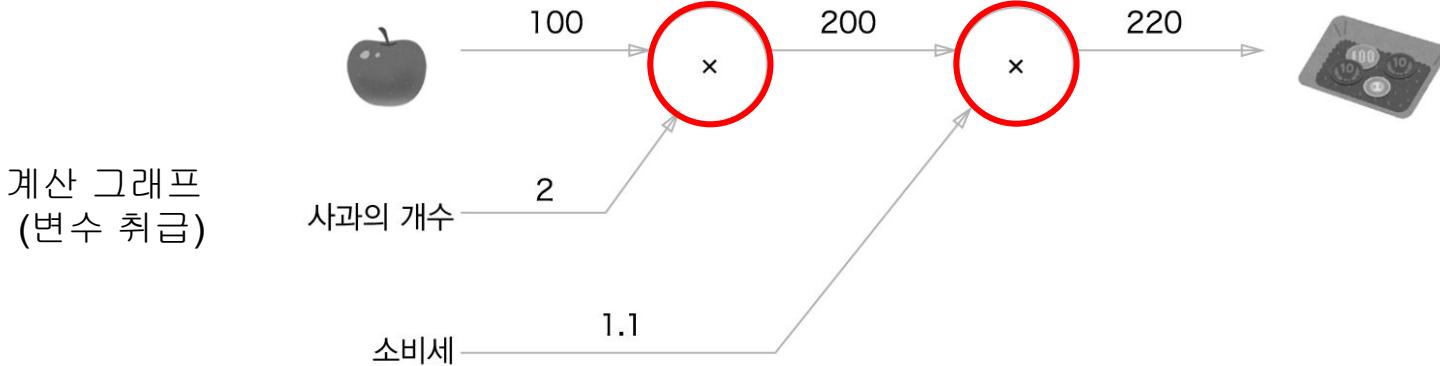
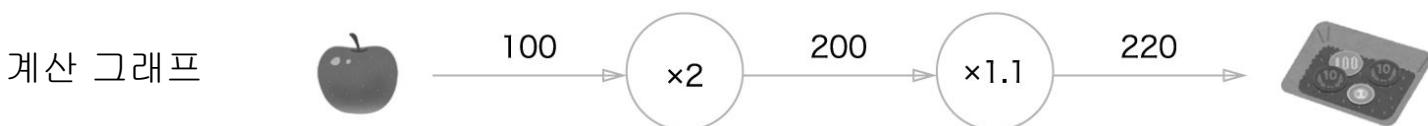
계산 과정을 그래프로 나타낸 것

노드 (node)와 에지 (edge)로 표현되는 그래프 자료구조임



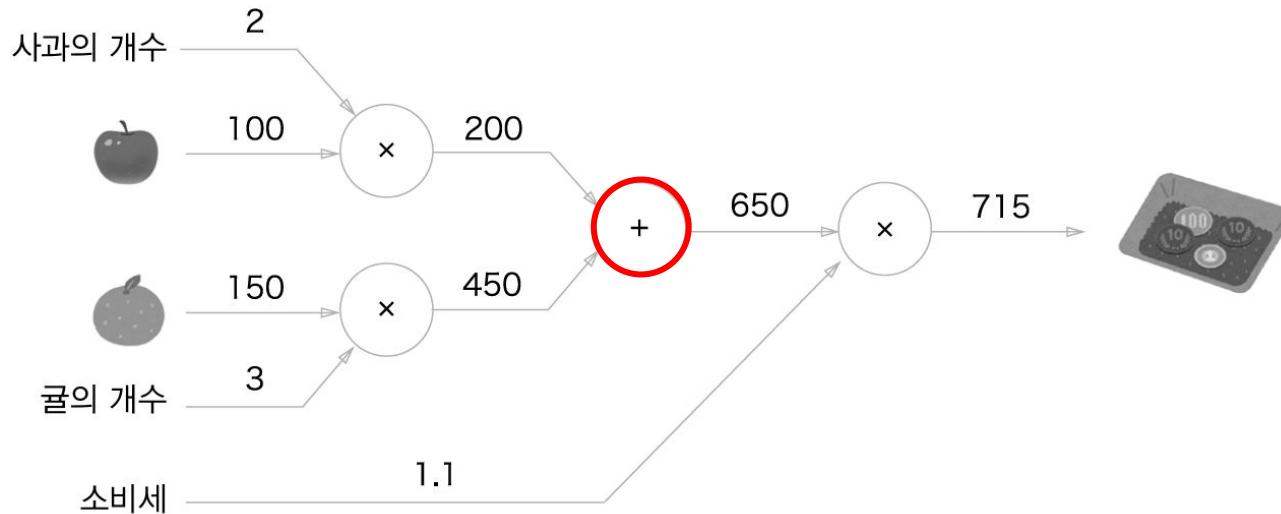
# Computational graph (계산 그래프)

문제1 : 현빈 군은 슈퍼에서 1개에 **100원**인 사과를 **2개** 샀습니다.  
이때 지불 금액을 구하세요. 단, 소비세가 **10%** 부과됩니다.



# Computational graph (계산 그래프)

문제2 : 현빈 군은 슈퍼에서 사과를 2개, 귤을 3개 샀습니다. 사과는 1개에 **100원**, 귤은 1개에 **150원**입니다. 소비세가 **10%**일 때 지불 금액을 구하세요.

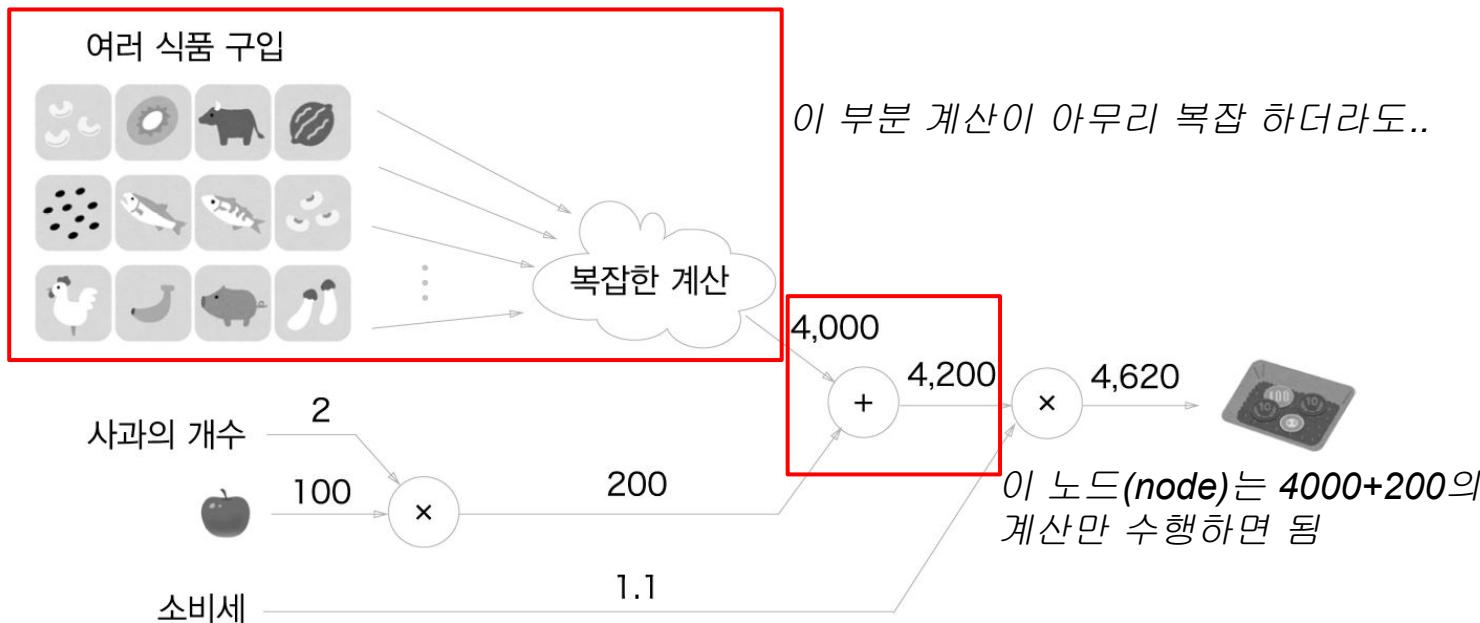


# Computational graph (계산 그래프)

계산 그래프는 ‘국소적 계산’을 전파하여 최종 결과를 얻는다는 특징이 있음

국소적이란 ‘자신과 직접 관계된 작은 범위’ 라는 뜻

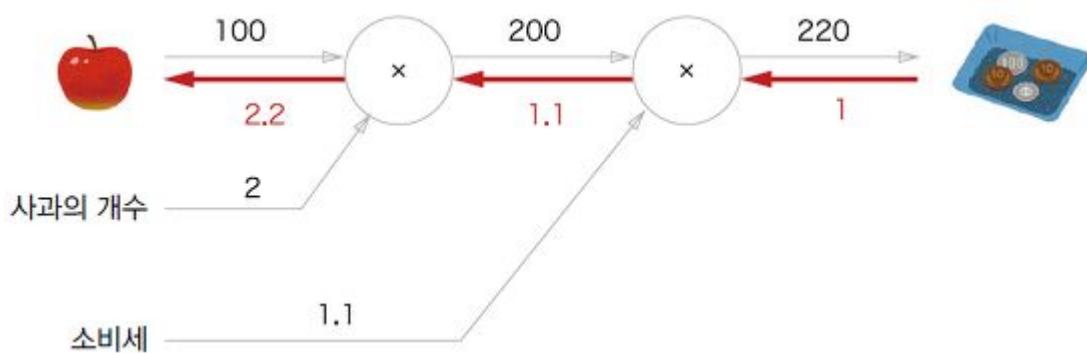
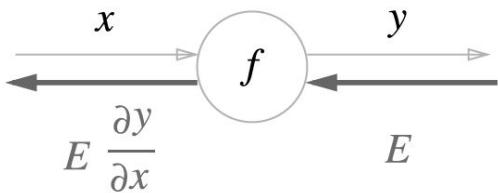
전체 계산 결과와 상관없이, 자신과 관계된 정보만으로 결과를 출력할 수 있다는 것



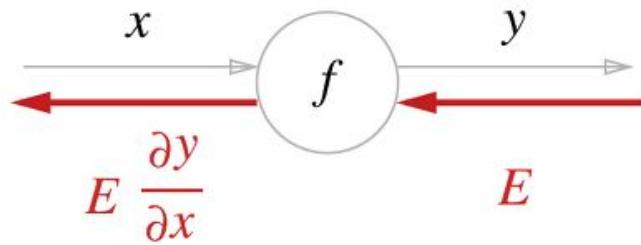
# Backpropagation (역전파)

문제1 : 현빈 군은 슈퍼에서 1개에 **100원**인 사과를 **2개** 샀습니다.  
이때 지불 금액을 구하세요. 단, 소비세가 **10%** 부과됩니다.

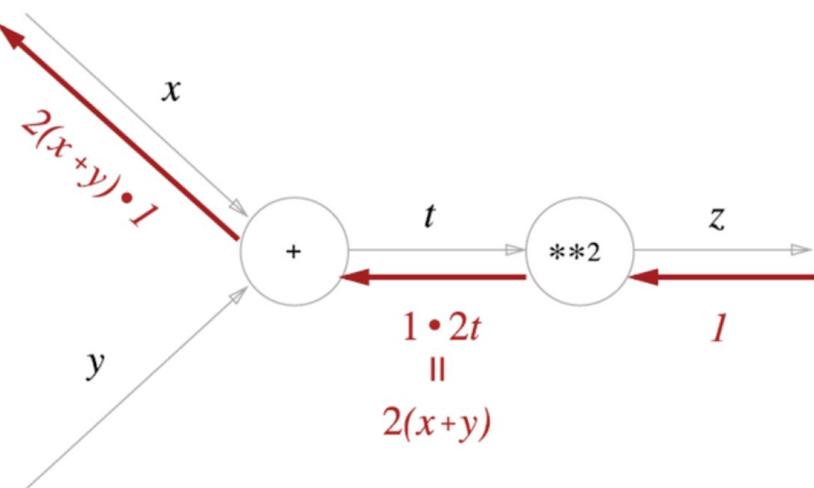
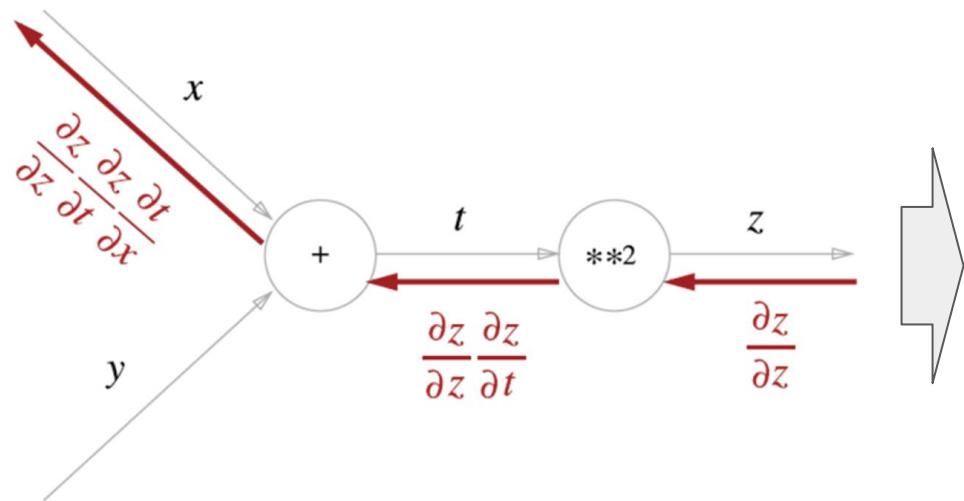
사과 가격이 오르면 최종 금액에 어떤 영향을 끼치는가?  
=> ‘사과 가격에 대한 지불 금액의 미분’을 구하는 문제!



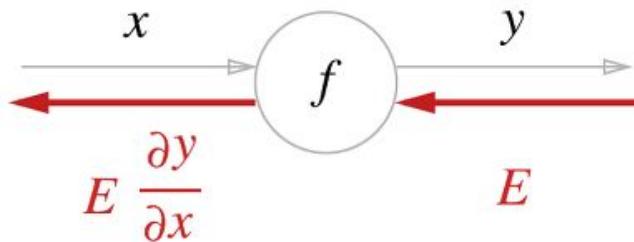
# 연쇄 법칙



역전파시 계산해야 하는 값 :  $x$ 에대한  $y$ 의 미분  
( $x$ 가 변할 때  $y$ 는 얼만큼 변하는지?)



# 연쇄 법칙



수식보다 의미를 이해하자

$x$  가 1만큼 변할 때  $y$ 는 어느정도 변하는지 계산한 것

예를 들어  $x$ 가 사과의 개수,

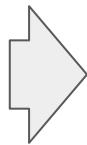
$y$ 가 전체 가격이라면,

$E \frac{\partial y}{\partial x}$  사과 개수 1개당 가격의 변동 정도로 해석할 수 있음

# 역전파

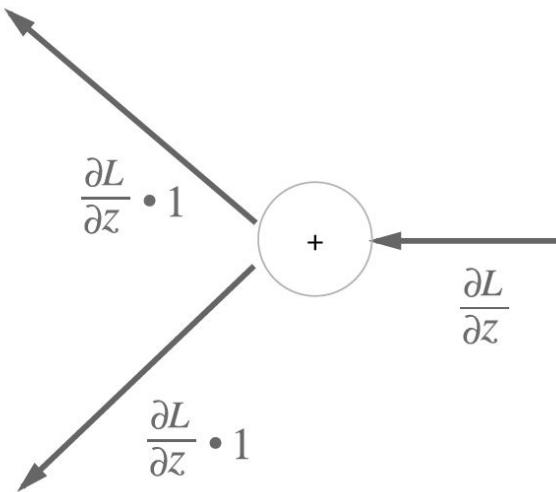
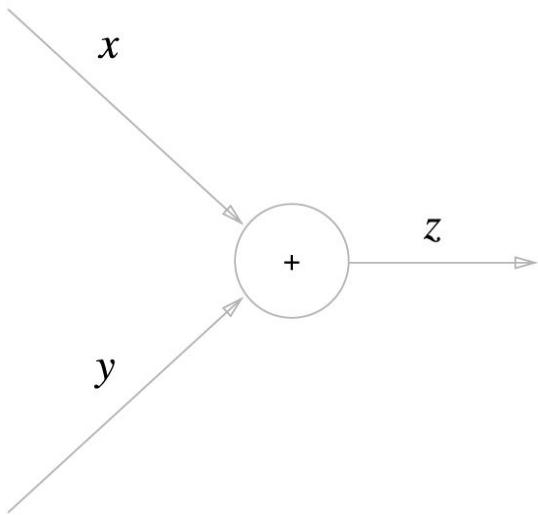
덧셈 노드의 역전파

$$z = x + y$$



$$\frac{\partial z}{\partial x} = 1$$

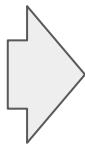
$$\frac{\partial z}{\partial y} = 1$$



# 역전파

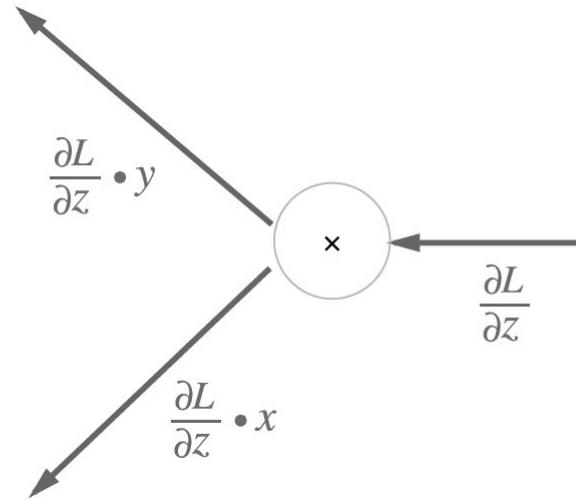
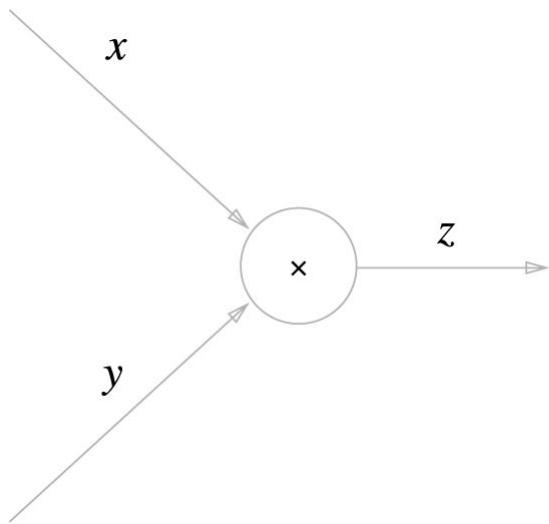
곱셈 노드의 역전파

$$z = xy$$



$$\frac{\partial z}{\partial x} = y$$

$$\frac{\partial z}{\partial y} = x$$



# 단순한 계층 구현하기

계산 그래프에서 사용 되는 곱셈 노드와 덧셈 노드를 구현해보자

```
class MulLayer:  
    def __init__(self):  
        self.x = None  
        self.y = None  
  
    def forward(self, x, y):  
        self.x = x  
        self.y = y  
        out = x * y  
  
        return out  
  
    def backward(self, dout):  
        dx = dout * self.y  
        dy = dout * self.x  
  
        return dx, dy
```

```
class AddLayer:  
    def __init__(self):  
        pass  
  
    def forward(self, x, y):  
        out = x + y  
        return out  
  
    def backward(self, dout):  
        dx = dout * 1  
        dy = dout * 1  
        return dx, dy
```

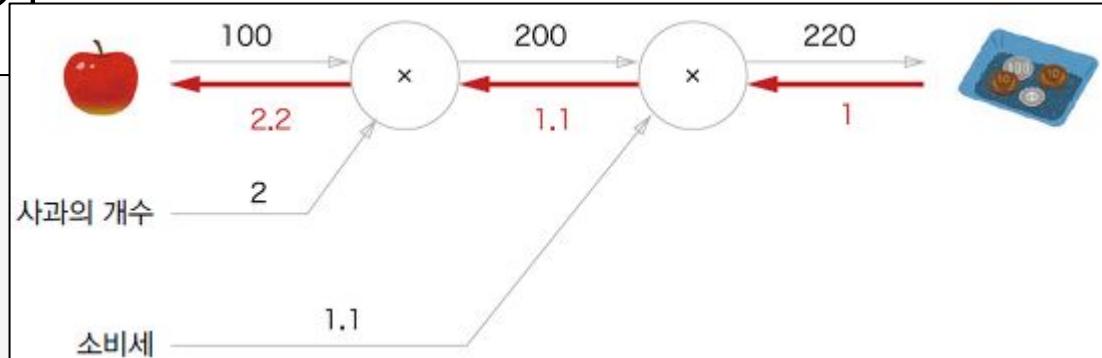
# 단순한 계층 구현하기

```
apple = 100  
apple_num = 2  
tax = 1.1
```

```
mul_apple_layer = MulLayer()  
mul_tax_layer = MulLayer()
```

```
# forward  
apple_price = mul_apple_layer.forward(apple, apple_num)  
price = mul_tax_layer.forward(apple_price, tax)
```

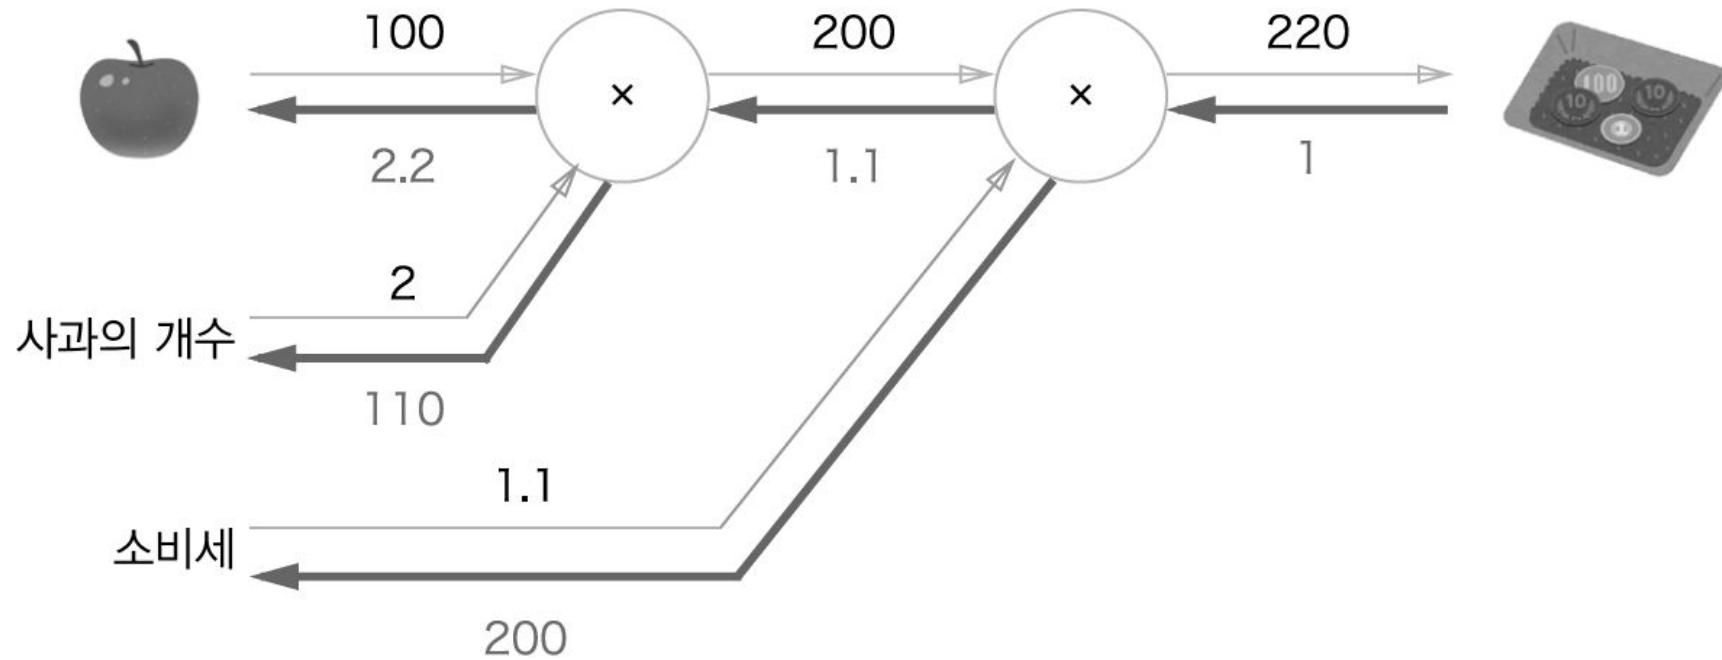
```
# backward  
dprice = 1  
dapple_price, dtax = mul_tax_layer.backward(dprice)  
dapple, dapple_num = mul_apple_layer.backward(dapple_price)  
  
print("price:", int(price))  
print("dApple:", dapple)  
print("dApple_num:", int(dapple_num))  
print("dTax:", dtax)
```



```
price: 220  
dApple: 2.2  
dApple_num: 110  
dTax: 200
```

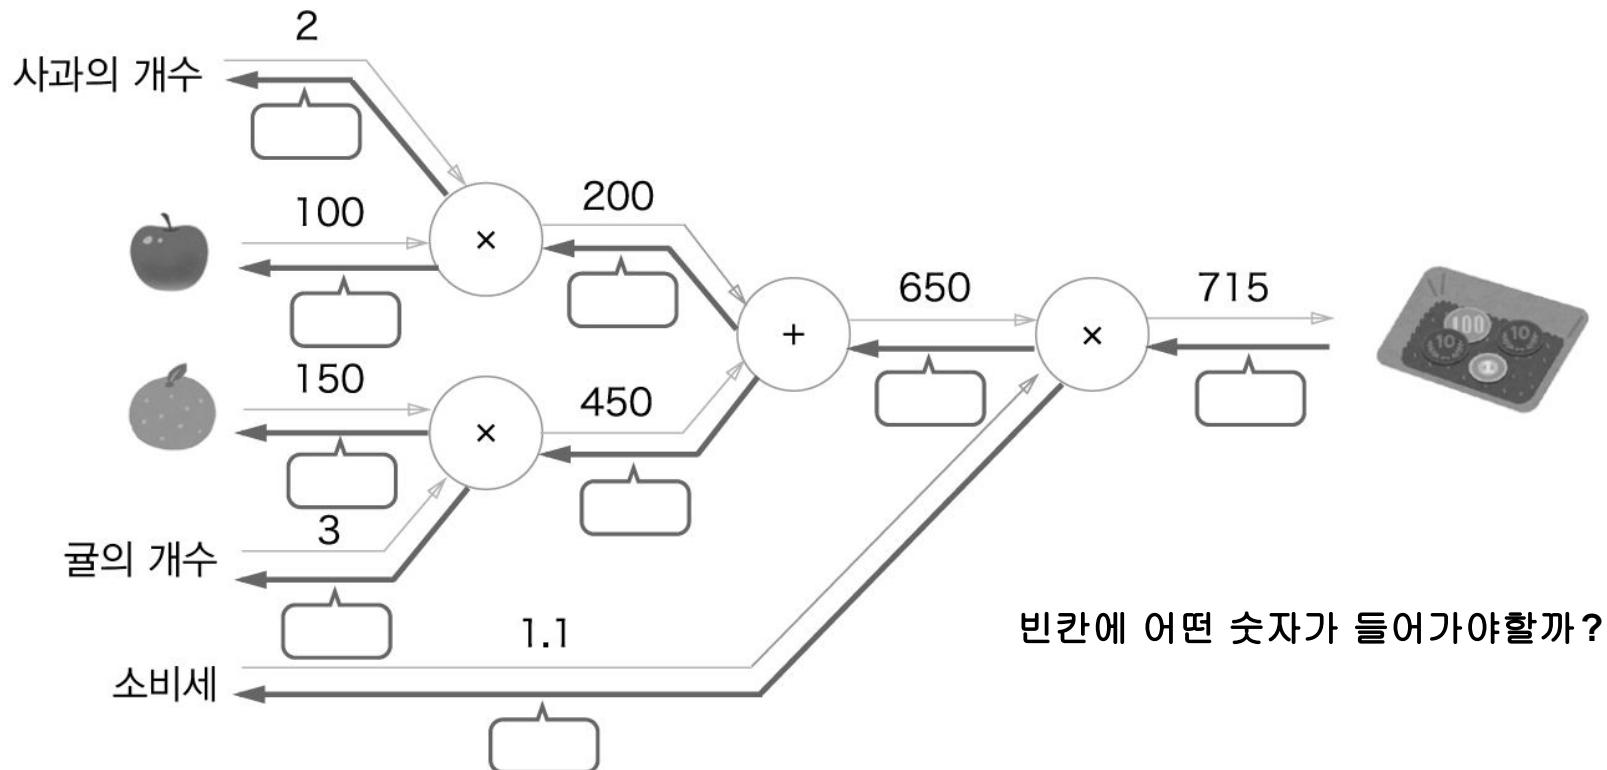
# 역전파 예시

사과 쇼핑의 역전파 예



# 역전파 예시

사과와 귤 쇼핑의 역전파 예



# 활성화 함수 계층 구현하기

계산 그래프에 활성화 함수 구현 (ReLU)

ReLU 수식

$$y = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

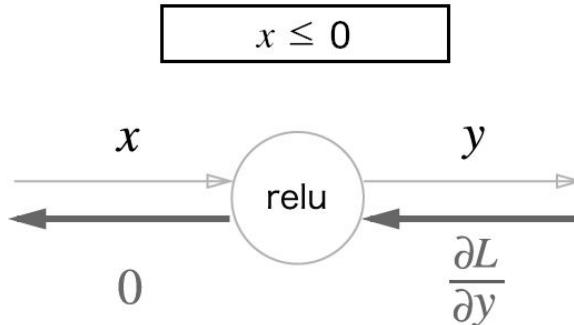
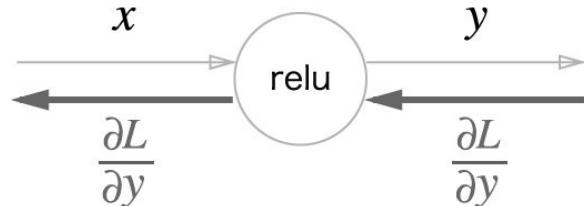
x에 대한 y의 미분

$$\frac{\partial y}{\partial x} = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases}$$

입력인 x가 0보다 크면 역전파는 상류의 값을 그대로 전달  
x가 0이하면, 하류로 신호를 보내지 않음

$x > 0$

$x \leq 0$



# 활성화 함수 계층 구현하기

계산 그래프에 활성화 함수 구현 (ReLU)

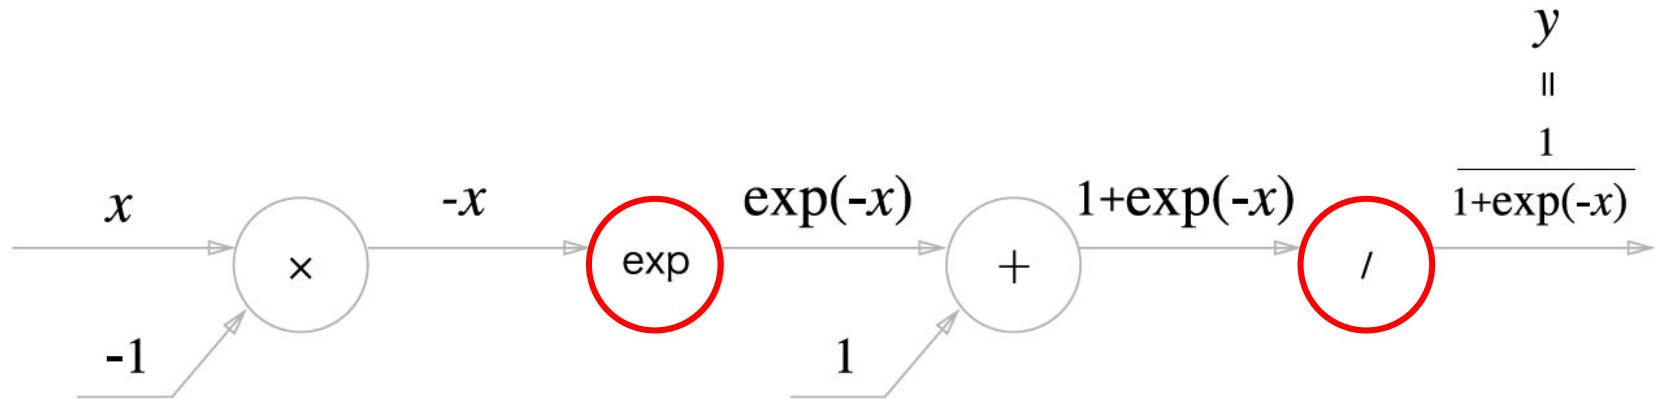
```
class Relu:  
    def __init__(self):  
        self.mask = None  
  
    def forward(self, x):  
        self.mask = (x <= 0)  
        out = x.copy()  
        out[self.mask] = 0  
  
        return out  
  
    def backward(self, dout):  
        dout[self.mask] = 0  
        dx = dout  
  
        return dx
```

# 활성화 함수 계층 구현하기

계산 그래프에 활성화 함수 구현 ( Sigmoid)

Sigmoid 수식

$$y = \frac{1}{1 + \exp(-x)}$$



# 활성화 함수 계층 구현하기

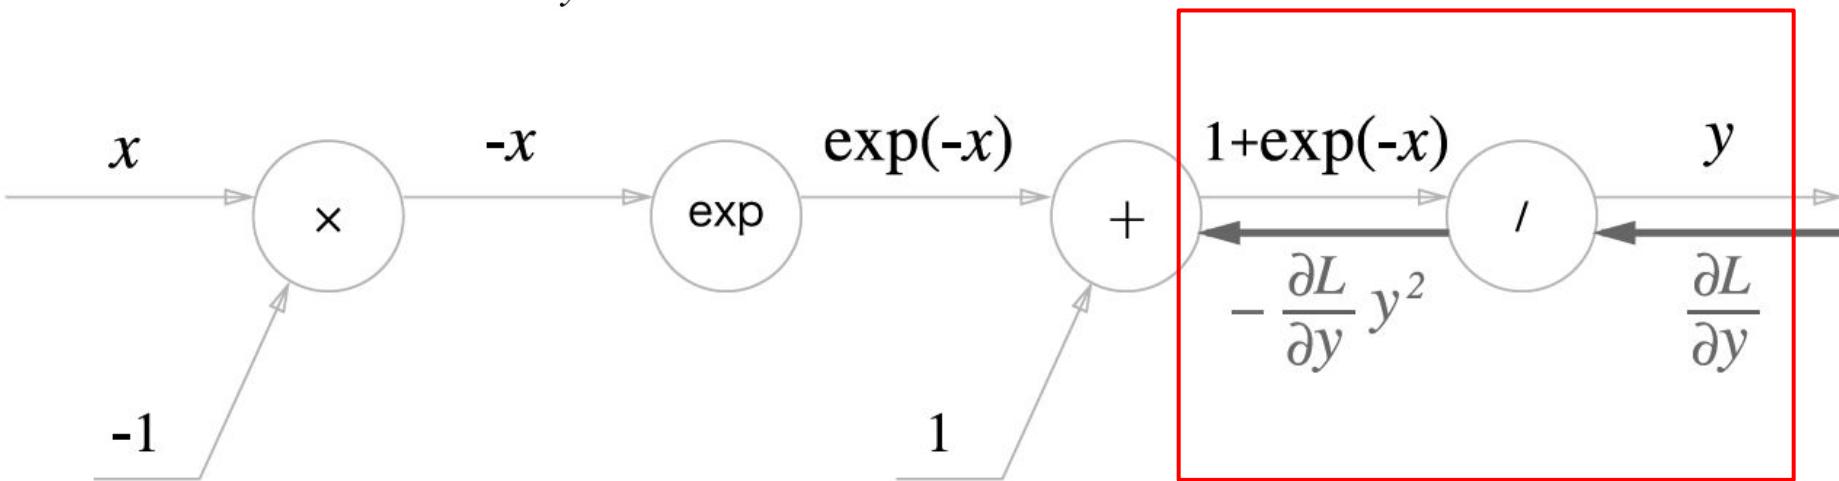
계산 그래프에 활성화 함수 구현 ( Sigmoid)

'/' 노드

$$\frac{\partial y}{\partial x} = -\frac{1}{x^2}$$

$y = 1/x$  의 미분

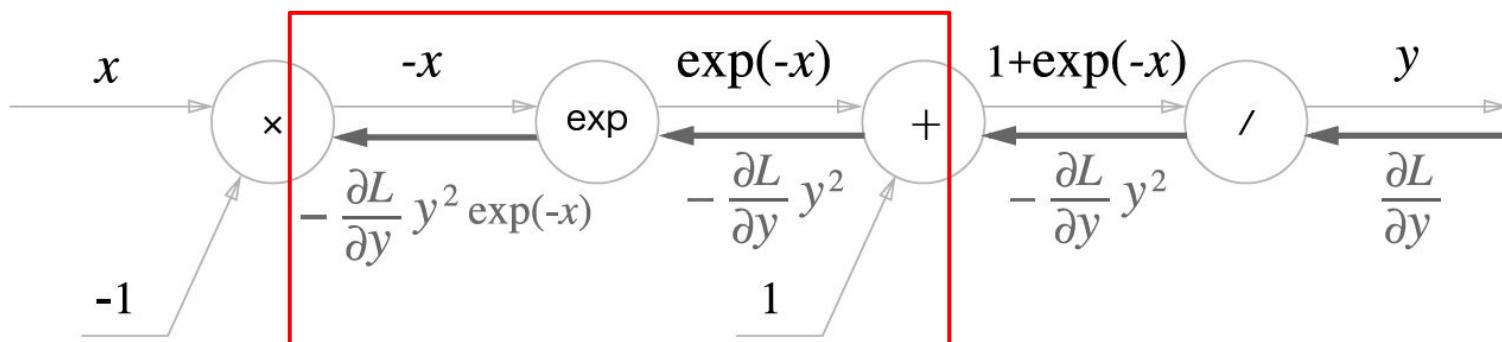
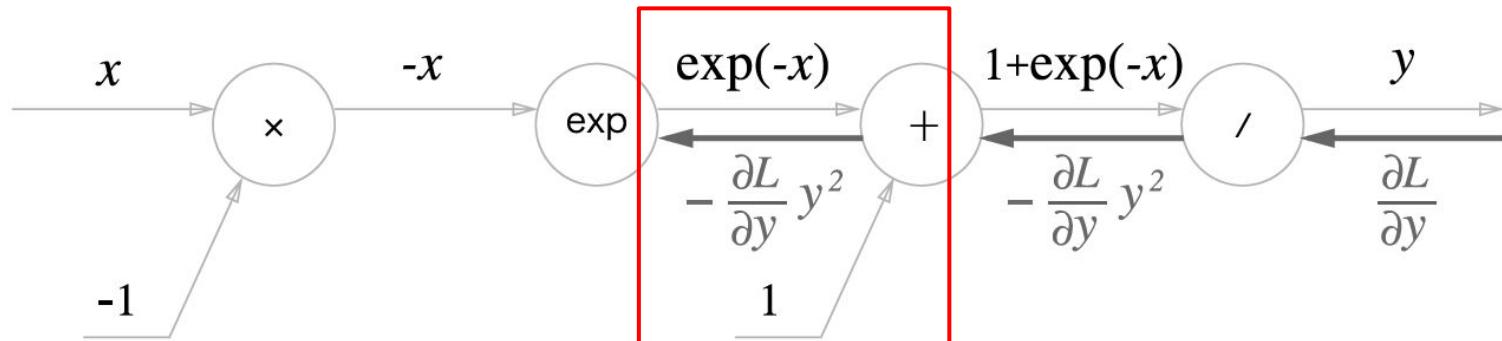
$$= -y^2$$



# 활성화 함수 계층 구현하기

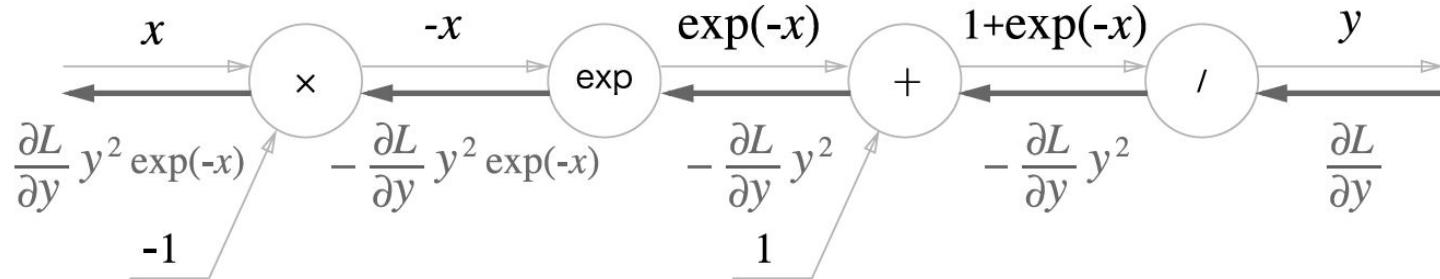
$$y = \exp(x) \quad \frac{\partial y}{\partial x} = \exp(x)$$

계산 그래프에 활성화 함수 구현 ( Sigmoid)

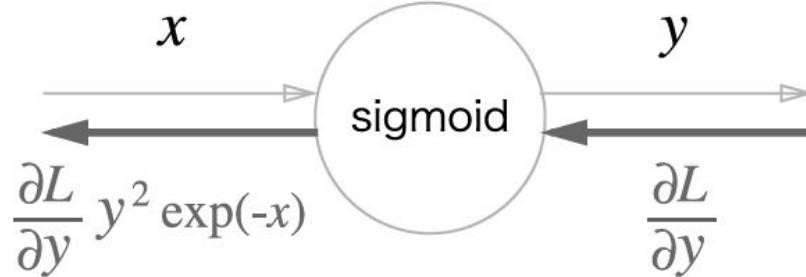


# 활성화 함수 계층 구현하기

계산 그래프에 활성화 함수 구현 ( Sigmoid)



위 계산 과정을 ‘sigmoid’ 노드로 축약!



# 활성화 함수 계층 구현하기

Sigmoid 수식

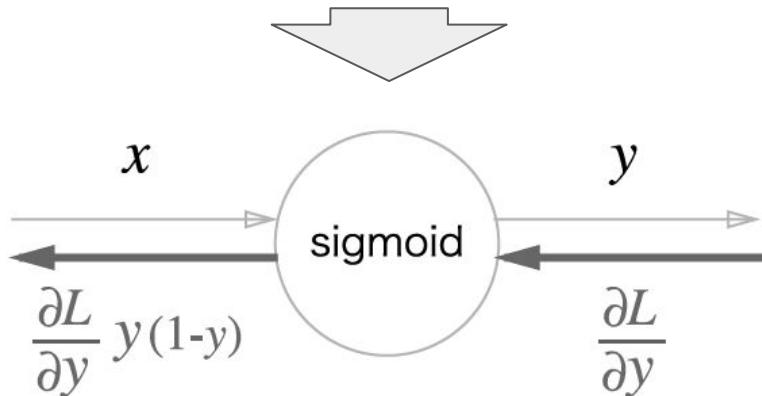
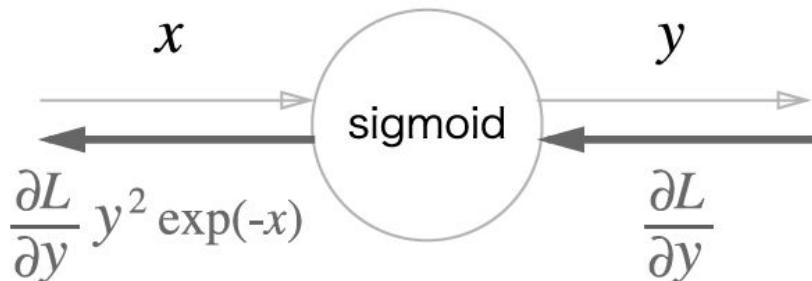
$$y = \frac{1}{1 + \exp(-x)}$$

계산 그래프에 활성화 함수 구현 ( Sigmoid)

$$\begin{aligned}\frac{\partial L}{\partial y} y^2 \exp(-x) &= \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))^2} \exp(-x) \\&= \frac{\partial L}{\partial y} \frac{1}{1 + \exp(-x)} \frac{\exp(-x)}{1 + \exp(-x)} \\&= \frac{\partial L}{\partial y} y(1-y)\end{aligned}$$

# 활성화 함수 계층 구현하기

계산 그래프에 활성화 함수 구현 ( Sigmoid)



```
class Sigmoid:  
    def __init__(self):  
        self.out = None  
  
    def forward(self, x):  
        out = 1 / (1 + np.exp(-x))  
        self.out = out  
  
        return out  
  
    def backward(self, dout):  
        dx = dout * (1.0 - self.out) * self.out  
  
        return dx
```

# Backpropagation (역전파)

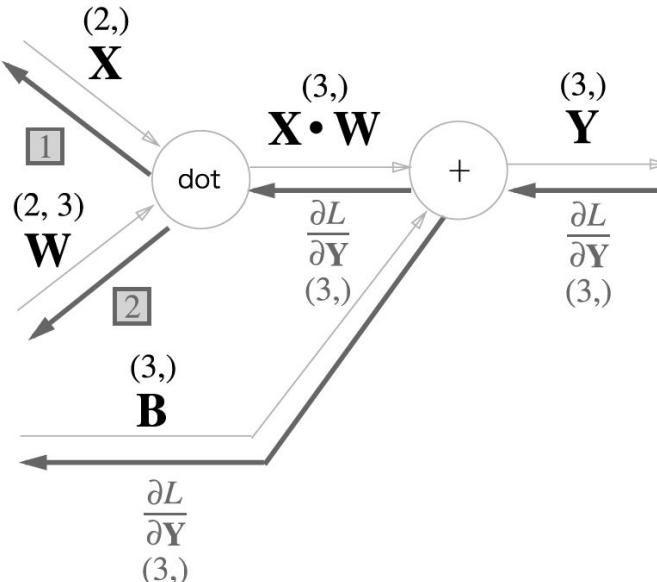
## 배치용 Affine 계층

신경망의 순전파 때 수행하는 행렬의 내적은 기하학에서 ‘Affine transformation’ (어파인 변환)이라고 함

어파인 변환을 수행하는 계층을 ‘Affine 계층’이라고 함

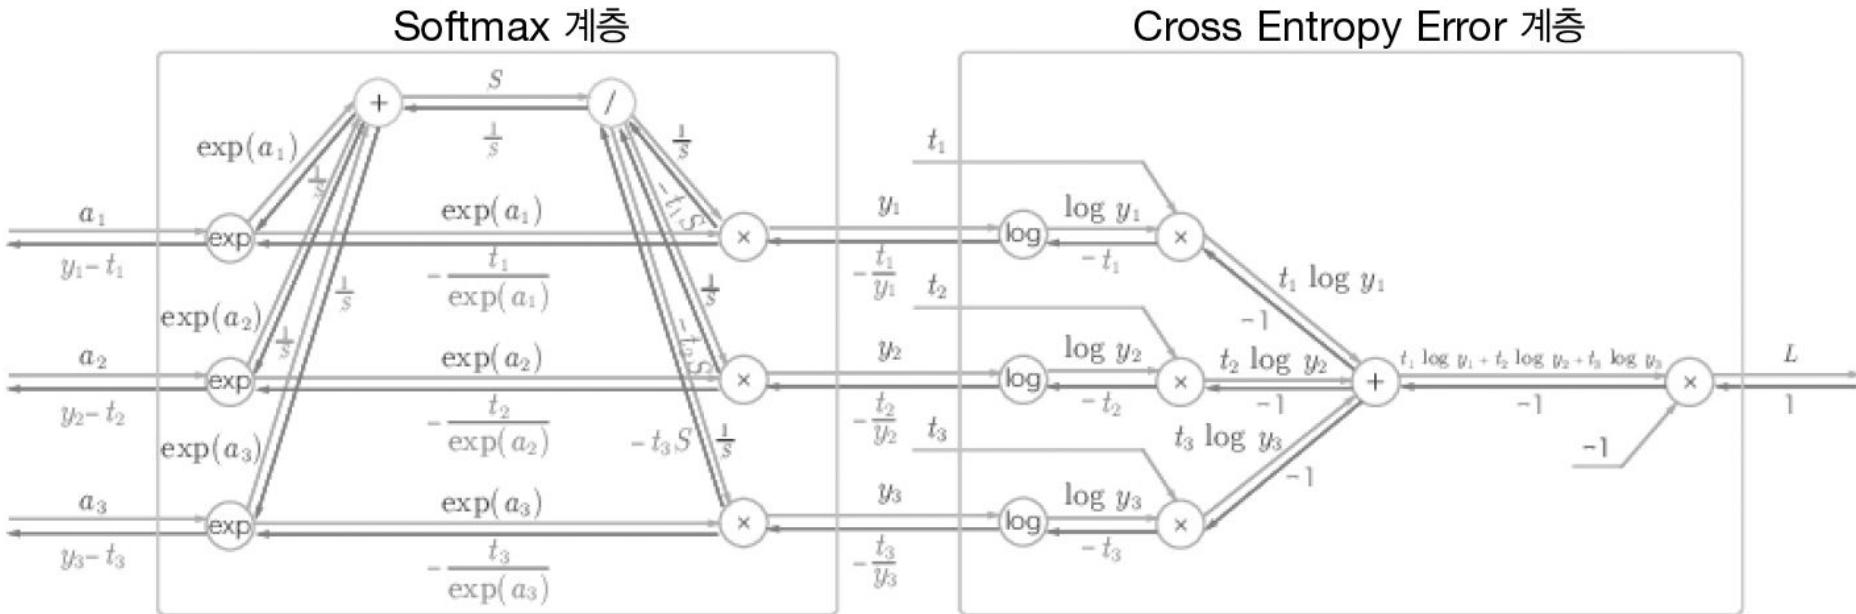
$$\boxed{1} \quad \frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} W^T \quad (2,) \quad (3,) \quad (3, 2)$$

$$\boxed{2} \quad \frac{\partial L}{\partial W} = X^T \frac{\partial L}{\partial Y} \quad (2, 3) \quad (2, 1) \quad (1, 3)$$



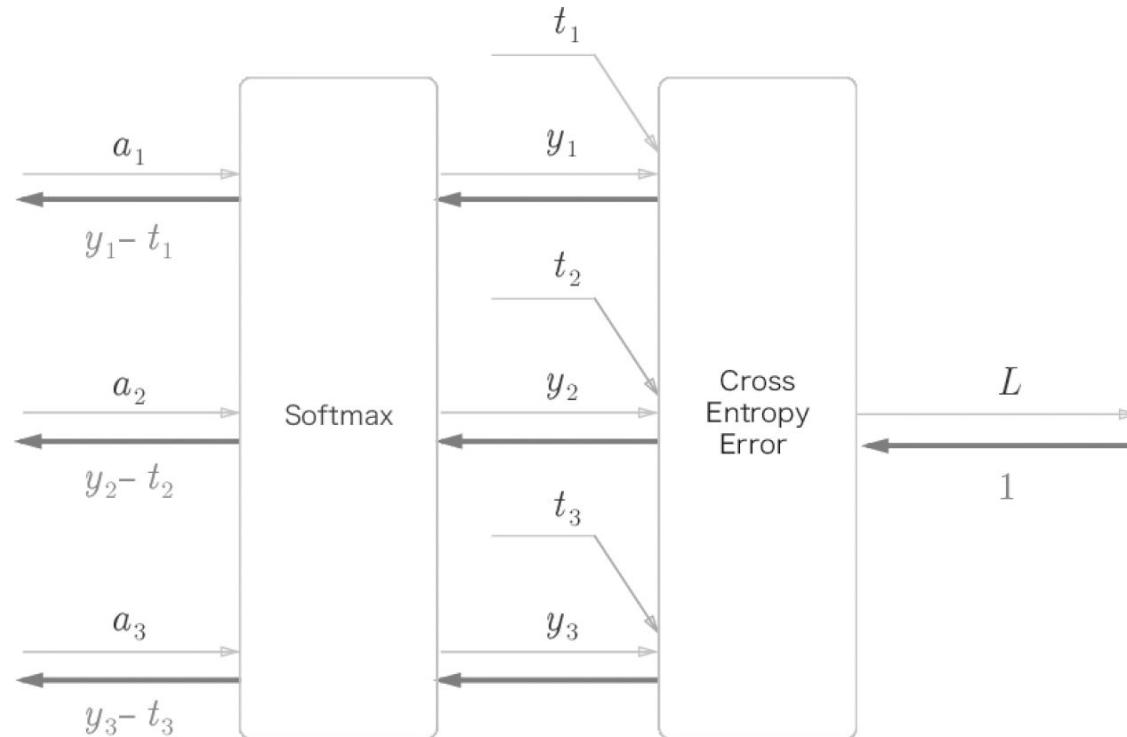
# Backpropagation (역전파)

Softmax-with-Loss 계층



# Backpropagation (역전파)

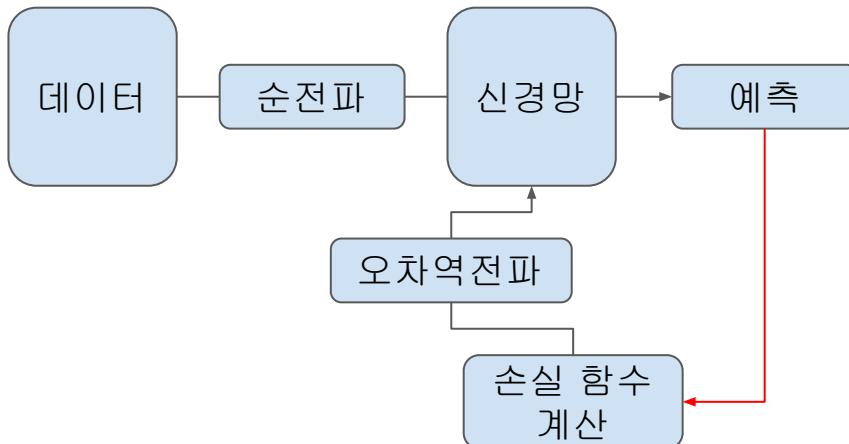
Softmax-with-Loss 계층



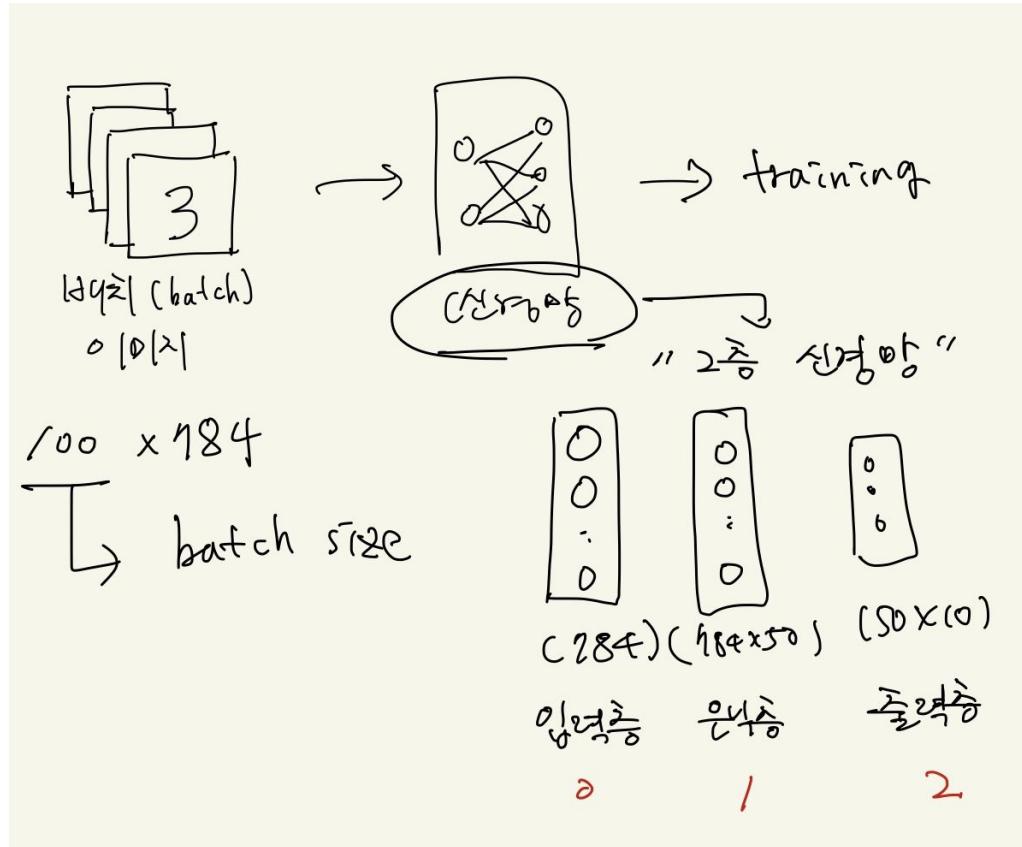
# 현재까지 학습한 내용

- 퍼셉트론
- 활성화 함수
- 다차원 배열의 계산
- 신경망 구현하기, 출력층 설계하기
- 데이터 추론
- 손실함수
- 미니배치
- 경시 하강법 (수치 미분)

=> 오차역전파법



# 오차역전파법 구현하기



앞서 경사하강법에서 구현했던 모델을  
오차역전파법으로 변경해보자

# 오차역전파법 구현하기

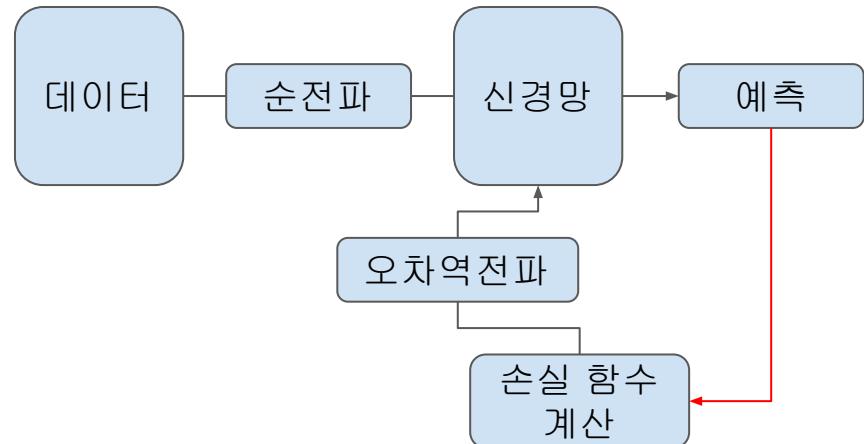
[Colab에서 확인하기](#)

# 지금까지 학습한 내용들

- 계산 그래프를 이용하면 계산 과정을 시각적으로 파악할 수 있다.
- 계산 그래프의 노드는 **국소적 계산**으로 구성된다. 국소적 계산을 조합해 전체 계산을 구성한다.
- 계산 그래프의 **순전파는 통상의 계산**을 수행한다. 한편, 계산 그래프의 **역전파로는 각 노드의 미분**을 구할 수 있다.
- 신경망의 구성 요소를 **계층으로 구현하여 기울기를 효율적으로 계산**할 수 있다(**오차역전파법**).

# 데이터 학습 단계 요약

1. 데이터 읽기 & 전처리
2. 하이퍼파라미터 설정
3. 학습 반복문
  - a. 미니배치 획득
  - b. 기울기 계산 (오차역전파법)
  - c. 가중치 갱신 (learning rate, gradient)
  - d. loss 값 계산, 저장



# 코드로 다시 보는 Neural Network

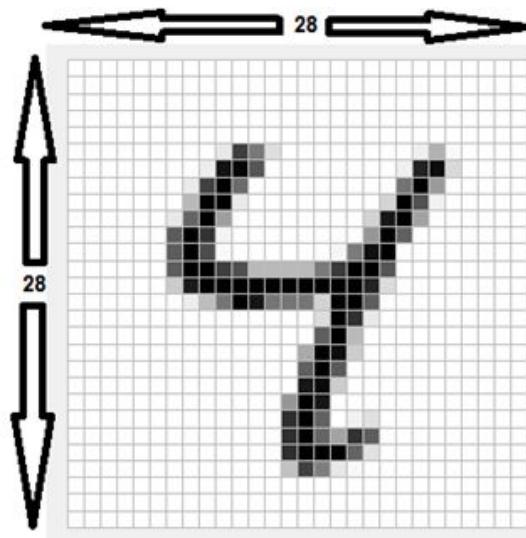
# 코드로 다시 보는 Neural Network

밑바닥 딥러닝 코드  $\rightarrow$  TF 코드 매칭 시키는 내용

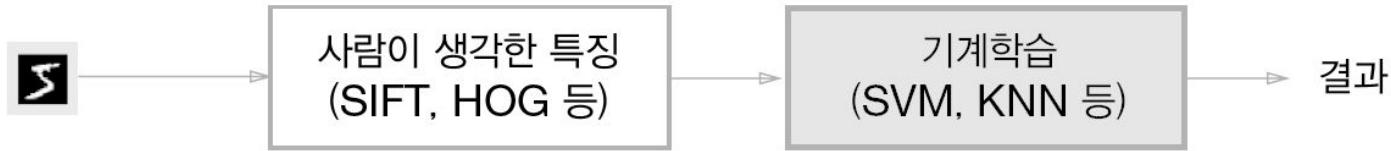
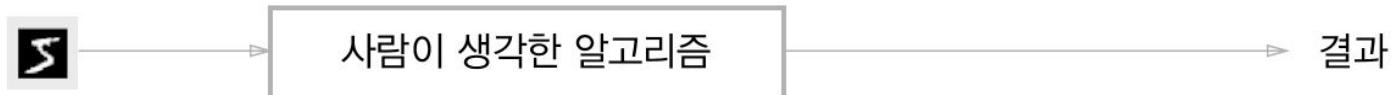
# Training Neural Network

## MNIST dataset

000000000000000000000000  
1111111111111111111111  
2222222222222222222222  
3333333333333333333333  
4444444444444444444444  
5555555555555555555555  
6666666666666666666666  
7777777777777777777777  
8888888888888888888888  
9999999999999999999999

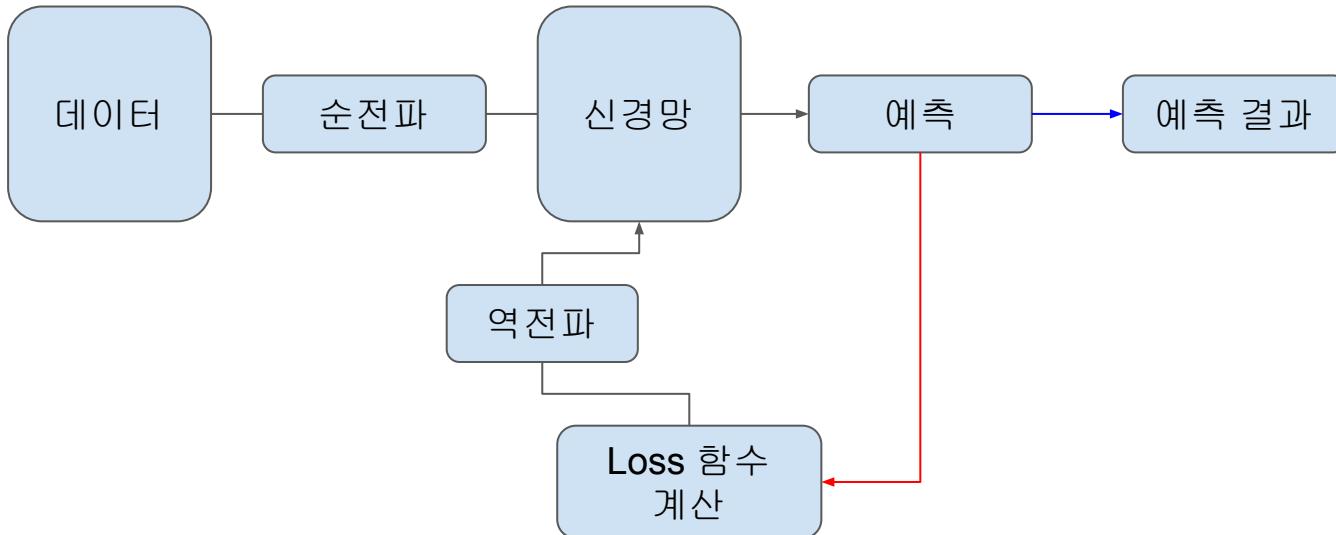


# Training MNIST data



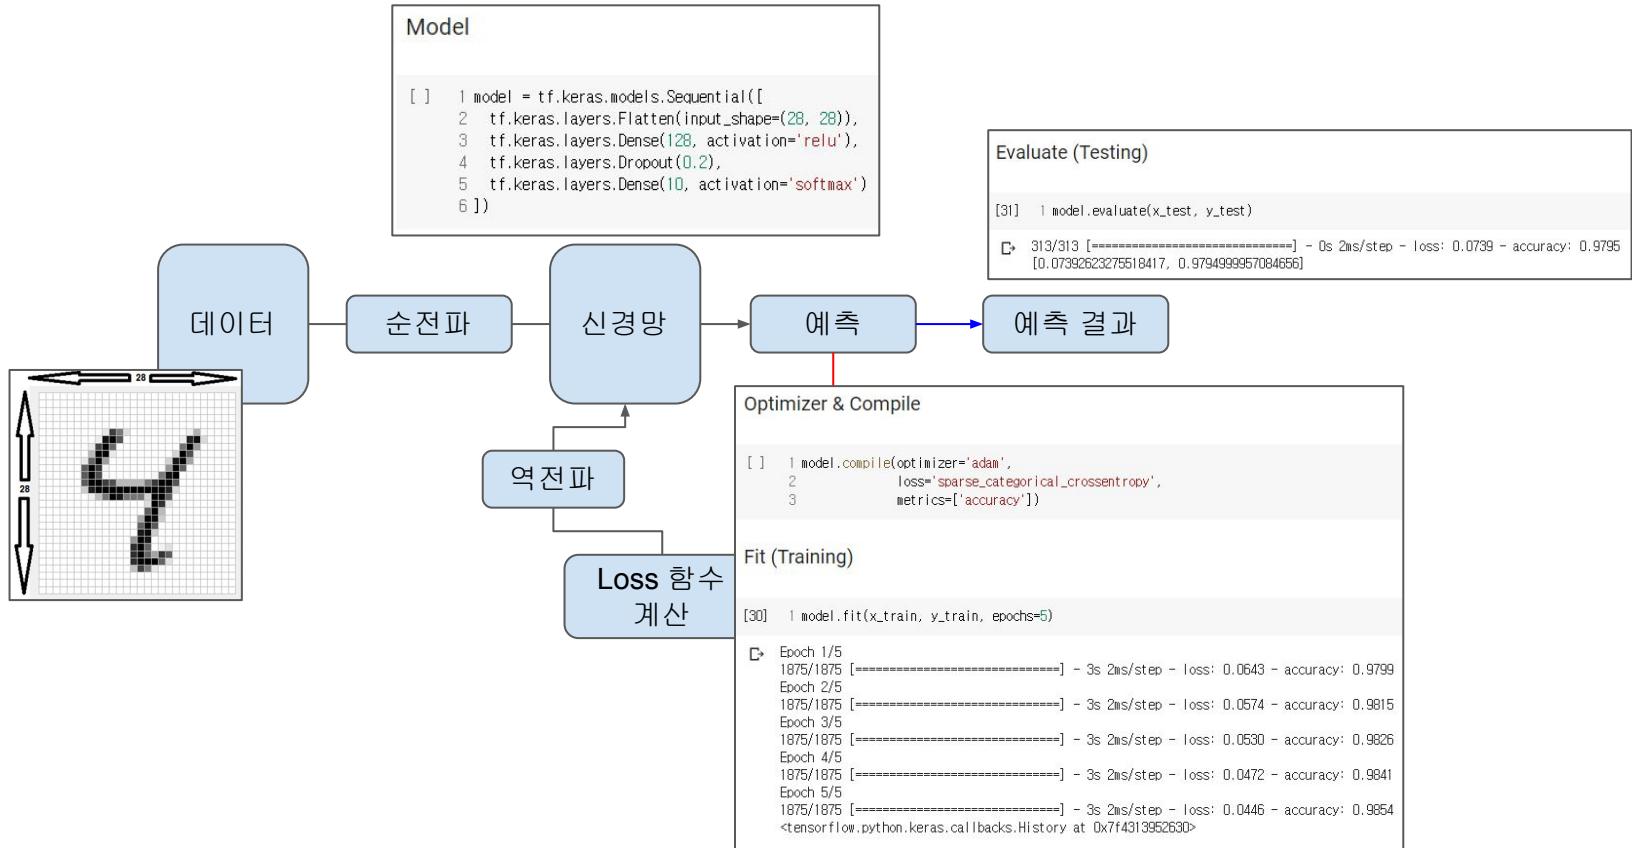
# Training MNIST data

[Colab에서 학습해보기](#)



# Training MNIST data

[Colab에서 학습해보기](#)



# Training MNIST data

## Model

```
[ ] 1 model = tf.keras.models.Sequential([
2   tf.keras.layers.Flatten(input_shape=(28, 28)),
3   tf.keras.layers.Dense(128, activation='relu'),
4   tf.keras.layers.Dropout(0.2),
5   tf.keras.layers.Dense(10, activation='softmax')
6 ])
```

```
[32] 1 model.summary()
```

↳ Model: "sequential"

Layer (type)	Output Shape	Param #
flatten (Flatten)	(None, 784)	0
dense (Dense)	(None, 128)	100480
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 10)	1290

Total params: 101,770  
Trainable params: 101,770  
Non-trainable params: 0

## Optimizer & Compile

```
[ ] 1 model.compile(optimizer='adam',
2                     loss='sparse_categorical_crossentropy',
3                     metrics=['accuracy'])
```

## Fit (Training)

```
[30] 1 model.fit(x_train, y_train, epochs=5)
```

↳ Epoch 1/5  
1875/1875 [=====] - 3s 2ms/step - loss: 0.0643 - accuracy: 0.9799  
Epoch 2/5  
1875/1875 [=====] - 3s 2ms/step - loss: 0.0574 - accuracy: 0.9815  
Epoch 3/5  
1875/1875 [=====] - 3s 2ms/step - loss: 0.0530 - accuracy: 0.9826  
Epoch 4/5  
1875/1875 [=====] - 3s 2ms/step - loss: 0.0472 - accuracy: 0.9841  
Epoch 5/5  
1875/1875 [=====] - 3s 2ms/step - loss: 0.0446 - accuracy: 0.9854  
<tensorflow.python.keras.callbacks.History at 0x7f4313952630>

## Evaluate (Testing)

```
[31] 1 model.evaluate(x_test, y_test)
```

↳ 313/313 [=====] - 0s 2ms/step - loss: 0.0739 - accuracy: 0.9795  
[0.07392623275518417, 0.9794999957084656]

# Training MNIST data

## Model

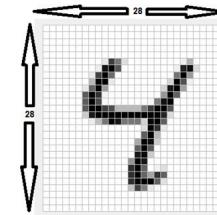
```
[ ] 1 model = tf.keras.models.Sequential([
2   tf.keras.layers.Flatten(input_shape=(28, 28)),
3   tf.keras.layers.Dense(128, activation='relu'),
4   tf.keras.layers.Dropout(0.2),
5   tf.keras.layers.Dense(10, activation='softmax')
6 ])
```

```
[32] 1 model.summary()
```

↳ Model: "sequential"

Layer (type)	Output Shape	Param #
flatten (Flatten)	(None, 784)	0
dense (Dense)	(None, 128)	100480
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 10)	1290

Total params: 101,770  
Trainable params: 101,770  
Non-trainable params: 0



Flatten

input layer

Dense

hidden layer

Dropout



output layer

# Training MNIST data

- Dense? Flatten?
- Dropout?
- softmax? relu?
- loss?
- optimizer?
- epochs?

# epoch / batch / iterations

In the neural network terminology:

one **epoch** = one forward pass and one backward pass of *all* the training examples

**batch size** = the number of training examples in one forward/backward pass. The higher the batch size, the more memory space you'll need.

number of **iterations** = number of passes, each pass using [batch size] number of examples. To be clear, one pass = one forward pass + one backward pass (we do not count the forward pass and backward pass as two different passes).

Example: if you have *1000 training examples*, and your *batch size is 500*, then it will take 2 iterations to complete 1 epoch.

# epoch / batch / iterations

In the neural network terminology:

## 전체 Training example 단위

one **epoch** - one forward pass and one backward pass of all the training examples

**batch size** – the number of training examples you'll need.

number of **iterations** - number of passes  
one forward pass + one backward pass (w)

Example: if you have 1000 training examples, and your batch size is 500, then it will take 2 iterations to complete 1 epoch.

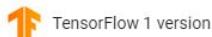
1000개의 Training Example이 있고, **batch size**가 500이면,  
**1 epoch**을 위해 2의 **iteration**이 필요하다

# tf.keras.datasets

[https://www.tensorflow.org/api\\_docs/python/tf/keras/datasets](https://www.tensorflow.org/api_docs/python/tf/keras/datasets)

TensorFlow > API > TensorFlow Core v2.3.0 > Python

## Module: tf.keras.datasets



Public API for tf.keras.datasets namespace.

### Modules

`boston_housing` module: Boston housing price regression dataset.

`cifar10` module: CIFAR10 small images classification dataset.

`cifar100` module: CIFAR100 small images classification dataset.

`fashion_mnist` module: Fashion-MNIST dataset.

`imdb` module: IMDB sentiment classification dataset.

`mnist` module: MNIST handwritten digits dataset.

`reuters` module: Reuters topic classification dataset.

`dataframe` `boston_housing` module: Boston housing price **regression** dataset.

`image` `cifar10` module: CIFAR10 small **images classification** dataset.

`image` `cifar100` module: CIFAR100 small **images classification** dataset.

`image` `fashion_mnist` module: Fashion-MNIST dataset.

`text` `imdb` module: IMDB **sentiment** classification dataset.

`image` `mnist` module: MNIST handwritten **digits** dataset.

`text` `reuters` module: Reuters **topic** classification dataset.

```
1 boston_data = tf.keras.datasets.module name
2 (x_train, y_train), (x_test, y_test) = boston_data.load_data()
```

# dataset 자세히 보기 - boston\_housing 예시

The screenshot shows the TensorFlow Core v2.3.0 API documentation for Python. The left sidebar navigation tree highlights several components: **tf.keras**, **datasets** (which contains **boston\_housing**), and **load\_data**. The main content area displays the **tf.keras.datasets.boston\_housing.load\_data** function, which loads the Boston Housing dataset. It includes a TensorFlow 1 version badge, a GitHub source link, a description, a view aliases button, and a code snippet:

```
tf.keras.datasets.boston_housing.load_data(  
    path='boston_housing.npz', test_split=0.2, seed=113  
)
```

Below the code snippet, a note states: "This is a dataset taken from the StatLib library which is maintained at Carnegie Mellon University. Samples contain 13 attributes of houses at different locations around the Boston suburbs in the late 1970s. Targets are the median values of the houses at a location (in k\$). The attributes themselves are defined in the [StatLib website](#).

# dataset 자세히 보기 - boston\_housing 예시

← → ⌂ ⌂ 안전하지 않음 | lib.stat.cmu.edu/datasets/boston

The Boston house-price data of Harrison, D. and Rubinfeld, D.L. 'Hedonic prices and the demand for clean air', J. Environ. Economics & Management, vol.5, 81-102, 1978. Used in Belsley, Kuh & Welsch, 'Regression diagnostics ... , Wiley, 1980. N.B. Various transformations are used in the table on pages 244-261 of the latter.

**Variables in order:**

CRIM	per capita crime rate by town
ZN	proportion of residential land zoned for lots over 25,000 sq.ft.
INDUS	proportion of non-retail business acres per town
CHAS	Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
NOX	nitric oxides concentration (parts per 10 million)
RM	average number of rooms per dwelling
AGE	proportion of owner-occupied units built prior to 1940
DIS	weighted distances to five Boston employment centres
RAD	index of accessibility to radial highways
TAX	full-value property-tax rate per \$10,000
PTRATIO	pupil-teacher ratio by town
B	$1000(Bk - 0.63)^2$ where Bk is the proportion of blacks by town
LSTAT	% lower status of the population
MEDV	Median value of owner-occupied homes in \$1000's

0.00632	18.00	2.310	0	0.5380	6.5750	65.20	4.0900	1	296.0	15.30
396.90	4.98	24.00								
0.02731	0.00	7.070	0	0.4690	6.4210	78.90	4.9671	2	242.0	17.80
396.90	9.14	21.60								

```
1 boston_data = tf.keras.datasets.boston_housing  
2 (x_train, y_train), (x_test, y_test) = boston_data.load_data()  
  
1 x_train[0]  
  
array([ 1.23247,  0.        ,  8.14        ,  0.        ,  0.538        ,  
       6.142        ,  
       91.7        ,  3.9769        ,  4.        ,  307.        ,  21.        ,  396.9        ,  
      18.72       ])
```

# Training CIFAR data

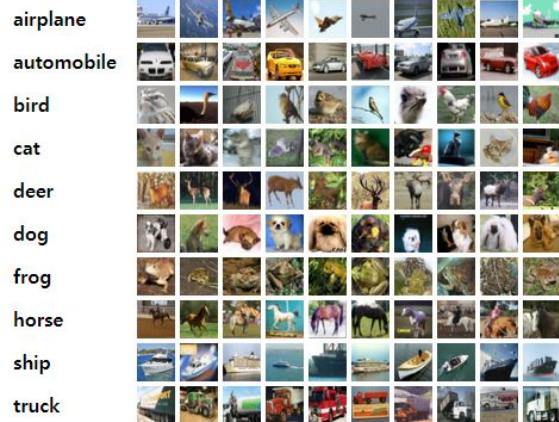
<https://www.cs.toronto.edu/~kriz/cifar.html>

## The CIFAR-10 dataset

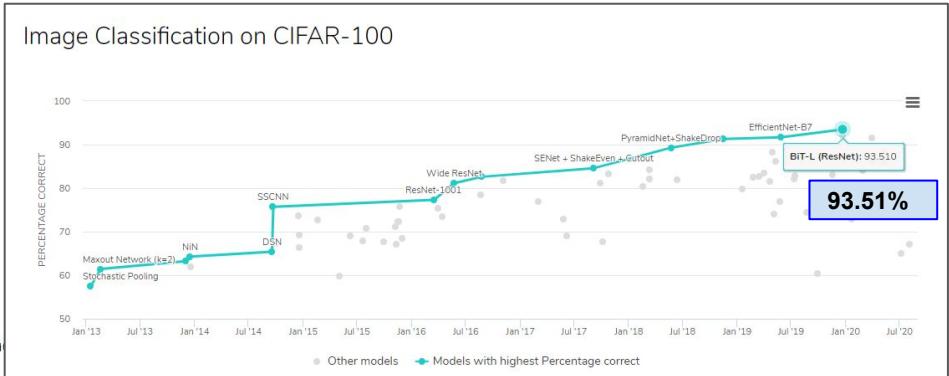
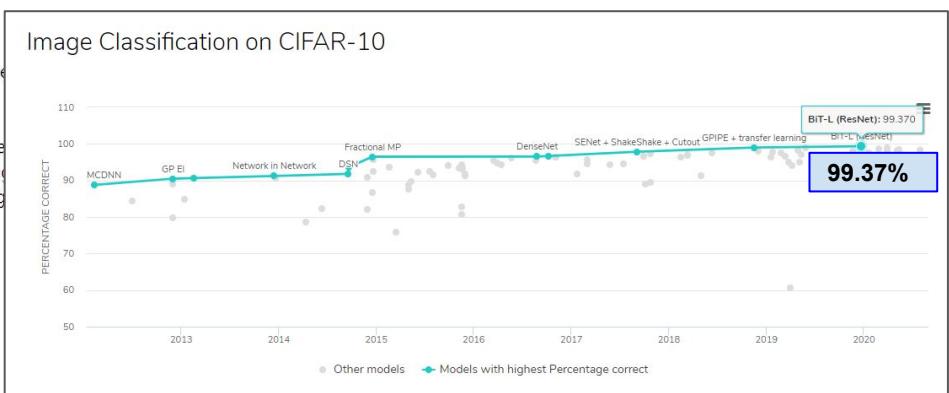
The CIFAR-10 dataset consists of 60000 32x32 colour images in 10 classes, with 6000 image images and 10000 test images.

The dataset is divided into five training batches and one test batch, each with 10000 image randomly-selected images from each class. The training batches contain the remaining images. The batches may contain more images from one class than another. Between them, the training batches from each class.

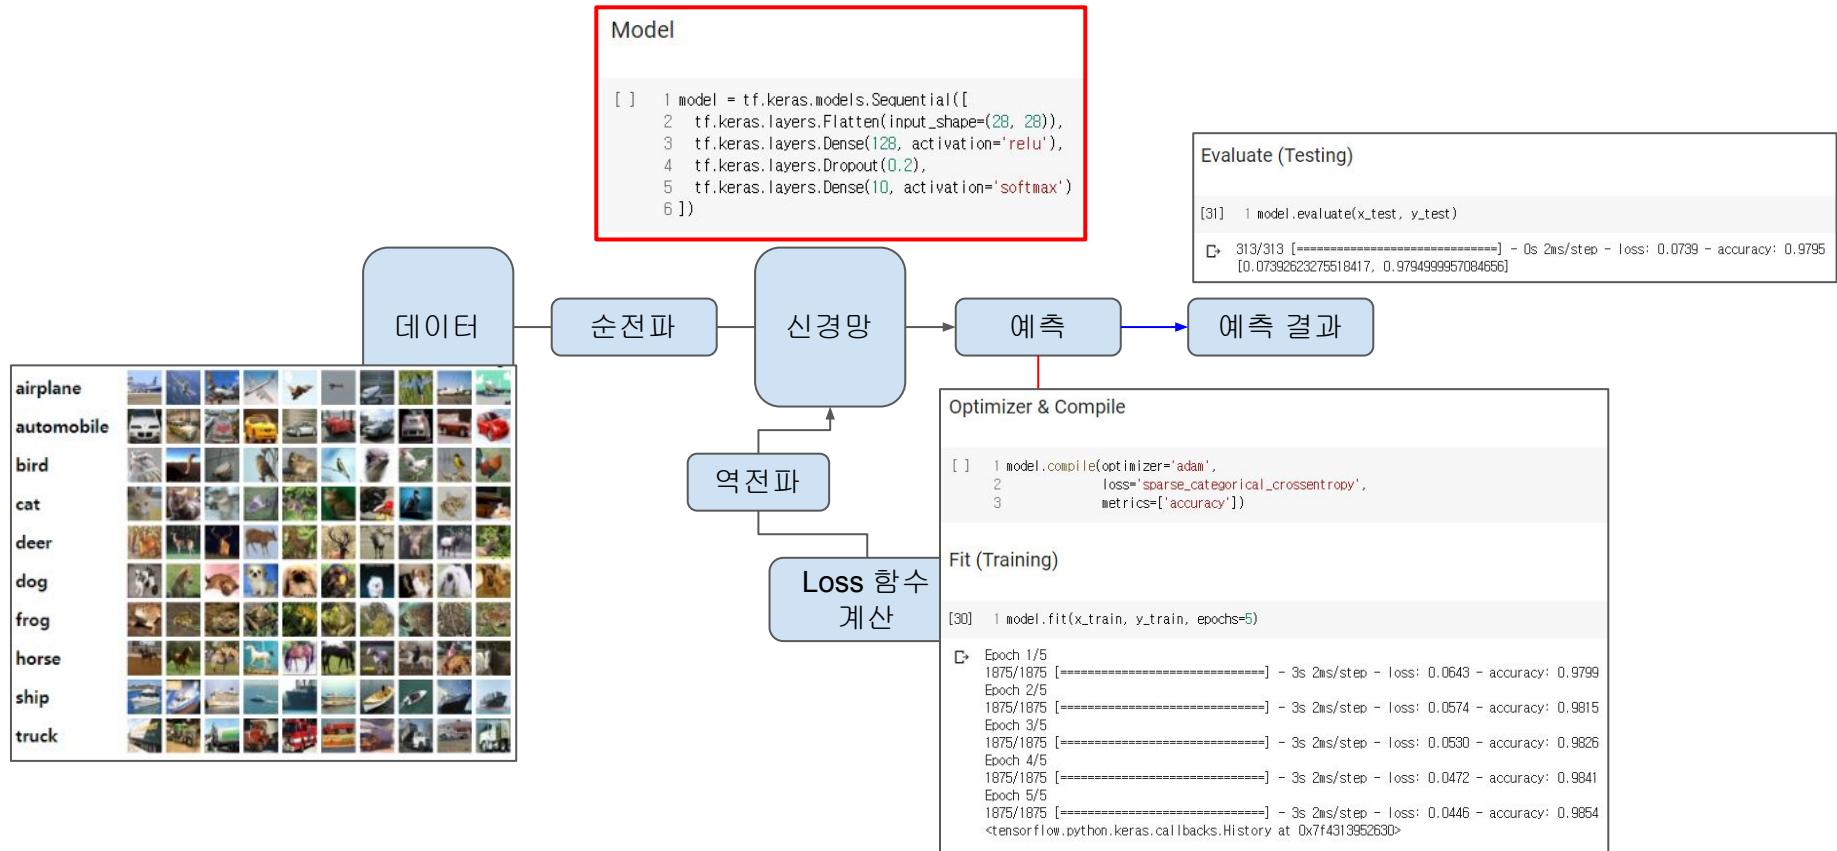
Here are the classes in the dataset, as well as 10 random images from each:



The classes are completely mutually exclusive. There is no overlap between automobiles and SUVs, things of that sort. "Truck" includes only big trucks. Neither includes pickup trucks.



# Training CIFAR-10 data



# Training CIFAR-10 data

MNIST 학습에 사용했던 모델을 그대로 사용해본다

```
1 model = tf.keras.models.Sequential([
2     tf.keras.layers.Flatten(input_shape=x_shape),
3     tf.keras.layers.Dense(128, activation='relu'),
4     tf.keras.layers.Dropout(0.2),
5     tf.keras.layers.Dense(10, activation='softmax')
6 ])
7
8 model.summary()
9
10 model.compile(optimizer='adam',
11                 loss='sparse_categorical_crossentropy',
12                 metrics=['accuracy'])
13
14 model.fit(x_train, y_train, epochs=5)
15 model.evaluate(x_test, y_test)
```

Model: "sequential\_4"

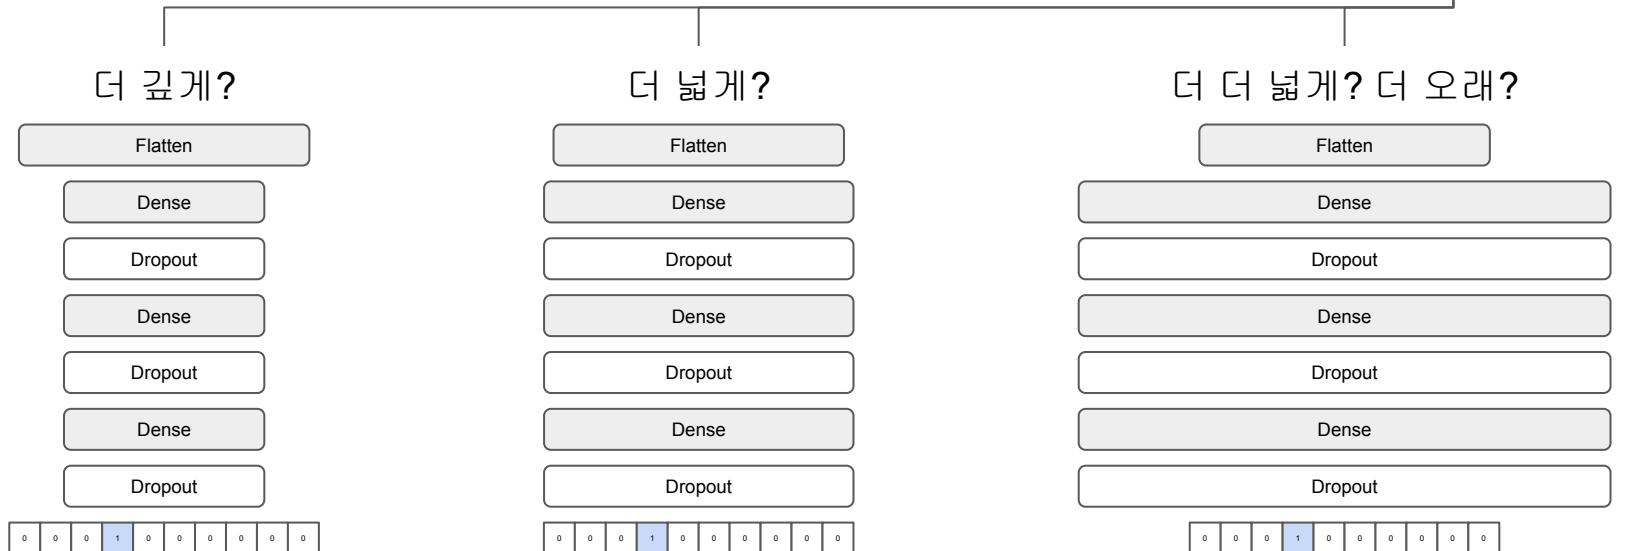
Layer (type)	Output Shape	Param #
flatten_4 (Flatten)	(None, 3072)	0
dense_13 (Dense)	(None, 128)	393344
dropout_9 (Dropout)	(None, 128)	0
dense_14 (Dense)	(None, 10)	1290

Total params: 394,634  
Trainable params: 394,634  
Non-trainable params: 0

```
Epoch 1/5
1563/1563 [=====] - 3s 2ms/step - loss: 2.0212 - accuracy: 0.2469
Epoch 2/5
1563/1563 [=====] - 3s 2ms/step - loss: 1.9198 - accuracy: 0.2915
Epoch 3/5
1563/1563 [=====] - 4s 2ms/step - loss: 1.8924 - accuracy: 0.3037
Epoch 4/5
1563/1563 [=====] - 3s 2ms/step - loss: 1.8731 - accuracy: 0.3095
Epoch 5/5
1563/1563 [=====] - 3s 2ms/step - loss: 1.8685 - accuracy: 0.3129
313/313 [=====] - 1s 2ms/step - loss: 1.7859 - accuracy: 0.3615
[1.7859476804733276, 0.36149999499320984]
```

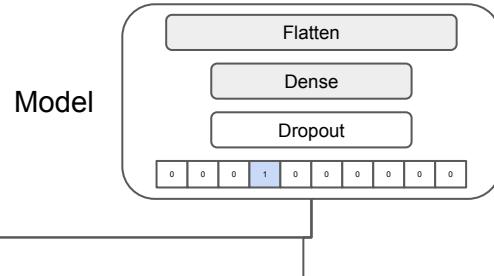
```
1563/1563 [=====] - 3s 2ms/step - loss: 1.8540 - accuracy: 0.3254
Epoch 16/20
1563/1563 [=====] - 3s 2ms/step - loss: 1.8519 - accuracy: 0.3254
Epoch 17/20
1563/1563 [=====] - 4s 2ms/step - loss: 1.8470 - accuracy: 0.3269
Epoch 18/20
1563/1563 [=====] - 3s 2ms/step - loss: 1.8527 - accuracy: 0.3254
Epoch 19/20
1563/1563 [=====] - 3s 2ms/step - loss: 1.8473 - accuracy: 0.3274
Epoch 20/20
1563/1563 [=====] - 4s 2ms/step - loss: 1.8416 - accuracy: 0.3273
313/313 [=====] - 1s 2ms/step - loss: 1.7571 - accuracy: 0.3696
[1.7570570707321167, 0.36959999799728394]
```

# Training CIFAR-10 data



[Colab에서 확인하기](#)

# Training CIFAR-10 data



더 깊게?

Layer (type)	Output Shape	Param #
flatten_10 (Flatten)	(None, 3072)	0
dense_34 (Dense)	(None, 128)	393344
dropout_21 (Dropout)	(None, 128)	0
dense_35 (Dense)	(None, 128)	16512
dropout_22 (Dropout)	(None, 128)	0
dense_36 (Dense)	(None, 128)	16512
dropout_23 (Dropout)	(None, 128)	0
dense_37 (Dense)	(None, 10)	1290
Total params:	427,658	
Trainable params:	427,658	
Non-trainable params:	0	

accuracy: 0.3549

**427,658**

더 넓게?

Layer (type)	Output Shape	Param #
flatten_11 (Flatten)	(None, 3072)	0
dense_38 (Dense)	(None, 256)	786688
dropout_24 (Dropout)	(None, 256)	0
dense_39 (Dense)	(None, 256)	65792
dropout_25 (Dropout)	(None, 256)	0
dense_40 (Dense)	(None, 256)	65792
dropout_26 (Dropout)	(None, 256)	0
dense_41 (Dense)	(None, 256)	65792
dropout_27 (Dropout)	(None, 256)	0
dense_42 (Dense)	(None, 10)	2570
Total params:	986,634	
Trainable params:	986,634	
Non-trainable params:	0	

accuracy: 0.3814

**986,634**

더 더 넓게? & 더 오래?

Layer (type)	Output Shape	Param #
flatten_12 (Flatten)	(None, 3072)	0
dense_43 (Dense)	(None, 1024)	3146752
dropout_28 (Dropout)	(None, 1024)	0
dense_44 (Dense)	(None, 1024)	1049600
dropout_29 (Dropout)	(None, 1024)	0
dense_45 (Dense)	(None, 1024)	1049600
dropout_30 (Dropout)	(None, 1024)	0
dense_46 (Dense)	(None, 1024)	1049600
dropout_31 (Dropout)	(None, 1024)	0
dense_47 (Dense)	(None, 10)	10250
Total params:	6,305,802	
Trainable params:	6,305,802	
Non-trainable params:	0	

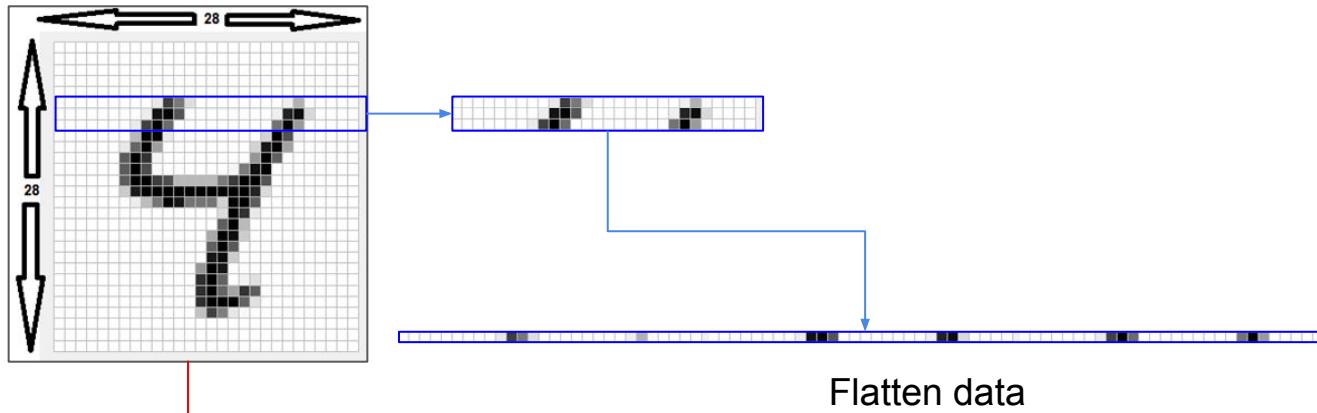
accuracy: 0.4127 / accuracy: 0.4251

20 epoch

100 epoch

성능이 개선되지 않는 이유?

# Fully connected layer (Dense layer)의 한계



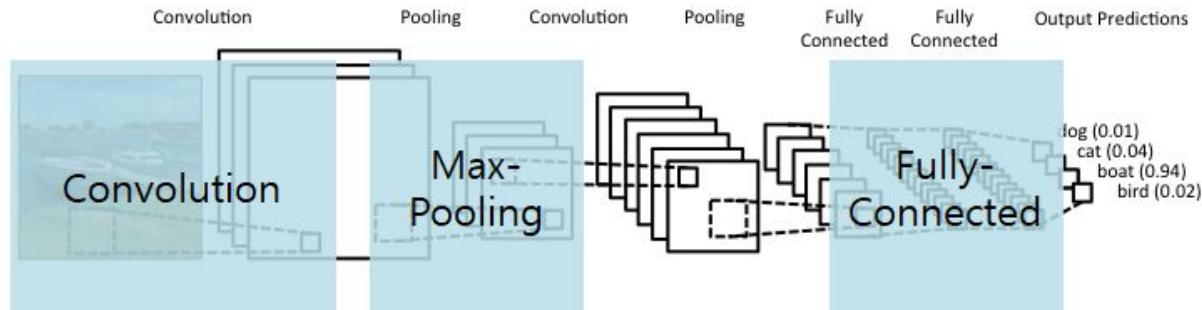
Flatten data

데이터의 형상이 무시되는 문제점이 있음

```
model = tf.keras.models.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(128, activation='relu'),
    tf.keras.layers.Dropout(0.2),
    tf.keras.layers.Dense(10, activation='softmax')
])
```

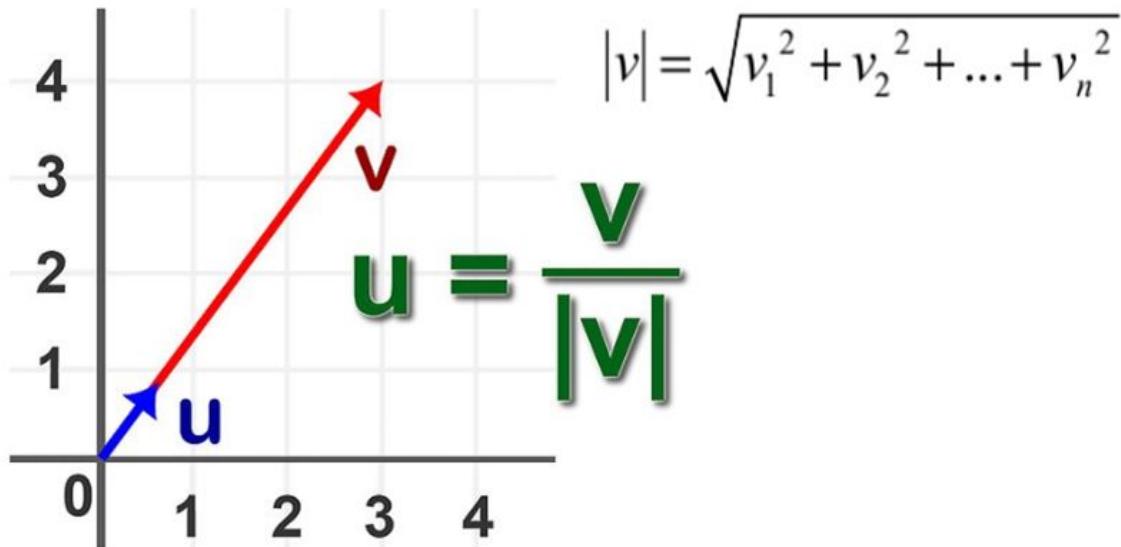
# Convolutional Neural Network (합성곱 신경망)

- Layer의 구성
  - Convolution Layer – Feature 추출
  - Max-Pooling Layer – Local Search
  - Fully-Connected Layer – 최종 분류



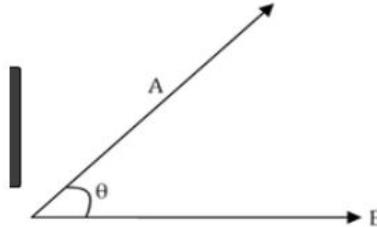
# Convolution Layer

- 정규화 (Normalization)
- 벡터를 자신의 길이로 나누어 주면 길이가 1이고 방향만 남은 단위벡터가 됨
- 벡터의 길이는 벡터의 norm 이라고도 함



# Convolution Layer

- 벡터의 내적 (Inner Product)
- 내적의 기하학적 의미는 A를 B로 사영시킨 선분의 길이와 B의 길이의 곱



$$\vec{A} \cdot \vec{B} = \|\vec{A}\| \|\vec{B}\| \cos \theta$$
$$\cos \theta = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$
$$\theta = \cos^{-1} \left( \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|} \right)$$

- 식으로 나타내면 다음과 같다

$$= x_1y_1 + x_2y_2 + \cdots + x_ny_n = \sum_{i=1}^n x_iy_i$$

$$= \mathbf{x}^T \mathbf{y} = \mathbf{y}^T \mathbf{x}$$

# Convolution Layer

- 정규화 + 내적 =  $\cos(\theta)$
- 앞선 내적 공식에서  $\cos(\theta)$ 값은 다음과 같이 구할 수 있다

$$\cos \theta = \frac{\overrightarrow{A} \cdot \overrightarrow{B}}{\|\overrightarrow{A}\| \|\overrightarrow{B}\|}$$

- 정규화를 시키면 분모의 A,B벡터의 길이가 1이므로 A,B의 내적이  $\cos(\theta)$  값이 됨
- 두 벡터의  $\cos(\theta)$ 값은 두 벡터의 유사성을 비교하는 척도로 사용 가능 (높을수록 유사, 낮을수록 이질)

# Convolution Layer

- **Concatenate**
- 2개의 열벡터 A,B가 있다면

A	B
1	2
2	4
3	6

- concat(A,B) by x 축
- concat(A,B) by y축
- concat(A,B) by z축

A,B	
A	B
1	2
2	4
3	6

1
2
3
2
4
6

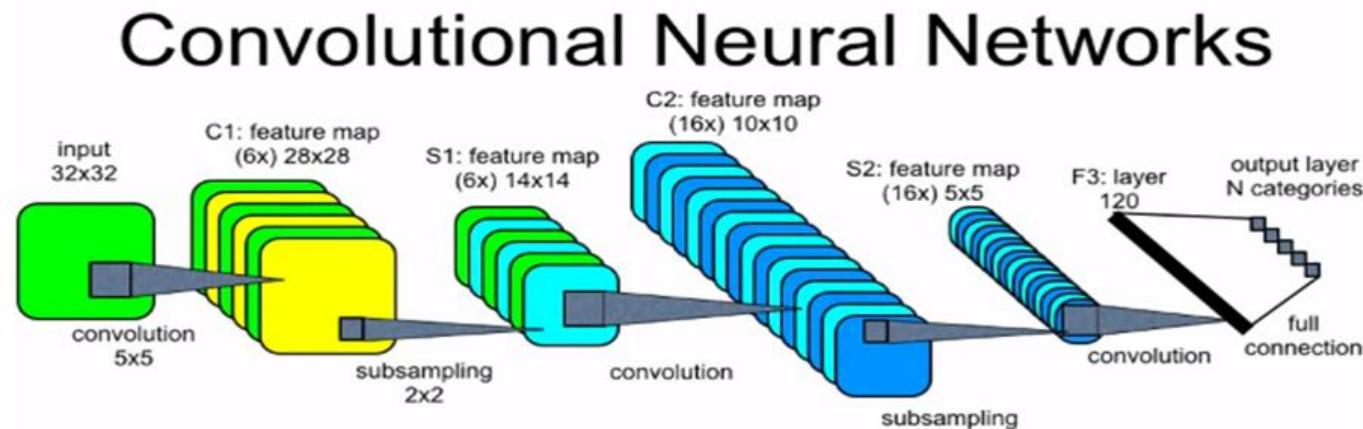
A
1
2
3

벡터가 아닌 행렬 또는 n차원 tensor에도 동일하게 적용

# Convolutional Neural Network (합성곱 신경망)

음성인식, 이미지 인식과 같은 2차원 데이터를 처리하기 좋은 딥 러닝 알고리즘

1. Feature 추출 (Convolution Stage, C<sub>n</sub>)
2. Subsampling, S<sub>n</sub>
3. 위 두 stage를 1차원 벡터 (그림에서는 F3)가 나올 때까지 반복
4. Classification

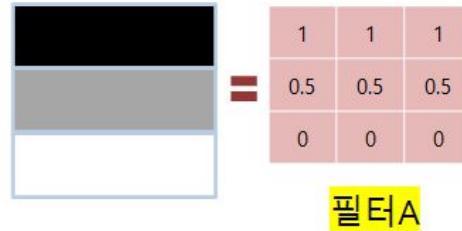


# Convolution Layer

흰색을 0, 회색을 0.5, 검정을 1이라고 했을 때 아래 이미지에서 오른쪽과 같은 특징을 찾고 싶다고 한다면



원래 이미지



필터 A

||

0	0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	0	0
0	0.5	0.5	0	0.5	0	0	0	0
0	0	0	1	1	1	1	0	0
0	1	0.5	0.5	0.5	0.5	0	0	0
0	0	1	0	1	0	0	0	0
0	0	0	0	0	0	0	0	0



정규화 + Convolution!! (합성곱)

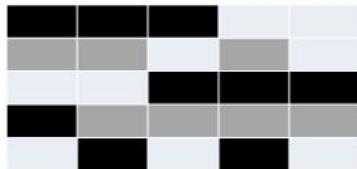
$$\begin{matrix} 1 & 2 \\ 3 & 4 \end{matrix} * \begin{matrix} 5 & 6 \\ 7 & 8 \end{matrix} = 1 \times 5 + 2 \times 6 + 3 \times 7 + 4 \times 8 = 70$$

중앙 파란색은 원래 이미지,  
주변의 옅은 색은 차원을 유지하고 경  
계를 구분하는 역할 (선택)

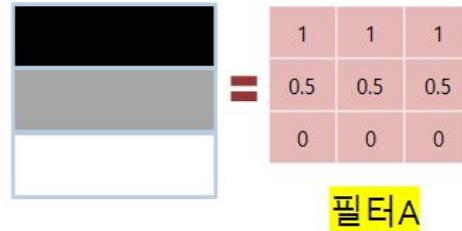
Convolution은 지정된 범위에서의 벡터  
내적이며 정규화가 되어 있으므로  
코사인유사도와 의미가 정확히 같음

# Convolution Layer

흰색을 0, 회색을 0.5, 검정을 1이라고 했을 때 아래 이미지에서 오른쪽과 같은 특징을 찾고 싶다고 한다면



원래 이미지



필터 A

II

0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	0
0	0.5	0.5	0	0.5	0	0	0
0	0	0	1	1	1	0	0
0	1	0.5	0.5	0.5	0.5	0	0
0	0	1	0	1	0	0	0
0	0	0	0	0	0	0	0

중앙 파란색은 원래 이미지,  
주변의 옅은 색은 차원을 유지하고 경  
계를 구분하는 역할 (선택)



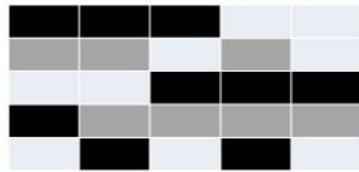
정규화 + Convolution!! (합성곱)

$$\begin{matrix} 1 & 2 \\ 3 & 4 \end{matrix} * \begin{matrix} 5 & 6 \\ 7 & 8 \end{matrix} = 1 \times 5 + 2 \times 6 + 3 \times 7 + 4 \times 8 = 70$$

Convolution은 지정된 범위에서의 벡터  
내적이며 정규화가 되어 있으므로  
코사인유사도와 의미가 정확히 같음

# Convolution Layer

흰색을 0, 회색을 0.5, 검정을 1이라고 했을 때 아래 이미지에서 오른쪽과 같은 특징을 찾고 싶다고 한다면



원래 이미지



필터 A

II

0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	0
0	0.5	0.5	0	0.5	0	0	0
0	0	0	1	1	1	1	0
0	1	0.5	0.5	0.5	0.5	0	0
0	0	1	0	1	0	0	0
0	0	0	0	0	0	0	0

중앙 파란색은 원래 이미지,  
주변의 옅은 색은 차원을 유지하고 경  
계를 구분하는 역할 (선택)



정규화 + Convolution!! (합성곱)

$$\begin{matrix} 1 & 2 \\ 3 & 4 \end{matrix} * \begin{matrix} 5 & 6 \\ 7 & 8 \end{matrix} = 1 \times 5 + 2 \times 6 + 3 \times 7 + 4 \times 8 = 70$$

Convolution은 지정된 범위에서의 벡터  
내적이며 정규화가 되어 있으므로  
코사인유사도와 의미가 정확히 같음

# Convolution Layer

흰색을 0, 회색을 0.5, 검정을 1이라고 했을 때 아래 이미지에서 오른쪽과 같은 특징을 찾고 싶다고 한다면



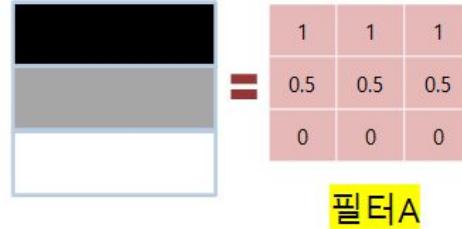
원래 이미지

||

0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	0
0	0.5	0.5	0	0.5	0	0	0
0	0	0	1	1	1	1	0
0	1	0.5	0.5	0.5	0.5	0.5	0
0	0	1	0	1	0	0	0
0	0	0	0	0	0	0	0

필터A

중앙 파란색은 원래 이미지,  
주변의 옅은 색은 차원을 유지하고 경  
계를 구분하는 역할 (선택)



정규화 + Convolution!! (합성곱)

$$\begin{matrix} 1 & 2 \\ 3 & 4 \end{matrix} * \begin{matrix} 5 & 6 \\ 7 & 8 \end{matrix} = 1 \times 5 + 2 \times 6 + 3 \times 7 + 4 \times 8 = 70$$

Convolution은 지정된 범위에서의 벡터  
내적이며 정규화가 되어 있으므로  
코사인유사도와 의미가 정확히 같음

# Convolution Layer

- Filter의 연산을 직접 해 봅시다!

0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	*
0	0.5	0.5	0	0.5	0	0	필터A
0	0	0	1	1	1	0	
0	1	0.5	0.5	0.5	0.5	0	
0	0	1	0	1	0	0	
0	0	0	0	0	0	0	

- 1. 정규화를 거쳐

0.471	0.471	0.471
0.236	0.236	0
0	0	0.471

\*

0.516	0.516	0.516
0.258	0.258	0.258
0	0	0

- 2. Convolution을 하면

=  $0.471 \times 0.516 + 0.471 \times 0.516 + \dots + 0.471 \times 0 = \underline{\underline{0.852}}$

- 수학적 의미를 염밀하게 따지지 않는다면 해당 영역이 필터와 85.2% 유사하다고 생각하여도 무방

# Convolution Layer

- 이 과정을 모든 영역에 적용하면?

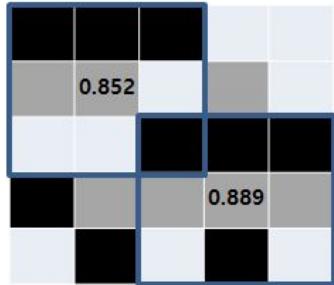
0	0	0	0	0	0	0	0
0	1	1	1	0	0.5	0	0
0	0.5	0.5	0	0.5	0	0	0
0	0	0	1	1	1	0	0
0	1	0.5	0.5	0.5	0.5	0	0
0	0	1	0	1	0	0	0
0	0	0	0	0	0	0	0

\*

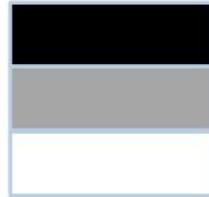
1	1	1
0.5	0.5	0.5
0	0	0

=

0.327	0.414	0.327	0.316	0.183
0.816	0.852	0.609	0.426	0.245
0.390	0.447	0.573	0.516	0.467
0.258	0.552	0.652	0.889	0.690
0.689	0.816	0.778	0.781	0.632



원래 이미지



필터A

원래 이미지에서 필터A와 가장  
유사한 부분은 파란 테두리 부분!

이런 필터를 여러개 사용하여  
Concatenate

# Convolution Layer

- Convolution filter의 예시

- Sharpen

0	0	0	0	0
0	0	-1	0	0
0	-1	5	-1	0
0	0	-1	0	0
0	0	0	0	0



- Edge Detect

0	1	0
1	-4	1
0	1	0



- Blur

0	0	0	0	0
0	1	1	1	0
0	1	1	1	0
0	1	1	1	0
0	0	0	0	0



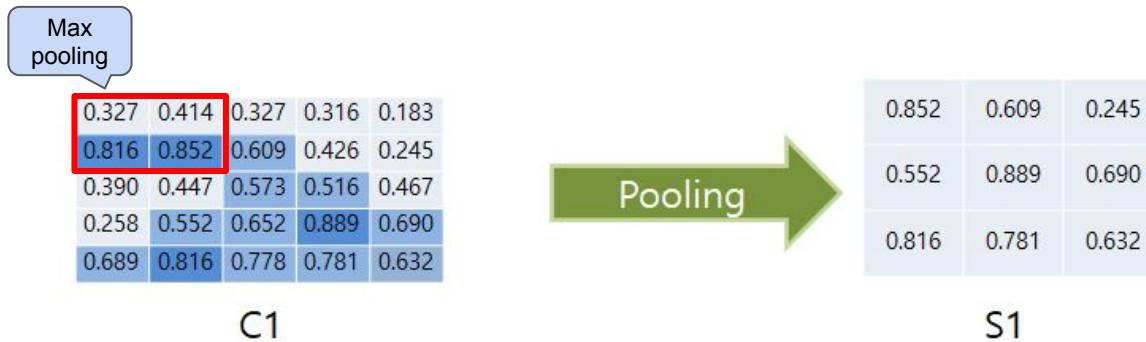
- Emboss

-2	-1	0
-1	1	1
0	1	2



# Pooling Layer

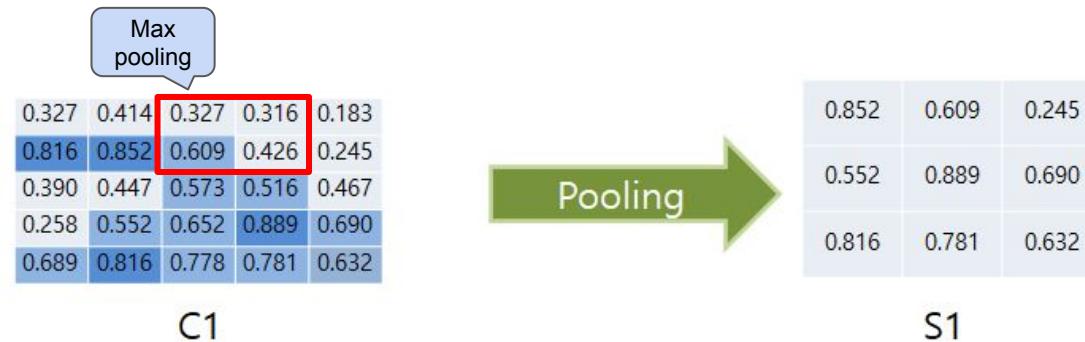
- Convolution을 실행한 C1에서 특징 (통상적으로 2x2 4칸 중 가장 큰 값을 고르는 Max Pooling을 사용)을 추려 냄



- S1을 새로운 Input처럼 생각하며 Convolution과 Subsampling을 반복

# Pooling Layer

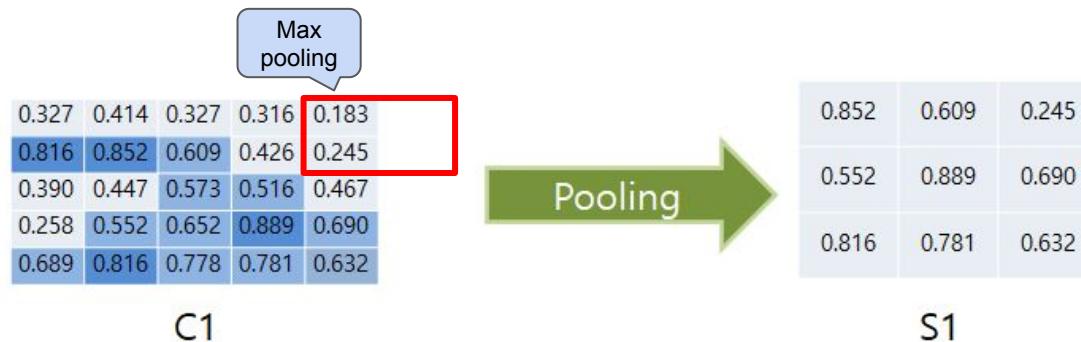
- Convolution을 실행한 C1에서 특징 (통상적으로 2x2 4칸 중 가장 큰 값을 고르는 Max Pooling을 사용)을 추려 냄



- S1을 새로운 Input처럼 생각하며 Convolution과 Subsampling을 반복

# Pooling Layer

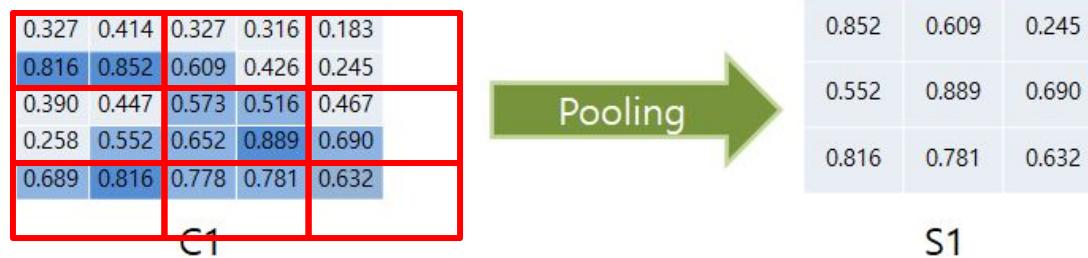
- Convolution을 실행한 C1에서 특징 (통상적으로 2x2 4칸 중 가장 큰 값을 고르는 Max Pooling을 사용)을 추려 냄



- S1을 새로운 Input처럼 생각하며 Convolution과 Subsampling을 반복

# Pooling Layer

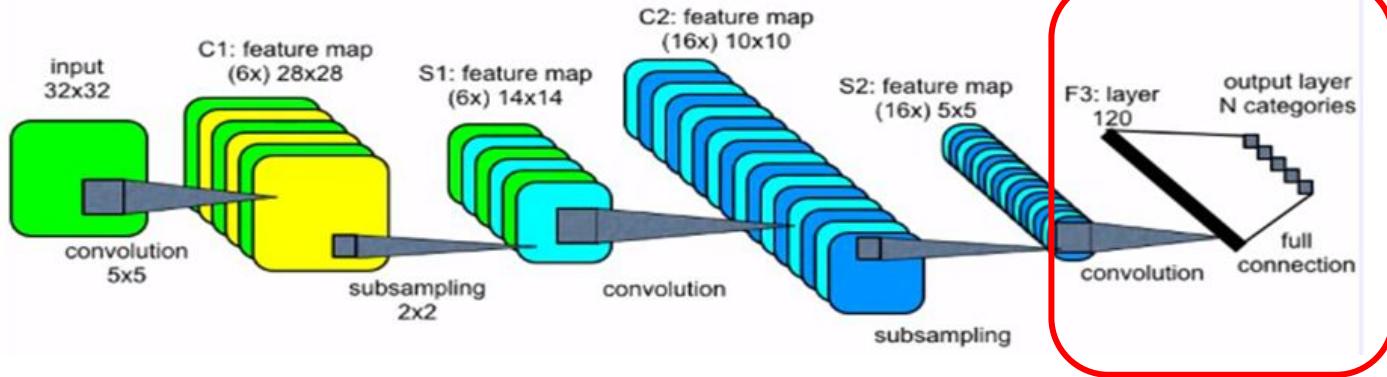
- Convolution을 실행한 C1에서 특징 (통상적으로 2x2 4칸 중 가장 큰 값을 고르는 Max Pooling을 사용)을 추려 냄



- S1을 새로운 Input처럼 생각하며 Convolution과 Subsampling을 반복

# Fully Connected Layer

## Convolutional Neural Networks



- MLP (Multi Layer Perceptron)에서 사용된 구조와 동일함
- 일반적으로 여러 필터를 통과한 특징들을 flatten 시켜  
하나의 벡터로 만든 후 최종 output 예측 직전단계에 활용함

# Some Techniques

## Data Augmentation

- Random cropping to 224 X 224 images
- Altering RGB/Grayscale
- Flipping
- ...



# Some Techniques

- Input 데이터에 이미지 변형 과정을 거쳐 데이터 자체의 특징은 유지하면서 데이터의 양은 늘려 학습의 효율을 크게 증가시킬 수 있는 기법. 데이터의 수가 적을 때 효과가 좋음.

Rotation



Zoom



Flip (Horizontal, Vertical)



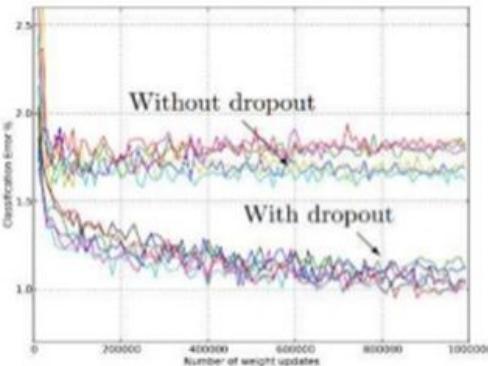
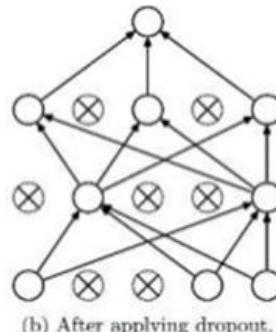
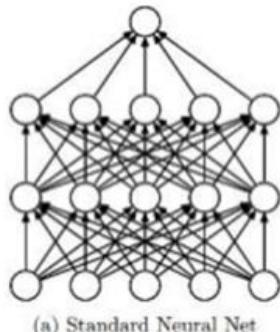
Shift (Width, Height)



# Some Techniques

## Dropout – Avoiding overfitting

- Fully-connected layers Node의 0.0~0.5를 데이터에 따라 off함
- Mini-batch마다 사용하는 neuron의 종류가 달라짐
- 여러 개의 architecture를 ensemble하는 효과가 생김
- Better generalization



# Training CIFAR-10 data

## 합성곱 신경망 (Convolutional Neural Network)

Layer (type)	Output Shape	Param #
conv2d_6 (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d_4 (MaxPooling2D)	(None, 15, 15, 32)	0
conv2d_7 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_5 (MaxPooling2D)	(None, 6, 6, 64)	0
conv2d_8 (Conv2D)	(None, 4, 4, 64)	36928
flatten_8 (Flatten)	(None, 1024)	0
dense_30 (Dense)	(None, 64)	65600
dense_31 (Dense)	(None, 10)	650
<hr/>		
Total params: 122,570		
Trainable params: 122,570		
Non-trainable params: 0		

```
Epoch 1/5  
1563/1563 [=====] - 5s 3ms/step - loss: 1.4835 - accuracy: 0.4626  
Epoch 2/5  
1563/1563 [=====] - 4s 3ms/step - loss: 1.1241 - accuracy: 0.6044  
Epoch 3/5  
1563/1563 [=====] - 4s 3ms/step - loss: 0.9768 - accuracy: 0.6571  
Epoch 4/5  
1563/1563 [=====] - 4s 3ms/step - loss: 0.8794 - accuracy: 0.6931  
Epoch 5/5  
1563/1563 [=====] - 4s 3ms/step - loss: 0.8053 - accuracy: 0.7190  
313/313 [=====] - 1s 2ms/step - loss: 0.8871 [accuracy: 0.6957  
[0.887057900428772, 0.6956999897956848]]
```

훨씬 적은 파라미터 수로 좋은 결과를 얻었음

# Training CIFAR-10 data

epoch 5 -> 50

```
Epoch 45/50
1563/1563 [=====] - 4s 3ms/step - loss: 0.1037 - accuracy: 0.9643
Epoch 46/50
1563/1563 [=====] - 5s 3ms/step - loss: 0.1198 - accuracy: 0.9587
Epoch 47/50
1563/1563 [=====] - 4s 3ms/step - loss: 0.1102 - accuracy: 0.9617
Epoch 48/50
1563/1563 [=====] - 4s 3ms/step - loss: 0.1116 - accuracy: 0.9626
Epoch 49/50
1563/1563 [=====] - 4s 3ms/step - loss: 0.1026 - accuracy: 0.9651
Epoch 50/50
1563/1563 [=====] - 5s 3ms/step - loss: 0.1105 - accuracy: 0.9628
313/313 [=====] - 1s 2ms/step - loss: 2.5728 - accuracy: 0.6903
[2.5728492736816406, 0.6902999877929688]
```

학습 epoch를 50으로 늘렸지만 test accuracy에서 개선이 없었음

# Training CIFAR-10 data

Model: "sequential\_3"

Layer (type)	Output Shape	Param #
conv2d_11 (Conv2D)	(None, 30, 30, 64)	1792
max_pooling2d_8 (MaxPooling2)	(None, 15, 15, 64)	0
conv2d_12 (Conv2D)	(None, 13, 13, 128)	73856
max_pooling2d_9 (MaxPooling2)	(None, 6, 6, 128)	0
conv2d_13 (Conv2D)	(None, 4, 4, 128)	147584
flatten_1 (Flatten)	(None, 2048)	0
dense_2 (Dense)	(None, 128)	262272
dense_3 (Dense)	(None, 10)	1290
Total params: 486,794		
Trainable params: 486,794		
Non-trainable params: 0		

```
Epoch 47/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.0700 - accuracy: 0.9794
Epoch 48/50
1563/1563 [=====] - 11s 7ms/step - loss: 0.0782 - accuracy: 0.9768
Epoch 49/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.0722 - accuracy: 0.9784
Epoch 50/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.0712 - accuracy: 0.9786
313/313 [=====] - 1s 4ms/step - loss: 3.1726 - accuracy: 0.6930
[3.172563076019287, 0.6930000185966492]
```

**accuracy: 0.6930**

layer를 추가했으나 비슷한 성능

Layer (type)	Output Shape	Param #
conv2d_14 (Conv2D)	(None, 30, 30, 64)	1792
max_pooling2d_10 (MaxPooling2)	(None, 15, 15, 64)	0
conv2d_15 (Conv2D)	(None, 13, 13, 128)	73856
max_pooling2d_11 (MaxPooling2)	(None, 6, 6, 128)	0
conv2d_16 (Conv2D)	(None, 4, 4, 128)	147584
flatten_2 (Flatten)	(None, 2048)	0
dropout (Dropout)	(None, 2048)	0
dense_4 (Dense)	(None, 128)	262272
dense_5 (Dense)	(None, 10)	1290
Total params: 486,794		
Trainable params: 486,794		
Non-trainable params: 0		

```
Epoch 47/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.1414 - accuracy: 0.9532
Epoch 48/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.1410 - accuracy: 0.9519
Epoch 49/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.1336 - accuracy: 0.9546
Epoch 50/50
1563/1563 [=====] - 12s 7ms/step - loss: 0.1382 - accuracy: 0.9543
313/313 [=====] - 1s 4ms/step - loss: 1.5392 - accuracy: 0.7249
[1.539198875427246, 0.7249000072479248]
```

**accuracy: 0.7249**

Dropout을 적용한 결과 약간의 개선

# Fashion-MNIST data



레이블	클래스
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

# Fashion-MNIST data

데이터 불러오기 & 정규화

```
1 import tensorflow as tf
2 fashion_mnist = tf.keras.datasets.fashion_mnist
3 (x_train, y_train), (x_test, y_test) = fashion_mnist.load_data()
4
5 x_train = x_train.reshape((60000, 28, 28, 1))
6 x_test = x_test.reshape((10000, 28, 28, 1))
7
8 # 픽셀 값을 0~1 사이로 정규화합니다.
9 x_train, x_test = x_train / 255.0, x_test / 255.0
```

# Fashion-MNIST data

## 모델 정의하기

### CNN?

```
1 from tensorflow.keras import datasets, layers, models
2
3 model = models.Sequential()
4 model.add(layers.Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
5 model.add(layers.MaxPooling2D((2, 2)))
6 model.add(layers.Conv2D(64, (3, 3), activation='relu'))
7 model.add(layers.MaxPooling2D((2, 2)))
8 model.add(layers.Conv2D(64, (3, 3), activation='relu'))
9 model.add(layers.Flatten())
10 model.add(layers.Dense(64, activation='relu'))
11 model.add(layers.Dense(10, activation='softmax'))
```

### MLP?

```
1 from tensorflow import keras
2 # layer를 하나씩 추가하는 방식
3 model = keras.models.Sequential()
4 model.add(keras.layers.Flatten(input_shape=[28,28]))
5 model.add(keras.layers.Dense(300, activation="relu"))
6 model.add(keras.layers.Dense(100, activation="relu"))
7 model.add(keras.layers.Dense(10, activation="softmax"))
8
9 # 층 리스트로 전달하는 방식
10 model = keras.models.Sequential([
11     keras.layers.Flatten(input_shape=[28,28]),
12     keras.layers.Dense(300, activation="relu"),
13     keras.layers.Dense(100, activation="relu"),
14     keras.layers.Dense(10, activation="softmax"),
15 ])
```

# Fashion-MNIST data

## 모델 컴파일 & 모델 학습 및 평가

```
model.compile(loss="sparse_categorical_crossentropy", optimizer="sgd", metrics=["accuracy"])
history = model.fit(x_train, y_train, epochs=30, validation_data=(x_test, y_test))
```

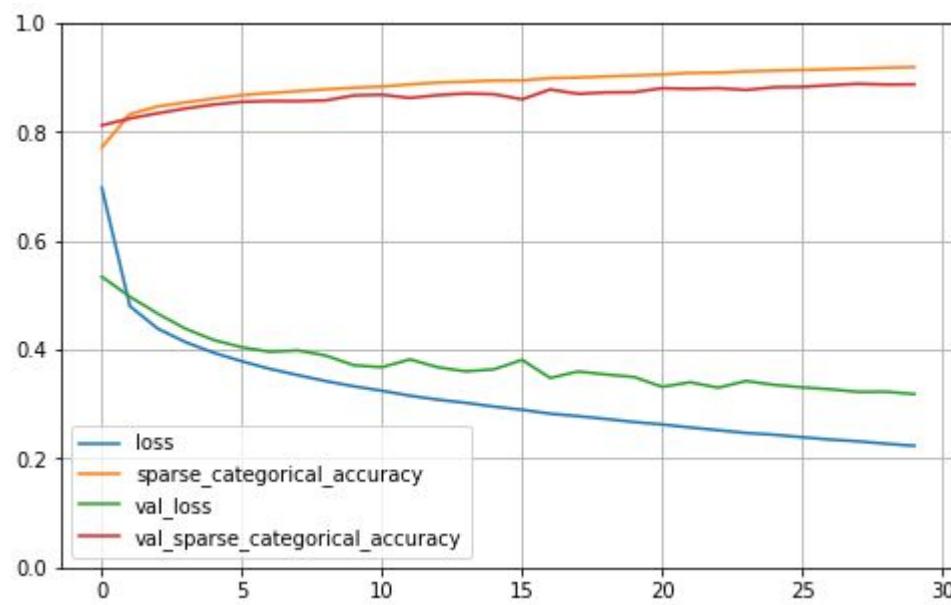
```
1875/1875 [=====] - 6s 3ms/step - loss: 0.2521 - sparse_categorical_accuracy: 0.9088 - val_loss: 0.3303 - val_sparse_categorical_accuracy: 0.8804
Epoch 24/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2471 - sparse_categorical_accuracy: 0.9111 - val_loss: 0.3425 - val_sparse_categorical_accuracy: 0.8771
Epoch 25/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2438 - sparse_categorical_accuracy: 0.9126 - val_loss: 0.3354 - val_sparse_categorical_accuracy: 0.8821
Epoch 26/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2392 - sparse_categorical_accuracy: 0.9137 - val_loss: 0.3308 - val_sparse_categorical_accuracy: 0.8827
Epoch 27/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2350 - sparse_categorical_accuracy: 0.9150 - val_loss: 0.3274 - val_sparse_categorical_accuracy: 0.8858
Epoch 28/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2317 - sparse_categorical_accuracy: 0.9164 - val_loss: 0.3225 - val_sparse_categorical_accuracy: 0.8885
Epoch 29/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2273 - sparse_categorical_accuracy: 0.9179 - val_loss: 0.3228 - val_sparse_categorical_accuracy: 0.8870
Epoch 30/30
1875/1875 [=====] - 6s 3ms/step - loss: 0.2234 - sparse_categorical_accuracy: 0.9190 - val_loss: 0.3186 - val_sparse_categorical_accuracy: 0.8873
```

# Fashion-MNIST data

학습 곡선 확인하기

```
import pandas as pd
import matplotlib.pyplot as plt

pd.DataFrame(history.history).plot(figsize=(8,5))
plt.grid(True)
plt.gca().set_ylim(0, 1)
plt.show()
```



# Fashion-MNIST data

## 모델 평가

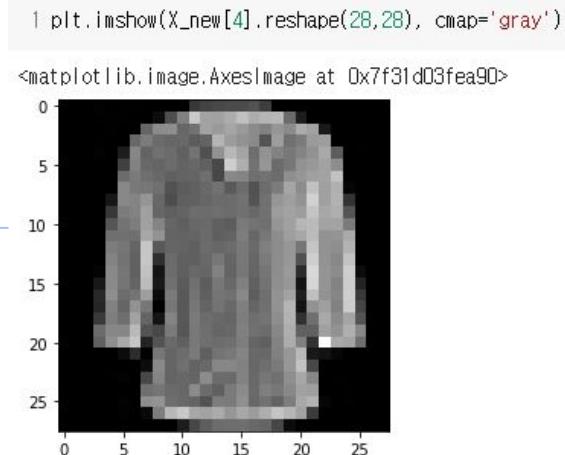
```
1 model.evaluate(x_test, y_test)  
  
313/313 [=====] - 1s 2ms/step - loss: 0.3247 - sparse_categorical_accuracy: 0.8860  
[0.32465073466300964, 0.8859999775886536]
```

## 데이터 예측하기

```
1 X_new = x_test[:5]  
2 y_proba = model.predict(X_new)  
3 y_proba.round(2)
```

array([[0., 0., 0., 0., 0., 0., 0., 0.01, 0., 0.98], [0., 0., 0.98, 0., 0.02, 0., 0., 0., 0., 0.], [0., 1., 0., 0., 0., 0., 0., 0., 0., 0.], [0., 1., 0., 0., 0., 0., 0., 0., 0., 0.], [0.49, 0., 0.02, 0., 0.01, 0., 0.48, 0., 0., 0.]]),	T-shirt/top	Shirt
--	-------------	-------



# Fashion-MNIST data

## 모델 저장 & 복원

```
1 model.save('fashion_mnist_mlp_model.h5')
```

```
1 model_loaded = keras.models.load_model('fashion_mnist_mlp_model.h5')
```

```
1 y_proba = model_loaded.predict(X_new)  
2 y_proba.round(2)
```

```
array([[0. , 0. , 0. , 0. , 0. , 0. , 0. , 0.01, 0. , 0.98],  
       [0. , 0. , 0.98, 0. , 0.02, 0. , 0. , 0. , 0. , 0. ],  
       [0. , 1. , 0. , 0. , 0. , 0. , 0. , 0. , 0. , 0. ],  
       [0. , 1. , 0. , 0. , 0. , 0. , 0. , 0. , 0. , 0. ],  
       [0.49, 0. , 0.02, 0. , 0.01, 0. , 0.48, 0. , 0. , 0. ]],
```

복원된 모델의 예측결과가  
저장한 모델과 같은 것을 확인함